

TECHNICAL RESEARCH REPORT

# 城市洪水深度超分辨率重建中的深水欠估问题 诊断、修正与方法学检验

以新西兰惠灵顿城区洪水数据集为例，10 米到 2 米最大淹没水深重建

研究对象 HydroGeo-SRNO 引导式超分辨率模型与深水加权损失项

数据 Wellington Urban Flood Dataset (NZTM2000 / EPSG:2193)

计算设备 单卡 NVIDIA GeForce GTX 950M, 显存 4 GB

报告日期 2026 年 9 月 29 日

# 目录

## 1. 摘要

## 2. 研究背景与目的

2.1 为什么需要把粗网格水深还原到细网格

2.2 引导式超分辨率的含义

2.3 一个长期被整体指标掩盖的问题

2.4 研究目的

2.5 本报告的五点贡献

## 3. 前置模型与低分辨率模拟的误差量化

3.1 粗网格模拟与聚合真值

3.2 误差的口径与评价指标

3.3 低分辨率模拟误差随网格尺寸的变化

3.4 细网格口径与粗网格口径

3.5 哪些条件让误差变大

3.6 地形失真的来源与量级

3.7 跨分辨率相关性的衰减规律

3.8 逐瓦片的离散与解释份额

3.9 前置模型的结构、训练与测试结果

3.10 本章术语速查

## 4. 数据、模型与方法

4.1 研究区与数据来源

4.2 数据组织与切分原则

4.3 降雨驱动与洪水场的基本形态

4.4 模型结构

4.5 损失函数与评价指标

4.6 计算条件

## 5. 研究过程

5.1 阶段一 基线训练及其饱和

5.2 阶段二 深水误差的根因诊断

5.3 阶段三 从头训练的深水损失对比

5.4 阶段四 冻结模型的温和微调

5.5 阶段五 两处测量陷阱与修正

5.6 阶段六 延长训练与当前状态

## 6. 结果

- 6.1 逐瓦片的空间重构对比
- 6.2 点对点一致性与偏差结构
- 6.3 基线水平与超分辨率增益
- 6.4 深水分桶诊断
- 6.5 从头训练的权利衡代价
- 6.6 微调的配对结果
- 6.7 统计检验与效应量
- 6.8 测试集复核
- 6.9 高阶统计分析 with 阈值敏感性
- 6.10 偏差随训练的演化

## 7. 分析与讨论

## 8. 主要结论

## 9. 不足与展望

## 10. 附录 术语表与复现命令

## 摘要

城市洪水数值模拟给出的水深场，空间分辨率通常在十米量级。要把这样的粗网格水深恢复到两米量级，同时保留街道、河道与洼地中的深水结构，是防洪评估中一项现实而困难的任务。本报告围绕 Wellington 城区洪水数据集上的引导式超分辨率模型 HydroGeo-SRNO，报告一次针对深水欠估问题的完整诊断与修正过程。该模型在浅水区表现良好，整体  $CSI@0.05\text{ m}$  在验证集达到 0.539，但在水深超过 1 米的区域，最不利处的预测深度比真值低约 1.5 米以上，呈现出明显的系统性偏浅。

诊断发现两处相互叠加的损失函数缺陷。其一，深度项与对数残差项都在对数空间中计算，两米量级的绝对误差在水深五米以上的位置只值十分之一的对数代价，最优解自然会偏向压低深水。其二，极端项虽然在线性尺度上计算，但掩膜阈值取自每个瓦片自身的 95 分位数，在多数瓦片上这个阈值只有 0.19 米左右，于是这一项实际上在监督浅水。针对这两点，模型新增一个以米为单位的线性深水项。从头训练时把权重设为 0.5，深水指标有所改善，但该权重的加权损失占目标函数 59%，整体精度随之下降 0.043，触发预先设定的精度护栏而被否决。改为在已经训练好的基线上做温和微调，权重大幅降低到 0.10，深水指标在验证集与测试集上分别提升 7.7% 与 8.2%，而整体精度的变化在统计上无法与零区分。配对检验给出效应量 1.28，自助法置信区间不跨零。

本报告同时记录了两处测量方法上的陷阱及其修正，它们对结论的可靠性影响不低于模型改动本身。一处是对进程退出码的误判，曾把两个已经训练完成的实验臂标记为崩溃。另一处更关键，用于挑选最佳训练轮次的验证子集只有 60 个批次，深水样本过少，导致挑选结果实际上是在噪声中取最大值。改用全部 182 个验证瓦片逐轮次重新评分后，结论才变得可靠。这两处修正共同说明，在样本稀少的深水指标上，测量基线的选择与模型设计同等重要。

除逐瓦片的指标之外，报告还给出了空间分布、时序驱动、点对点一致性 with 高阶统计四类直接证据。空间上，深水像元只占总像元的百分之一二，却承载了全部水量的百分之四十点四，误差以成片的形式沿河道与地形陡变带分布， $\text{lag-1}$  空间自相关系数平均为 0.65，远非随机噪声。淹没超限曲线显示模型给出的深水面积稳定在真值的六成半，欠估同时发生在深度与范围两个方面。误差分布的偏度与超额峰度表明尾部远重于正态分布，这解释了为什么深水问题不能被逐点损失项有效约束。

前置模型是本方案的第一部分，对应本报告第二章，它要回答的是低分辨率水动力模拟本身有多准。以两米结果为参考，把粗网格上的模拟水深与按面积加权聚合到同一网格的两米真值相比。一百年一遇情景下，五米到三十米四档的均方根误差依次为 0.4012、0.3726、0.4603 与 0.5257 米。十米处存在一个低谷。把总误差按方差拆开，粗化造成的信息损失份额从五米档的百分之十点二升到三十米档的百分之二十三点六，说明网格越粗，单靠改进数值格式能拿回的精度越少。在此基础上训练一个只读粗网格输入的轻量卷积网络，用来预测并扣除粗网格的误差场。它在测试条带上把十米网格的均方根误差从 0.2944 米降到 0.1935 米，配对检验的效应量为负 0.95，改善覆盖了百分之八十五点五的瓦片。

**关键词** 城市洪水；超分辨率重建；深水欠估；损失加权；配对检验；测量基线

## 一 研究背景与目的

### 1.1 为什么需要把粗网格水深还原到细网格


城市内涝的数值模拟受限于计算量与地形数据的网格间距。这里说的二维水动力求解器，指的是一类直接求解浅水方程的数值程序，它在每个网格单元上同时推算水深与两个方向的流速分量，再用质量守恒与动量守恒把水流从一个单元推进到相邻单元。之所以强调二维，是因为城市内涝的水层通常只有几十厘米到数米，水深远小于水平范围，垂向运动可以忽略。这类程序在整座城市的尺度上运行时，网格边长往往只能取到十米甚至更粗，因为计算量随网格边长的降低而急剧增长。

在这样的网格上，一条宽度不足十米的街道、一段被建筑挤压的排水通道，都不能被完整表达。模拟结果给出的水深场因此是模糊的，最深处的位置与量值都会被抹平。空间分辨率这个词在这里指的是网格能分辨的最小尺度，网格边长十米意味着任何比十米更细的结构在结果中都看不出来。可是防洪决策真正关心的信息恰恰藏在这些细节里。哪条街会淹到一米以上，哪个路口会积水超过半米，这些判断决定了疏散路线与泵站调度。

直接加密网格重新求解当然是最彻底的办法，代价却是算力的急剧上升。对于需要反复试算多种降雨情景的工程任务，这条路通常走不通。于是产生了另一种思路。先在一套粗网格上完成完整的水动力求解，再用一个学习模型把粗网格结果映射到细网格。粗网格解保留了水流的整体结构与水量守恒，学习模型只需要补足被网格抹掉的细节。这就是本报告研究的引导式超分辨率。引导二字指的是模型除了粗网格水深之外，还会接收一套高分辨率的静态地理信息作为辅助条件，例如高程与到河道的距离，用来判断水应该往哪里流。

### 1.2 引导式超分辨率的含义

需要注意这里的问题设定与常见的降雨到淹水预测并不相同。后者的输入是降雨过程与地形，模型需要从零推算水深。本报告的任务中，粗网格水深本身就是输入，模型要做的是把它和高分辨率静态地理信息结合起来，重建细网格水深。静态信息包括高程、坡度、土地利用类型、到河道的距离、不透水面积比例等，它们在粗网格与细网格上都能获取，因此可以作为可靠的辅助条件。图 1 给出了这一任务的示意。



**图1 引导式超分辨率任务的输入与输出。**左侧方框是模型的输入，即十米网格上的最大淹没水深场。这里说的最大淹没水深，指的是一场降雨全过程中每个位置达到过的最大水深，它比某个瞬时水深更能代表风险，因为它记录的是最不利的时刻。中间是完成映射的神经网络。右侧是模型输出的两米网格水深，训练时与独立的高分辨率模拟结果逐像素比对。下方箭头表示静态地理信息同时输入模型，它不随降雨情景变化，但对判断水往哪里流至关重要。这类结构与图像超分辨率的差别在于，低分辨率输入是一次完整的水动力求解结果，与高分辨率真值之间没有降采样关系，两者之间也就不存在确定的解析关系，因此模型无法靠套用现成的插值公式得到答案，必须真正理解地形对水流的约束。

### 1.3 一个长期被整体指标掩盖的问题

项目前期训练出的基线模型在常用指标上表现良好。以整体精度衡量，它明显优于双线性插值与最近邻插值这两种传统做法。这两种做法都是纯粹的几何运算，双线性插值根据目标点到四个邻近网格点的距离做加权平均，最近邻插值直接取最近的一个网格点的值。它们只关心位置关系，完全不看地形，因此可以把它们当作不学习的参照。衡量整体精度的指标是临界成功指数（Critical Success Index，后文简称判定指标或CSI），它是洪水制图领域的通用指标，计算方式是正确判为积水的像元数除以正确判为积水的像元数、漏判的像元数与误判的像元数三者之和，取值在零到一之间，越大越好。这里说的像元指的是网格的最小单元，在两米网格上每个像元代表四平方米的地面。指标后面通常带一个阈值，例如在0.05米阈值下，只要水深超过五厘米就算积水。基线模型在这个阈值下达到0.539，而在1.00米阈值下只有0.169。后一个数字在绝对意义上不高，容易被解读成任务本身的难度，从而被搁置。

把误差按水深分层拆开之后，问题才显露出来。分层指的是不把所有像元混在一起统计，而是先按真实水深把像元分成若干区间，再在每个区间内单独计算误差。在水深一至一点五米的区间里，一万七千余个像元的平均误差达到0.85米，而且方向单一，全部偏向低估。这里说的偏差指的是预测值减去真值的平均，为负就代表预测偏浅。水深越大，偏浅的幅度越大。到三米以上的深水区，平均偏差达到负1.75米，也就是说模型系统性地把深水压成了浅水。系统性这个词强调的是方向一致。模型稳定地朝同一个方向出错，偶然的正负相消不会产生这种模式。淹水最严重的地方恰恰是模型错得最厉害的地方，这个模式与整体指标给出的印象完全相反。

### 1.4 研究目的

本报告的目标集中在一个更具体的问题上，就是能否通过修改损失函数，在不牺牲整体精度的前提下，纠正深水区的系统性偏浅。这里说的损失函数是训练时用来衡量模型错得有多严重的那个数值，训练过程就是不断调整网络参数去把这个数值压到最小。模型学成什么样，取决于损失函数把什么定义为错、把不同程度的错看得多重。如果损失函数对深水区的误差给不出足够的惩罚，模型就没有理由去把深水做准。围绕这个目标，工作分四步展开。第一步定位深水误差的成因，确认它来自损失函数的哪一部分。第二步设计并检验一个新的深水损失项，先在从头训练的条件下观察它与整体精度的取舍关系。第三步改变策略，把深水损失项加在已经训练好的模型上做温和微调，检验能否用更小的精度代价换取深水改善。第四步对结论做统计与测量层面的复核，确认所观察到的改善确实来自损失函数的改动，可以排除测量偏差与随机波动。

图2用一条时间轴概括了整个研究的推进顺序，后文将按这个顺序逐段展开。

## 1.5 本报告的五点贡献

把上面的工作浓缩成可以带走的结论，本报告在五个方面提供了新的东西。


第一，给出了深水欠估的一个可测量的成因，而不是停留在现象描述。以往遇到模型在深水区偏浅，常见的处理是直接加大深水样本的权重，或者干脆扩充深水数据。本报告的做法是先把损失函数各项在真实数据上的数值量出来，找到两处叠加的缺陷，一处是对数变换压缩了深水的绝对梯度，另一处是极端项的掩膜阈值随瓦片浮动，在多数瓦片上落在了浅水。两处缺陷都有明确的实测数值支撑，因此成因是可验证的，不是推测的。

第二，提出了用占比而不是用权重数字来控制深水项强度的做法。同一个权重数字加在不同模型上，由于深水项本身的原始数值不同，实际强度可以相差三倍。把权重换成它占总目标的百分比之后，跨模型、跨训练阶段的比较才有意义。这个换算关系在本报告中被明确给出，并且直接改变了实验设计，把原计划的权重从 0.25 调到了 0.10。

第三，把测量基线本身当作一个需要验证的环节来处理。用于挑选最佳轮次的小样本验证子集只有六十个批次，在深水指标如此稀少的情形下，从中取最大值等价于在噪声里挑最高的那个数。本报告用不含深水项的对照臂证明了这一点，因为该臂按设计不可能从深水项获益，它的指标波动就完全等于噪声。改用全部一百八十二个验证瓦片重新评分之后，结论才站得住。这一条对任何小样本指标都适用，不限于洪水问题。

第四，用空间、分布与高阶统计三类独立证据刻画了误差的结构。逐瓦片的空间对比说明误差沿河道与地形陡变带成片分布，空间自相关平均达到 0.65。点对点密度图与淹没超限曲线说明欠估同时发生在深度与范围两个方向上，深水面积稳定在真值的六成半。误差分布的偏度与超额峰度说明尾部远重于正态分布。三类证据都指向同一个判断，误差是一个有空间范围、有厚尾的场，并不表现为互相独立的逐点扰动，这解释了为什么单纯的逐点损失项收效有限。

第五，把超分辨率模型前面的误差来源单独量化，并落成一个可直接调用的校正器。本报告把粗网格模拟值相对聚合两米真值的偏差、以及粗化本身丢掉的信息分开报告，给出误差随网格边长的变化、地形失真随边长的加剧、跨分辨率相关性的衰减方式，并用分组 Shapley 值把逐瓦片匹配度的方差分摊到五组地理条件上。在此基础上训练的前置模型只读取粗网格输入，参数量约两万三千个，在测试条带上把十米网格的均方根误差降低约三分之一。它的输出仍是一套粗网格水深场，可以直接接在已有的超分辨率模型之前，后者未被改动。



**图 2 研究推进的五段结构。** 五个圆点代表依次进行的工作阶段，横轴上的位置只表示先后顺序，不代表真实的时间间隔。第一阶段训练基线模型并观察其性能变化。第二阶段把误差按水深分层，定位深水欠估的成因。第三阶段尝试从头训练并直接加大深水权重，结果因为整体精度的代价过大而被否决，所以用红色标出。第四阶段改用微调策略，深水获得改善而整体精度基本不动，因此用绿色标出。第五阶段延长训练，检验改善能否随训练区间的延长而继续扩大，结论是否定的，因此用灰色标出。需要说明的是，正文的第四章按顺序编到第六节，其中第五节记录的是两处测量方法的修正，它改变的是评测方式而非模型本身，因此在这条时间轴上没有单独设点，而是并入第四阶段与第五阶段之间。

## 二 前置模型与低分辨率模拟的误差量化

本章处理的是整条预报链的输入端。低分辨率水动力求解是超分辨率重构的输入，它的误差不会在后续环节里自动消失，只会被原样传递下去。因此在训练重构模型之前，需要先把这部分误差量清楚。本章要回答三个问题。低分辨率模拟相对两米参考结果

相差多少，这个差值里有多少来自数值求解、有多少来自网格粗化本身，以及哪些地理条件会让误差明显变大。把这三个问题答清楚，才有可能训练一个小模型去预测并扣除这部分误差，这个小模型就是本章所说的前置模型。它的输出仍然是一套粗网格水深场，可以直接接在后面已经完成的超分辨率模型前面。需要先交代一句，本章的全部计算只读取已有的低分辨率模拟结果与两米参考结果，不训练、不修改、也不重新评估任何超分辨率模型。

## 2.1 粗网格模拟与聚合真值

本章从头到尾只比较两份资料。它们来自同一片地面，用的是同一个降雨情景，最后落在同一套粗网格方块上。先把这两份资料分清楚，后面每一节的读数才不会串。

第一份是粗网格模拟值。水动力程序直接在这套粗网格上求解浅水方程，网格边长取五米、十米、二十米与三十米中的一档，每个方块给出一个水深值。这份资料是超分辨率模型真正会拿到的输入，它的误差会原样传给下游，所以最需要量准。

第二份是聚合真值，它由两米精细结果压缩得到。一个十米方块正好覆盖二十五个两米小格，把这二十五个小格的水深按面积加权平均，就得到这一块的代表值。这个压缩动作叫聚合，它不求解任何方程，只做平均。放大的倍数随网格边长变化，五米档是六点二五，十米档是二十五，二十米档是一百，三十米档是二百二十五。聚合之后，两份资料落在同一套方块上，位置一一对应。

后文为了行文简洁，把粗网格模拟值简称为模拟值，把聚合后的二米真值简称为聚合真值。图表的表头与坐标轴标签受篇幅限制，也沿用这两个短名。表6里的模拟均流速指粗网格模拟值给出的平均流速，聚合均流速指聚合后的二米真值给出的平均流速。读到任何一个短名，都可以回到本节的两份资料来对号。

两者的区别用一个真实方块讲一遍。取十米网格上位于第1620行、第107列的那一块，它覆盖两米格网的第8100至8104行与第535至539列。在一百年一遇情景下，这一块内部二十五个两米小格的水深最低是0.003米，最高是2.873米，按面积加权平均得到0.860米，这就是聚合真值。同一个位置上，粗网格水动力程序自己算出的是0.750米。两者相差0.110米，方向是粗网格在这一块上算少了。挑这一块的规则是，在聚合水深介于0.8与1.2米之间的方块里取差值最接近全域中位数的那一块。两份值都超过五厘米的方块共有十二万五千余块，它们在这个情景下的差值中位数正好是0.110米，所以这个例子既不极端也不特殊。


把这一块的二十五个值排开看，就能看清聚合丢掉了什么。有几格几乎是干的，水深不到一厘米，另外几格落在水道里，接近三米。二十五格压成一个0.860米的代表值之后，方块内部的高低起伏全部消失，只剩下一个平均水位。这部分丢失来自粗化本身，与数值格式的好坏无关，改进求解器也找不回来。它和粗网格算得准不准是两件独立的事。

为什么两份都要留。粗网格模拟值不可替代，超分辨率模型只接收粗网格输入，它面对的误差就是这一份值相对真值的偏离。聚合值的用处是提供一个能对齐的参照。粗网格模拟值与两米真值不在同一套网格上，一个是十米方块，一个是两米小格，无法直接相减。把两米真值聚合到同一套方块上，两份值才有了共同的落脚点，相减才有意义。

由此得到全章反复使用的一条恒等式，也就是误差的三笔账。第一笔叫模拟项，等于粗网格模拟值减去聚合真值，它衡量同一个方块上粗网格自己算出的水深与方块平均水深差了多少。第二笔叫聚合项，等于聚合真值减去两米真值，它衡量方块平均值与方块内部各两米小格之间的偏离。第三笔是总误差，等于粗网格模拟值减去两米真值。把前两笔相加，中间的聚合真值一正一负相互抵消，正好等于第三笔。这个抵消是恒等式成立的原因，不是巧合。

模拟项里其实混着两样东西，需要交代一句。粗网格用方块形状去近似真实水面，会带来形状上的偏差，这叫表示误差。粗网格上的离散格式与两米网格不同，又会带来数值上的偏差，这叫数值误差。现有数据无法把这两样分开，本章因此合并报告，并在表注里写明这一点。

三笔账的量级可以在一百年一遇、三十米网格上读出来。以两米格网为共同度量，总误差的均方根是0.6018米，模拟项0.5261米，聚合项0.2922米。两个分项之和大于总数，因为它们出自同一个差值的两段，直接相加会把同一份偏离算两次。正确的做法是先平方再相加，0.5261与0.2922按平方相加再开方得到0.6018米，与总误差吻合。换成份额的说法，总平方误差里约76.4%来自模拟项，23.6%来自聚合项，两项的交叉部分不超过万分之六。交叉项指两个误差项在同一像元上相乘再取平均的那一部分，它接近零，说明两类误差在同一像元上几乎没有同向或反向的系统关系。



**图 3 粗网格模拟与聚合真值这两份资料的关系，以及一块真实十米方块。** 子图 (a) 是一张示意。上排从两米精细网格出发，经过面积加权平均这一个动作，落到一个粗网格方块上，得到聚合真值。下排从粗网格水动力程序出发，它在同一套方块上直接求解浅水方程，得到粗网格模拟值。两条路径都不经过对方，它们的共同点是最右端那一套方块完全相同，因此同一个位置上的两份值可以直接相减。这张子图要看的只有一件事，聚合不求解方程，它只是把细网格的结果压到粗方块上。子图 (b) 是一块真实十米方块内部的二十五个两米水深，颜色越深表示水越深，格内数字是水深值，单位是米，两块轴上的数字是两米网格的编号。可以读出这个方块内部极度不均匀，有一片几乎干的角落，也有接近三米的深水，最高与最低相差 2.87 米。这正是聚合要抹掉的信息。子图 (c) 把同一方块上的三个数字画在一条水深轴上。蓝点是方块内二十五个两米小格的水深，按数值大小排好之后从上到下摆放。绿色竖线是聚合真值 0.860 米，紫色虚线是粗网格模拟值 0.750 米，红色阴影是两者之间的差。可以读出蓝点散布在零到 2.87 米之间，而两个代表值都落在 0.8 米附近且只差 0.110 米，说明压缩之后细节不见了，留下的是一个平滑的平均水位。这张图的物理含义是粗化的代价，它能得出的结论是聚合损失与数值求解的准确度无关。

把三个子图连起来看，可以建立本章最基本的图像。同一片地面上有两份资料，一份是算出来的，一份是压出来的，它们唯一可比的地方是那套方块。这一节的数字取自单元格示例文件与十米网格误差图，都可以在 `outputs/premodel/cell_example.json` 与 `outputs/premodel/map_100a_10m.npz` 中逐项复算。




图4 误差的三笔账与两笔账的份额。子图(a)是一张加法示意,用三十米网格、一百年一遇情景的真实数值作例子。上两个方框分别写出第一笔与第二笔,第一个方框是粗网格模拟值减去聚合真值,对应数值求解与方块形状造成的差,方框内注明这一项在两米格网上的均方根是0.5261米。第二个方框是聚合真值减去两米真值,对应粗化本身造成的差,同一条件下的数值是0.2922米。右侧方框指出两式相加时中间的聚合真值一正一负相互抵消,于是得到第三个方框,也就是粗网格模拟值减去两米真值,数值是0.6018米。最下方一条黄色方框写的是读法提醒,两个分项出自同一个差值的两段,不能直接相加,只有先平方再相加才能还原总数,按这个做法算得0.6018米,与总误差一致。子图(b)把两笔账的份额画成堆叠柱状图,横轴是四档网格边长,纵轴是占总平方误差的比例,百分数。每一档有左右两根柱子,左侧是二十年一遇情景,右侧是一百年一遇情景,紫色段是模拟项,绿色段是聚合项,绿色段上方的数字是聚合项的具体份额。可以读出三件事。模拟项在每一档上都占大头,最少也有约四分之三。聚合项的份额随网格变粗而上升,从五米的约百分之十升到三十米的约百分之二十四。交叉项在四档网格上都不超过万分之六,因此图中未单独画出。这张图的物理含义是网格越粗,粗化造成的信息损失在总误差里的比重越大,它能得出的结论是继续放粗网格时,单靠改进数值格式已经收效不大。

这两张图构成本章的地基。图3说明两份值各自是什么,图4说明三笔账怎么相加。后面每一节都在这个框架里展开,读到具体数字时回到这两张图,位置关系就不会迷路。

## 2.2 误差的口径与评价指标

研究区与数据集的组织方式在3.1节与3.2节有完整说明,这里只重述与本章直接相关的部分。两米参考结果写在11520行、6480列的格网上,共74649600个单元。真正被水动力模型求解过的只是其中一部分,把水深为缺测值的单元排除之后还剩30931463个,占整个格网的百分之四十一。后文所说的全域,指的就是这三千余万个单元。可用的粗网格有边长五米、十米、二十米与三十米四档,相对两米的分辨率比依次为二点五、五、十与十五。降雨情景取二十年一遇与一百年一遇两个,简称为20a与100a,其中a是年这个英文词的首字母,二十年一遇表示年平均发生概率为二十分之一。每个情景输出七个整点时刻的水深与单宽流量,本章的比较统一使用最大淹没水深,也就是整场降雨过程中每个单元达到过的最大水深。

总误差等于模拟项与聚合项相加,两者在同一个两米单元上还可能互相影响,因此总误差的方差要写成三项,也就是模拟项方差、聚合项方差与两倍的协方差。协方差那一项在图4的子图(b)中就是交叉项。本报告逐单元验证了这个恒等式,残差落在十的负十一次方量级,可以认为分解是精确的。这一步保证了后面报告的两类误差份额不会互相污染。

指标按用途分成三组。第一组是数值类,包括平均绝对误差(Mean Absolute Error,简写MAE)、均方根误差(Root Mean Square Error,简写RMSE)、平均偏差与体积相对误差。前两者的单位都是米,MAE对全部单元一视同仁,RMSE因为先平方再开方,对大误差更敏感。平均偏差是预测值减真值的平均,正号表示粗网格给多了水。体积相对误差先把全部单元的水量加起来再相除,衡量的是总量是否守恒,它与逐点误差可以背离。第二组是判定类,即临界成功指数(Critical Success Index,简写CSI),在1.3节已经介绍过,这里在五厘米、三十厘米与一米三个阈值下分别计算。掩膜是一张与水深层同样大小的真假标记图,水深超过阈值的单元记为真,其余记为假。在二值掩膜下交并比与临界成功指数恒等,因此本章不再单列交并比,只额外给出F1分数,它是一个把精确率与召回率调和平均的指标,数值上略高于CSI。第三组是分布相似性,用到三个量。皮尔逊相关系数(Pearson correlation coefficient)度量两组数值的线性同步程度。斯皮尔曼等级相关系数(Spearman rank correlation coefficient)先排序再求相

关，对非线性但单调的关系更稳健。结构相似度（Structural Similarity Index，简写 SSIM）同时考虑亮度、对比度与结构，取值越接近一表示两幅图的观感越接近。两个相关系数只在湿区单元上统计，湿区取水深超过五厘米，因为在干区上相关系数没有意义，结构相似度则在粗网格全域上计算。

关于计算规模，需要说明抽样方式。本章没有对全域做任何抽样，全部三千万个单元都参与了统计。为了在四吉字节显存与普通内存的机器上完成计算，两米场以单精度按行分块读入，每块处理完毕即释放，峰值占用控制在一吉字节以内。分块只影响内存，不影响任何统计量的取值。逐瓦片分析覆盖了全部 487 块可用瓦片，每块边长 480 米，两个情景各算一次，因此参与回归的记录共 974 条。




图 5 前置模型在整个预报链中的位置与两类误差的量级。子图 (a) 是一条流程示意。第一个方框是粗网格水力模拟，它给出边长五米到三十米的粗网格模拟水深场。第二个方框是本章新增的前置模型，它读取粗网格水深场与同一档粗网格上的静态地理特征，输出一个校正后的粗网格场。第三个方框是已经完成的超分辨率模型 HydroGeo-SRNO，本章不对它做任何改动。第四个方框是最终交付的两米水深场。方框之间的箭头表示数据流向，校正后的场同时向上反馈一条虚线，标注的是两类误差的来源。虚线来自粗化本身的信息损失，也就是单元内地形起伏与水深变化在取平均时被抹平的那一部分。子图 (b) 是柱状图，横轴是四档网格边长，纵轴是粗网格模拟值相对聚合真值的均方根误差，单位是米，两种颜色对应二十年一遇与一百年一遇两个情景。柱子越高表示粗网格离聚合真值越远。可以读出两个特征，十米处的柱子最低，二十米与三十米处的柱子明显抬升，且一百年一遇情景整体高于二十年一遇。子图 (c) 把总误差拆成模拟项与聚合项，横轴同样是网格边长，纵轴是在两米格网上量得的均方根误差，单位是米。圆点连线是总误差，方点是模拟项，三角点是聚合项，实线对应一百年一遇，虚线对应二十年一遇。可以读出模拟项始终高于聚合项，且两者都随网格变大而上升，但聚合项上升的速度更快，说明网格越粗，信息损失在总误差里的比重越大。

这张图给出本章的基本图像。误差确实随网格尺寸增长，但增长不是均匀的，十米处出现了一个低谷。同时可以看到，粗化造成的信息损失虽然数值上小于数值求解本身的偏差，但它的增长速度更快，这意味着继续放粗网格时，单靠改进数值格式已经收效不大。

**表 1 粗网格模拟值与聚合后的二米真值的误差。**粗网格模拟值指水动力程序直接在这套粗网格上求解浅水方程得到的水深场，聚合后的二米真值指把两米精细结果按面积加权平均到同一套网格的结果，两者的区别见 2.1 节。所有指标都在各自的粗网格上计算，因此这一张表度量的是表示误差与数值误差，不含二米真值自身被粗化丢掉的信息。临界成功指数在三个阈值下给出。相关与结构相似度只在湿区像元上统计，湿区取水深超过五厘米。体积相对误差是全部单元水量之和的相对偏差，正值表示粗网格给多了水。

| 重现期  | 边长(米) | 分辨率比 | MAE(米) | RMSE(米) | 偏差(米)   | 体积相对误差(%) | CSI@0.05 | CSI@0.30 | CSI@1.00 | Pearson | Spearman | SSIM  |
|------|-------|------|--------|---------|---------|-----------|----------|----------|----------|---------|----------|-------|
| 20a  | 5     | 2.5  | 0.0787 | 0.3391  | +0.0072 | +10.2     | 0.325    | 0.238    | 0.212    | 0.603   | 0.230    | 0.960 |
| 20a  | 10    | 5.0  | 0.0702 | 0.3160  | +0.0046 | +6.5      | 0.363    | 0.268    | 0.239    | 0.655   | 0.282    | 0.956 |
| 20a  | 20    | 10.0 | 0.0919 | 0.3950  | +0.0101 | +14.4     | 0.279    | 0.171    | 0.108    | 0.298   | 0.226    | 0.925 |
| 20a  | 30    | 15.0 | 0.0924 | 0.4392  | +0.0113 | +16.1     | 0.282    | 0.202    | 0.090    | 0.195   | 0.286    | 0.897 |
| 100a | 5     | 2.5  | 0.0989 | 0.4012  | +0.0115 | +12.6     | 0.350    | 0.268    | 0.231    | 0.641   | 0.244    | 0.956 |
| 100a | 10    | 5.0  | 0.0881 | 0.3726  | +0.0080 | +8.7      | 0.392    | 0.299    | 0.256    | 0.690   | 0.288    | 0.951 |
| 100a | 20    | 10.0 | 0.1118 | 0.4603  | +0.0081 | +8.9      | 0.305    | 0.200    | 0.130    | 0.373   | 0.228    | 0.923 |
| 100a | 30    | 15.0 | 0.1144 | 0.5257  | +0.0101 | +11.1     | 0.320    | 0.223    | 0.117    | 0.223   | 0.300    | 0.895 |

表 1 是本章的主表，它把每一档粗网格在两套指标下的表现放在一起。最直接的读法 is 看 均方根误差 一列。在二十年一遇情景下，五米、十米、二十米与三十米四档的数值依次为 0.3391、0.3160、0.3950 与 0.4392 米。在一百年一遇情景下依次为 0.4012、0.3726、0.4603 与 0.5257 米。两条序列都在十米处取得最小值，然后单调抬升。从十米到三十米，误差分别增加了 百分之三十九与百分之四十一。平均绝对误差一列的走势与之类似，量级约为均方根误差的四分之一，因为它对少数极端单元不敏感。

五米比十米更差这一点需要专门说明。它看上去违反直觉，因为五米网格更细，按理应当更接近 真值。可能的原因有两条。其一，五米与十米是两个独立运行的数值解，网格改变会同时改变渠道 过流断面与干湿判定的结果，两者与两米解的距离不一定随网格加密而单调缩小。其二，五米网格 对渠系的分辨更细，细窄水道里的水深更容易被单独算出来，而聚合真值把这些水道平均掉了，于是逐点差别反而更大。这两条解释目前都无法从现有数据中分离，需要一次专门的对照实验，此处标注为待补充。可以确定的是，从十米到三十米这一段是单调的，本章后面的规律都建立在这一段上。

判定类指标给出了另一幅图景。在五厘米阈值下，二十年一遇情景的四档数值为 0.3248、0.3626、0.2789 与 0.2818，同样是十米最高。在一米阈值下，数值从五米的 0.2123 降到三十米的 0.0898，降幅接近百分之五十八。这个差别说明粗网格对深水区的判定能力衰减得比浅水区快得多，因为深水区面积小、边界细，一格之内的平均很容易把它稀释掉。体积相对误差一列在十米处最小，二十年一遇情景下为百分之六点五，到三十米升到百分之十六点一，方向全部为正，说明粗网格总体上把水量算多了。

**表 2 两类误差在二米格网上的分解。**把粗网格模拟值与聚合后的二米真值都按最近邻升采样回二米格网，总误差等于两者之差。总误差可以写成两项相加。模拟项是升采样后的粗网格模拟值减去升采样后的聚合真值。聚合项是升采样后的聚合真值减去真实二米水深。后三列给出三项平方误差在总平方误差中的占比，三项相加为一。交叉项为正值表示两类误差在同一像元上同向叠加，为负值表示部分抵消。最后两列是总误差与聚合项单独造成的淹没匹配度，聚合项那一列可以理解为单靠粗网格的方块状表示能达到的匹配度上限。


| 重现期  | 边长<br>(米) | 总误差<br>RMSE(米) | 模拟项<br>RMSE(米) | 聚合项<br>RMSE(米) | 模拟项<br>方差占比(%) | 聚合项<br>方差占比(%) | 交叉项<br>占比(%) | 总误差<br>CSI@0.05 | 聚合项<br>CSI@0.05 |
|------|-----------|----------------|----------------|----------------|----------------|----------------|--------------|-----------------|-----------------|
| 20a  | 5         | 0.3592         | 0.3391         | 0.1181         | 89.1           | 10.8           | +0.1         | 0.321           | 0.613           |
| 20a  | 10        | 0.3540         | 0.3160         | 0.1594         | 79.7           | 20.3           | -0.0         | 0.333           | 0.477           |
| 20a  | 20        | 0.4496         | 0.3954         | 0.2140         | 77.4           | 22.6           | +0.0         | 0.224           | 0.364           |
| 20a  | 30        | 0.5046         | 0.4395         | 0.2479         | 75.9           | 24.1           | -0.0         | 0.211           | 0.317           |
| 100a | 5         | 0.4236         | 0.4012         | 0.1355         | 89.7           | 10.2           | +0.1         | 0.348           | 0.639           |
| 100a | 10        | 0.4157         | 0.3727         | 0.1841         | 80.4           | 19.6           | -0.0         | 0.367           | 0.503           |
| 100a | 20        | 0.5241         | 0.4608         | 0.2497         | 77.3           | 22.7           | +0.0         | 0.250           | 0.385           |
| 100a | 30        | 0.6018         | 0.5261         | 0.2922         | 76.4           | 23.6           | -0.0         | 0.237           | 0.337           |

表 2 把误差拆开，这是本章最需要仔细阅读的一张表。前三列给出总误差、模拟项与聚合项在 两米格网上的均方根误差。以一百年一遇情景为例，三十米网格的总误差是 0.6018 米， 其中模拟项 0.5261 米，聚合项 0.2922 米。两者之和大于总数，原因是它们取自同一个差值的两个部分， 需要按方差相加，直接相加会重复计入。后三列给出的正是方差份额， 分别为百分之七十六点四、百分之二十三点六与约等于零的交叉项。交叉项在所有档位上都不超过 万分之六，说明两类误差在同一像元上几乎没有系统性的同向或反向关系，可以放心地分开讨论。

份额的走势值得单独看。二十年一遇情景下，聚合项的方差占比从五米的百分之十点八升到三十米的 百分之二十四点一。一百年一遇情景下从百分之十点二升到百分之二十三点六。也就是说， 在五米网格上，粗网格误差里只有约十分之一来自粗化，其余十分之九来自数值求解本身。 到三十米网格上，粗化的份额上升到约四分之一。最后两列给出一个更容易记住的量。把聚合真值本身当作预测，它在五厘米阈值下能拿到的 CSI 是 0.6385（一百年一遇五米）到 0.3373（一百年一遇三十米）。这个数字说明，即使把低分辨率模拟做得完全没有误差， 单靠方块状的粗网格表示，淹没范围最多也只能匹配到这个程度。剩下的差距必须由超分辨率 环节去补。

2.3 低分辨率模拟误差随网格尺寸的变化

这一节把上一节的全局数字展开，按水深与坡度分层看误差的结构，并给出全域的空间分布。 分层的意义在于，全局平均会把深水区的大误差与浅水区的小误差混在一起，掩盖真正的问题所在。 分层的方式是把真值水深划成八个区间，把单元平均坡度划成五个区间，在每个区间内单独统计。



**图 6 误差随网格边长的变化。**四个子图的横轴都是网格边长，取五、十、二十、三十米四个值并按对数刻度摆放，这样低分辨率一侧不至于被挤在一起。子图 (a) 的纵轴是误差，单位是米，圆点实线是平均绝对误差，方点虚线是均方根误差，蓝色对应二十年一遇，红色对应一百年一遇。可以读出均方根误差大约是平均绝对误差的四倍，说明误差分布是厚尾的，少数单元贡献了大部分平方误差。两条曲线都在十米处最低，向两侧抬升。子图 (b) 的纵轴是全域平均偏差，单位是米，横线标出零的位置。两个情景的偏差都在零以上但数值极小，约在 0.005 到 0.011 米之间，说明粗网格在总量上略微偏多，但整体尺度上的偏置很轻。偏差随网格边长缓慢抬升，三十米处达到最大。子图 (c) 给出淹没范围匹配度，纵轴是临界成功指数，取值在零到一之间。圆点、方点、三角分别对应五厘米、三十厘米与一米三个阈值，颜色与线型规则同前。可以读出三件事。同一阈值下，指数在十米处最高。阈值越高，指数越低，一米的曲线明显低于五厘米的曲线。不同网格之间的差距在低阈值下较小，在高阈值下被放大。子图 (d) 的纵轴是相对偏差，单位是百分数，横线同样标出零。实心圆点两条曲线是体积相对误差，虚线三条曲线是一百年一遇情景下淹没面积相对真值的偏差，分别对应三个阈值。可以读出体积误差全为正，落在百分之八到百分之十七之间。淹没面积的偏差则随阈值改变方向。五厘米阈值下粗网格算出的面积比真值小，一米阈值下反而比真值大。后一点很容易被忽略。粗网格把深水范围画宽了，同时把浅水范围画窄了，两者的方向相反。

这张图回答的是误差怎么随网格变粗而增长。结论可以概括成三段。十米是一个低谷，二十米与三十米稳定抬升，深水判定的衰减比浅水判定快。面积偏差出现方向翻转这一点，对后面的超分辨率任务有直接含义。粗网格给出的深水区偏大，因此重构模型在深水位置上的主要任务是把偏大的范围收回来，而不是把偏小的范围补出来。





图7 按真值水深分层的误差结构。四个子图的横轴都是聚合真值水深区间，从左到右依次为0至0.05、0.05至0.3、0.3至0.5、0.5至1.0、1.0至1.5、1.5至2.0、2.0至3.0与3.0米以上，单位是米，标签旋转以便阅读。子图(a)与(b)的纵轴是平均偏差，单位是米，横线标出零，颜色对应四档网格，分别是深蓝五米、中蓝十米、橙色二十米与红色三十米，子图(a)是二十年一遇情景，子图(b)是一百年一遇情景。可以读出同一个模式。在最浅的一个区间里偏差为正，粗网格略微高估。从0.3米以上的区间开始偏差转负，此后随水深增加越来越负。在3.0米以上区间，五米网格的偏差约为负2.7米，三十米网格约为负4.6米。四条曲线在浅水区几乎重合，在深水区明显分开，说明网格尺寸的影响主要集中在深水。子图(c)的纵轴换成平均绝对误差，单位是米，只画一百年一遇情景。走势与偏差一致，最浅区间在0.04米以下，最粗的两档在深水区间超过4米。子图(d)的纵轴是单元数，用对数刻度，横轴仍为水深区间，对比两个情景。可以读出样本高度集中在浅水，十米网格的最浅区间接近一百万个单元，同一网格的最深区间不足四千个。这一点决定了深水指标的统计不确定性远大于浅水指标，后文做配对检验时必须把这件事考虑进去。

这张图说明粗网格的深水欠估是一个稳定的结构性特征，而不是个别单元的偶然现象。它的方向单一，幅度随水深增加而扩大，并且在四档网格上都存在。同时可以看出，深水样本极少，最深区间只有几百个单元，因此关于深水的任何结论都需要报告样本量。


坡度分层的结果与直觉相反，需要仔细读。坡度仍按五个区间切分，但要读两条不同的数列。第一条把全部有效单元都算进去，第二条只算有水单元。两条数列的方向并不一致。



**图 8** 按单元平均坡度分层的误差结构。四个子图的横轴都是单元平均坡度区间，依次为 0 至 0.05、0.05 至 0.15、0.15 至 0.3、0.3 至 0.6、0.6 至 9.0，单位为无量纲，坡度按垂直高差除以水平距离定义，因此 0.3 表示水平前进一米上升三十厘米。子图 (a) 是全部有效单元的平均绝对误差，单位是米，颜色对应四档网格，实线是一百年一遇情景，虚线是二十年一遇情景。可以读出一个下降的走势。十米网格、一百年一遇情景下五个区间的数值依次是 0.1515、0.1406、0.1036、0.0575 与 0.0260 米，从最平坦到最陡一路变小，最陡区间只有最平坦区间的六分之一。子图 (b) 把统计范围收窄到有水单元，纵轴仍是平均绝对误差，单位是米，颜色与线型规则同前。可以读出走势变了样。十米网格、一百年一遇情景下五个区间的数值变成 0.268、0.334、0.319、0.304 与 0.396 米，最陡区间比最平坦区间高约五成，中间三段几乎持平，没有单调的走向。子图 (c) 解释了两条数列为什么不同，横轴同为坡度区间，蓝色柱子是各区间聚合真值的平均水深，用左轴读数，单位是米，红色方点线是该区间有水单元的占比，用右轴读数，单位是百分数。可以读出最平坦区间有五成二的单元有水，平均水深 0.198 米，最陡区间只有百分之四有水，平均水深 0.033 米。干湿比例随坡度急剧下降，这正是子图 (a) 那条下降曲线的来源。子图 (d) 是全部有效单元的平均偏差，单位是米，横线标出零，规则同子图 (a)。可以读出偏差在五个区间上都很小，最平坦区间为负 0.049 米，其余四个区间落在正负 0.03 米以内，坡度分层没有给出像水深分层那样清晰的方向。这张图的物理含义是坡度本身不足以决定误差的大小，它能得出的结论是读分层统计时必须先看清每个区间里有多少水。

坡度分层的诚实结论是，坡度与单元一级的误差没有稳定的单调关系。全部单元读数里看到的下降，主要来自干湿比例。陡坡上大多数方块是干的，两份值都接近零，把干单元混进来会把平均误差拉低，这是算术上的必然，不是地形效应。只看有水单元，坡度的影响变弱，而且在不同网格上方向还会翻转。三十米网格上最陡区间的平均绝对误差是 0.157 米，反而成了五个区间里最小的一个。因此本章不把坡度当作误差大小的稳定预测因子。

由此可以排除一个本来很自然的方案。若按地形陡缓分成两类分别校正，在单元一级上找不到可以依据的方向，同一档网格内部的方向都不稳定。误差在空间上确实成片分布，但把它拉开的条件不在坡度这一项上，2.5 节会给出几个更稳定的因素。



**图9** 一百年一遇情景下全域水深与粗网格误差的空间分布。图分上下两排, 每排四幅, 自左向右依次是五米、十米、二十米与三十米网格。上排是聚合后的二米真值的水深场, 颜色由浅蓝到深蓝表示水深由小到大, 色标范围固定在零到三米, 超出三米的部分按最深色显示, 每一幅配一条独立色标, 单位是米。纵横坐标是格网行列号, 北在上方, 为了便于印刷未标注刻度数值。可以读出淹水集中在中部与南部的河谷与低洼街区, 随网格变粗, 同一片水域的颜色变得更均匀, 细密的支流消失。下排是图4所说第三笔账的误差场, 也就是粗网格模拟值减聚合真值, 颜色用发散色标, 红表示粗网格算深了, 蓝表示算浅了, 色标范围对称固定在负二米到正二米, 单位是米。可以读出误差不是逐点随机的, 它沿河道与地形陡变带成片出现。五米网格上的红色斑块最碎, 随网格变粗逐渐连成大片, 三十米网格上的蓝色条带几乎完整覆盖主要河道。把上下两排对照, 可以确认蓝色条带的位置与上排的深蓝色河道位置重合, 说明欠估发生在水最深的地方。

这张图给出误差的空间性格。它带有明显的组织结构, 方向明确, 位置可以预期, 与白噪声的表现完全不同。这一点对前置模型是决定性的。如果误差是随机噪声, 任何模型都无法预测它, 也就没有必要做前置校正。既然它沿河道成片分布, 而河道位置在粗网格上是已知的, 模型就有可以利用的信息。

把观测到的规律外推到三十米以上需要格外小心。本数据集最粗的一档网格只有三十米, 因此四十米及以上的数值都无法直接测量。作为参考, 把十米、二十米与三十米三个点按幂函数拟合, 二十年一遇情景下均方根误差约按边长的0.30次幂增长, 一百年一遇情景下约为0.31次幂, 三个点上的决定系数都在0.996以上。把这条曲线延续到二百米, 二十与一百年一遇两个情景给出的均方根误差分别约为0.78米与0.95米, 平均绝对误差分别约为0.16米与0.19米。这是一条纯外推, 没有实测数据支持, 研究方案中提到的三十米到二百米区间在本数据中没有覆盖, 此处标注为待补充。同样需要标注的是, 方案里把误差归因于河道与管网两个因素。本数据只包含地表河道信息, 排水管网与检查井的数据节点不存在。管网效应因此无法单独量化, 只有河道邻近度可以作为代理变量, 关于这一部分的讨论只能停留在代理层面。

## 2.4 细网格口径与粗网格口径

两米真值与五米以上的粗网格模拟值不在同一套格网上，比较之前必须先决定把谁搬到谁的格网上。把细的搬到粗的，就是把粗网格模拟值与同一方块的聚合后的二米真值相比，本章称之为粗网格口径。反过来把粗的搬到细的，就是把每个粗方块的模拟值按最近邻铺到它覆盖的每一个两米单元上，再与两米真值逐格相减，本章称之为细网格口径。两个口径用的是同一批数据，差别只在比较发生在哪一套格网上。这一节先把两个口径的数字摆出来，再说明本章为什么把粗网格口径当作主口径。

表 3 是本节的对照表。它逐档列出三个量，细网格口径的均方误差、粗网格口径的均方误差、以及方块内部的方差。最后一栏给出两个口径的均方根误差，单位换成米，便于与其他表格对照。

**表 3 细网格口径与粗网格口径的对照，以及把两者连起来的恒等式。**细网格口径把每个两米单元与最近邻升采样后的粗网格模拟值相比，粗网格口径把每个粗方块与同一方块的聚合后的二米真值相比。粗网格口径 MSE 是粗网格模拟值减聚合真值的平方在一格上的平均，对应表 2 的模拟项。块内方差是聚合真值减两米真值平方的平均，对应表 2 的聚合项，它衡量方块内部本来就不均匀的那一部分，与粗网格算得准不准无关。两项之和一栏是粗网格口径 MSE 与块内方差相加，按逐块恒等式，它应当等于细网格口径 MSE。差值一栏是细网格口径 MSE 减去两项之和。表头中的 MSE 指均方误差，也就是误差平方的平均，取平方根即 2.2 节定义的均方根误差。十米、二十米与三十米三档上这个差值落在十的负九次方平方米量级，相对量级为十的负八次方，属于单精度累加的舍入，说明恒等式在数值上成立。逐块改用双精度复算时，最大残差为九乘十的负十四次方平方米，可以认为严格成立。五米档的方块宽两个半两米单元，最近邻升采样形成的分组与面积加权方块并不重合，因此差值升到十的负五次方平方米量级，约为该档细网格口径的万分之五，这一档需要单独看，正文有说明。后两栏是同一批数字开平方后的均方根误差，单位是米，便于与其他表格对照。

| 重现期  | 边长(米) | 分辨率比 | 细网格口径<br>MSE(平方米) | 粗网格口径<br>MSE(平方米) | 块内<br>方差(平方米) | 两项之和(平方米) | 差值<br>(平方米) | 粗网格口径占比<br>(%) | 块内方差占比<br>(%) | 细网格口径<br>RMSE(米) | 粗网格口径<br>RMSE(米) |
|------|-------|------|-------------------|-------------------|---------------|-----------|-------------|----------------|---------------|------------------|------------------|
| 20a  | 5     | 2.5  | 0.1290            | 0.1150            | 0.0139        | 0.1289    | 7.0e-05     | 89.1           | 10.8          | 0.3592           | 0.3391           |
| 20a  | 10    | 5    | 0.1253            | 0.0999            | 0.0254        | 0.1253    | -3.2e-09    | 79.7           | 20.3          | 0.3540           | 0.3160           |
| 20a  | 20    | 10   | 0.2021            | 0.1564            | 0.0458        | 0.2021    | 1.2e-08     | 77.4           | 22.6          | 0.4496           | 0.3954           |
| 20a  | 30    | 15   | 0.2546            | 0.1932            | 0.0615        | 0.2546    | -1.2e-08    | 75.9           | 24.1          | 0.5046           | 0.4395           |
| 100a | 5     | 2.5  | 0.1794            | 0.1610            | 0.0184        | 0.1793    | 9.5e-05     | 89.7           | 10.2          | 0.4236           | 0.4012           |
| 100a | 10    | 5    | 0.1728            | 0.1389            | 0.0339        | 0.1728    | -3.6e-09    | 80.4           | 19.6          | 0.4157           | 0.3727           |
| 100a | 20    | 10   | 0.2747            | 0.2123            | 0.0624        | 0.2747    | 1.6e-08     | 77.3           | 22.7          | 0.5241           | 0.4608           |
| 100a | 30    | 15   | 0.3622            | 0.2768            | 0.0854        | 0.3622    | -1.8e-08    | 76.4           | 23.6          | 0.6018           | 0.5261           |


读表 3 先看差值一栏。在十米、二十米与三十米三档上，细网格口径均方误差减去后两项之和，剩下的值落在十的负九次方平方米量级，相当于该档数值的十的负八次方，这是累加时的浮点舍入。也就是说，细网格口径的均方误差等于粗网格口径的均方误差加上块内方差，三者之间没有拟合，也没有近似。

这条等式可以从一块方块直接算出来。设方块内有  $N$  个两米单元，真值依次记作  $t_1$  到  $t_N$ ，粗网格模拟值是这一个方块上的单值  $c$ ，方块的聚合真值是这  $N$  个数的平均，记作  $a$ 。把细网格口径的平方误差按方块展开，得到每个两米单元上  $c - t$  的平方的平均。把  $c - t$  写成  $c - a + a - t$  两项之和再平方，展开后多出一个交叉项。交叉项等于  $c - a$  乘以方块内各单元  $a - t$  的偏差之和。而  $a$  就是那  $N$  个数的平均，偏差之和严格等于零，交叉项随之消失。剩下的第一项  $c - a$  的平方在方块内是常数，第二项是各单元偏离方块平均的平方。等式因此逐块成立。全部方块取平均之后，等式对全域也成立。本节还把这一推导逐块用双精度复算了一遍，十米、二十米与三十米三档上最大残差为九乘十的负十四次方平方米，与推导相符。

两笔账回答的是两个不同的问题。 $c - a$  那一项问粗网格自己算得准不准，它比较同一个方块上数值求解给出的值与方块的面积平均。 $a - t$  那一项问方块内部本来有多不均匀，它只由两米真值决定，与粗网格模拟值没有任何关系，换网格、换数值格式都改不了它。细网格口径把这两件事加在一起报，单独看它回答不了其中任何一个问题。

细网格口径还系统性地偏高，而且偏高的部分与模型好坏无关，这是它最需要警惕的地方。表 3 里块内方差占细网格口径的比例，在十米档上约占百分之二十，到三十米档升到百分之二十四上下。换成绝对值看，十米档的块内方差在 0.0254 与 0.0339 平方米之间，三十米档在 0.0615 与 0.0854 平方米之间。即便粗网格模拟值与方块的面积平均完全一致，细网格口径也不会给出零误差，它至少留下块内方差这一项。

偏高的幅度随网格变粗而上升，这一点会影响跨分辨率趋势的读法。以一百年一遇情景为例，块内方差从五米档的 0.0184 平方米升到三十米档的 0.0854 平方米，变为原来的约四点六倍。同一区间里粗网格口径的均方误差从 0.1610 升到 0.2768 平方米，变为原来的约一点七倍。用均方根误差表示，细网格口径从五米的 0.4236 米升到三十米的 0.6018 米，增长约百分之四十二，粗网格口径从 0.4012 米升到 0.5261 米，增长约百分之三十一。趋势的方向在两个口径下一致，但细网格口径把衰减读得更陡，看起来像是精度掉得更快。



**图 10 细网格口径与粗网格口径的对照。** 四个子图的横轴都是四档网格边长。子图 (a) 与子图 (b) 是堆叠柱状图，分别对应二十年一遇与一百年一遇情景，纵轴是均方误差，单位是平方米。每根柱子分两段，深蓝段是粗网格口径的均方误差，橙色段是块内方差，柱顶标出的百分数是块内方差占细网格口径的比例，柱顶的黑色短横线是细网格口径的合计。可以读出两段的比例随网格变粗而改变，粗网格口径一段始终更长，块内方差一段从五米处的约百分之十升到三十米处的约四分之一，深蓝与橙色的分界随网格变粗明显上移。子图 (c) 的纵轴换成均方根误差，单位是米，实线对应一百年一遇，虚线对应二十年一遇，圆点是细网格口径，方点是粗网格口径。可以读出同一情景下细网格口径的曲线始终在上方，两条曲线的间距随网格变粗而拉大，三十米处相差百分之十四到百分之十五。子图 (d) 的纵轴是块内方差占细网格口径的比例，单位是百分数，两个情景各一条曲线，每个点旁标注具体取值。可以读出比例从五米处的约百分之十单调升到三十米处的约百分之二十四，说明网格越粗，细网格口径里属于地面本来不均匀的份额越大。这张图的物理含义是两个口径的间距来自地面本身的不均匀，它能得出的结论是用细网格口径报告误差会系统性地高估模型的不足。

把四个子图连起来看，可以在两条口径之间建立换算。细网格口径给出的误差水平总是更高，高出的部分等于块内方差的平方根，与模型质量无关。两条口径对趋势方向的判断一致，对衰减幅度的判断有差别，细网格口径会把衰减读得更陡。这一节的数字取自 `outputs/premodel/scale_dialect.json`，可以由两米专题文件与各档网格的洪水文件逐项复算。

本章把粗网格口径当作主口径，理由有两条。第一条是下游需要的东西就落在粗网格上。前置模型的作用是估计并扣除粗网格模拟值里的可减误差，它的输出要与粗网格场相加，再交给超分辨率环节。若把监督目标定义在每一个两米单元上，一块方块会得到二十五个残差，加回之前还得再平均一次，聚合这一步绕不开，只是由显式变成隐式。第二条是粗网格口径把两类误差分得干净。粗网格口径里的那一部分正是前置模型要修的可减误差，块内方差那一部分属于下游超分辨率环节要补的细节。两个模型的分工因此一目了然，既没有丢掉信息，也没有让责任重叠。

保留粗网格口径并不排斥细网格口径。表 2 已经把两类误差都放在两米格网上报过一遍，读者若要查某个具体两米单元的偏差，那里有完整数字。本节补充的是口径之间的换算关系，让读者知道两个口径相差多少、差在哪里。

把粗网格值搬到细网格这一步用最近邻升采样，不用双线性插值。最近邻把方块内的值原样复制到该方块覆盖的每个两米单元上，方块内的平均因此被保留。把一个粗网格场升到两米再按面积聚合回去，得到的就是原来的场。本节以十米档为例实测了这一次往返，最大偏差是 1.9 乘十的负六次方米，平均偏差在十的负九次方米量级，可以认为严格守恒。双线性插值在方块边界处把相邻方块的值加权混合，升采样之后再聚合回去得不到原值，方块内的水量会随插值方式改变，对水深场不合适。

五米档的例外需要单独交代。五米方块宽两个半两米单元，一个方块并不正好覆盖整数个两米单元。面积加权聚合按重叠面积分配权重，一个方块可能横跨三个两米单元，权重取 0.4、0.4 与 0.2 这种形式。最近邻升采样只能把每个两米单元整体划归某一个方块，分组边界与面积加权的边界因此错开半个单元。错开之后，每个分组内部的平均不再等于方块的面积加权平均，交叉项不再严格为零，表 3 的差值一栏在五米档上因此升到十的负五次方平方米量级。这个差值只有该档细网格口径的万分之五，不影响任何结论。十米、二十米与三十米三档的两米单元数都是整数，分组与方块完全重合，恒等式因此严格成立。

## 2.5 哪些条件让误差变大

前两节说明误差随网格变粗而增长，也说明本章在粗网格口径上读这些数字。这一节回答另一个问题，同样一档网格上，为什么有些地方误差大而有些地方误差小。做法是把研究域按某一地理条件的取值分成三档，比较取值最低的三分之一与最高的三分之一的误差。每个条件都做两次，一次在单元一级，一次在瓦片一级。两级的结果并不总是一致，不一致的地方本章如实写出。

先把两级的差别交代清楚。单元一级的记录是一条对应一个粗网格方块，条件变量取该方块自身的取值，统计范围是十米网格、一百年一遇情景下的全部有水方块，共 276143 块。瓦片一级的记录是一条对应一块 480 米见方的瓦片，条件变量取该瓦片内的平均值，统计范围是全部 487 块可用瓦片乘以两个降雨情景，共 974 条。瓦片是本章后文做解释份额时的单位，把它一并列出，是为了让两级的结论可以互相对照。

十米网格、一百年一遇情景下，各条件取值高组与低组的误差对照




图 11 各条件取值高组与低组的误差对照，十米网格。六个子图的横轴都是条件变量的三个取值档，由低到高依次为蓝色、灰色与红色三组柱子，纵轴是平均绝对误差，单位是米，柱顶数字是具体取值。每个子图还配一条灰色虚线，用右侧纵轴读数，表示该组内部的平均水深，单位是米，用来提示各组之间的水深并不相同。上排三个子图是单元一级，只统计有水单元，横轴依次是单元坡度、单元建筑覆盖率与单元到水体的距离，距离的单位是米。下排三个子图是瓦片一级，横轴依次是瓦片内建筑占比、瓦片内不透水面占比与瓦片土地利用混合度。可以读出两类不同的形状。上排三幅的柱顶高度差别不大，建筑覆盖率一幅几乎持平，坡度与到水体距离两幅呈单调变化但幅度有限。下排三幅都呈明显的上升，建筑占比一幅从 0.037 米升到 0.117 米，不透水面一幅从 0.038 米升到 0.108 米，土地利用混合度一幅从 0.051 米升到 0.100 米。再看灰色虚线，上排单元建筑覆盖率一幅的虚线随横轴下降，说明全覆盖组的平均水深反而浅，这是读上排结论时必须一起看的信息。这张图的物理含义是误差的主要外部条件集中在建成状况上，它能得出的结论是校正模型应当把建筑与地类信息当作主要输入。

**表 4 哪些条件让误差变大，单元一级与瓦片一级的两组对照。**每个条件按取值分成三档，本表只列最低与最高两个三分之一。单元一级取十米网格、一百年一遇情景，统计范围是全部有水单元，共 276143 个，条件变量取该单元自身的取值。瓦片一级取十米网格下的全部 487 块瓦片与两个情景，共 974 条记录，条件变量取该瓦片内的平均值。平均绝对误差单位是米。比值是两组的平均绝对误差相除，大于一表示高值组误差更大，小于一表示方向相反。末两列给出两组内部的平均水深，用来提示两组的水深并不相同，读比值时需要一起看。相关系数是条件变量与误差绝对值之间的皮尔逊相关系数，只描述线性同步程度。

| 统计部位 | 条件变量       | 低值组取值     | 低值组MAE(米) | 高值组取值   | 高值组MAE(米) | 高值组与低值组之比 | 低值组平均水深(米) | 高值组平均水深(米) | 与误差的相关系数 |
|------|------------|-----------|-----------|---------|-----------|-----------|------------|------------|----------|
| 单元   | 单元坡度       | ≤0.06241  | 0.2745    | ≥0.2292 | 0.3114    | 1.13      | 0.362      | 0.351      | 0.00     |
|      | 单元建筑覆盖率    | 覆盖率 0     | 0.3052    | 覆盖率 1   | 0.3075    | 1.01      | 0.413      | 0.263      | 0.00     |
|      | 单元到水体距离    | ≤646      | 0.3431    | ≥2137   | 0.2573    | 0.75      | 0.455      | 0.254      | -0.07    |
| 瓦片   | 单元平均坡度     | ≤0.2584   | 0.1141    | ≥0.3811 | 0.0498    | 0.44      | 0.112      | 0.061      | -0.42    |
|      | 单元内二米高程标准差 | ≤0.8801   | 0.1137    | ≥1.298  | 0.0501    | 0.44      | 0.111      | 0.062      | -0.40    |
|      | 瓦片内建筑像元占比  | ≤0.008681 | 0.0368    | ≥0.4045 | 0.1173    | 3.19      | 0.057      | 0.093      | 0.47     |
|      | 瓦片内不透水面占比  | ≤0.05686  | 0.0383    | ≥0.171  | 0.1075    | 2.81      | 0.045      | 0.112      | 0.32     |
|      | 瓦片到水体平均距离  | ≤525      | 0.0803    | ≥1460   | 0.0864    | 1.08      | 0.097      | 0.081      | 0.05     |
|      | 瓦片土地利用混合度  | ≤0.6268   | 0.0514    | ≥0.9328 | 0.1003    | 1.95      | 0.061      | 0.101      | 0.37     |

表 4 把图 11 的数字连同相关系数一起列出，读法是先看比值一栏再看最后一栏。比值是条件取值最高的三分之一与最低的三分之一之间的平均绝对误差之比，大于一表示高值组误差更大。相关系数是条件变量与误差绝对值之间的皮尔逊相关系数，仅描述线性同步程度。三个因素在两级上方向一致，而且量级最大。瓦片内建筑占比的两组误差是 0.0368 米与 0.1173 米，比值 3.19。不透水面占比的两组是 0.0383 米与 0.1075 米，比值 2.81。土地利用混合度的两组是 0.0514 米与 0.1003 米，比值 1.95。这三个量指向同一件事，地表越破碎、硬化程度越高、地类越混杂，粗网格越难还原。

另外三个因素的方向不稳定，需要如实说明。到水体的平均距离在瓦片一级几乎没有区别，两组误差是 0.0803 米与 0.0864 米，比值 1.08，相关系数 0.05，可以认为无关。单元内二米高程标准差与单元平均坡度在瓦片一级都与误差负相关，相关系数分别是负 0.396 与 负 0.422，也就是说起伏更大、坡度更陡的瓦片反而更准。原因已在 2.3 节交代，这类瓦片多在城市外围的山坡上，整片干或整片湿，判定反而容易。到了单元一级，高程标准差没有稳定方向，坡度的比值在不同网格上从 1.55 变到 0.86，连符号都会翻转。因此这两个因素不能当作误差大小的稳定指示。

还有一件事必须提醒。上面所有对照都只是相关关系，而且都被水深带偏。表 4 的末两栏给出每一组内部的平均水深，可以读出不少高误差组同时也是水更深的一组。最清楚的一个例子是单元建筑覆盖率。无建筑组的平均水深是 0.413 米，满覆盖组只有 0.263 米，两组的平均绝对误差分别是 0.305 米与 0.308 米，几乎没有差别，也就是说单元一级看不到建筑的独立作用。因此本章报告的是哪些条件附近的误差更大，不能读成这些条件造成了这些误差。

把两级合起来可以得到一条可用的经验。误差在数值上更大的地方是建成密度高、地表破碎之处，而不是陡坡或远离河道之处，后者只是水深更浅。这一条与图 9 中误差沿河道成片出现并不矛盾。成片出现说的是误差在空间上是连续的，建成密度说的是误

差在数值上更大，两件事可以同时成立。

## 2.6 地形失真的来源与量级

上一节把粗网格误差拆成模拟项与聚合项，这一节专门交代聚合项的来源。粗网格用一个大方块代表一片真实地形，方块内的高程回落成一个平均值。单元内部的起伏越大，这个平均值丢掉的细节就越多。本节只用静态文件里确实存在的通道，逐项量算这种丢失的程度。需要先说明的是，静态文件只包含地表河道信息，排水管网与检查井的图层在数据节点中不存在，因此管网引起的失真在本节无法单独量算，只能在其他小节用河道邻近度作为代理。

单元内高程标准差衡量一个粗单元内部的高程散布，它来自两米高程在同一个单元内的标准差。五米网格上的均值是 0.589 米，十米是 1.097 米，二十米是 2.157 米，三十米是 3.145 米。四条数字接近按边长线性增长，斜率约为每米边长增加 0.10 米。单元内高差给出同一件事的另一种说法，它等于单元内最高点与最低点之差，三十米网格上的均值是 12.87 米，也就是用一个水深值去代表将近十三米的高差。作为参照，两米全域的高程标准差是 94.66 米，那是整个研究域跨越山地与海湾的结果，属于全域名，与单元内的量不可直接比较。

被粗化抹掉的局部洼地用一组更贴近水文的量刻画。把单元内高程均值减去单元内最低高程，得到的差值表示单元内部最低的那个汇水点比单元平均值低了多少。这个差值的均值在五米网格上是 0.993 米，十米是 1.955 米，二十米是 4.261 米，三十米是 6.443 米。单元占比给出更容易记住的量级。三十米网格上有 99.7% 的单元内部存在一个比单元均值低零点一米以上的局部洼点，92.9% 的单元内部存在一个低零点五米以上的洼点。同一组比例在五米网格上分别是 87.8% 与 64.2%。地表水在填洼之前会先在这些洼点里停住，粗网格看不到它们，于是把本该滞留的水直接推向下游。这与表 1 里体积相对误差全部为正的结果方向一致。

坡度的失真方向非常明确。把两米坡度按面积加权聚合到粗网格，得到的平均坡度几乎是常数，四档都落在 0.343 附近，与两米全域的平均坡度 0.3433 相同。粗网格模拟文件自己给出的坡度均值则随边长下降，五米是 0.3352，十米是 0.3233，二十米是 0.3010，三十米是 0.2826。两者之比在五米上是 0.977，到三十米降到 0.823。比值小于一表示粗网格系统性地把地形看缓，坡面汇流到达干流的时间会被估长。粗糙度的表现相反，曼宁系数在四档网格上稳定在 0.220 附近，与聚合后的 0.2208 几乎相同，说明粗糙度本身在粗化中几乎不变，它只能通过与坡度的组合间接影响误差。

河道的情形需要单独说明。本章没有独立的河道图层，水体只能通过土地利用编码七识别。这个掩膜覆盖研究域的 0.344%，在四档粗网格上聚合后的水体占比都是 0.344%，说明面积在粗化中守恒，变化的是形状。对两米水体掩膜做欧氏距离变换，得到每个水体像元到最近非水体像元的距离，把它乘以二近似水道宽度。中位宽度是两米，也就是变换能分辨的最小值，92.6% 的水体像元宽度不超过五米，94.1% 不超过十米。九成以上的地表水道比最细的一档粗网格还要窄。水道宽度与网格边长的中位比从五米的 0.40 降到三十米的 0.067，窄于网格边长的水体像元占比从 92.2% 升到 99.4%。

土地利用的组成也随粗化变均匀。取出每个单元内部占面积最大的那一类地类，它的面积占比在五米上是 97.8%，十米是 96.1%，二十米是 92.8%，三十米是 89.8%。不透水率与建筑占比在四档网格上都稳定在 13.4% 与 28.0%，与水体占比一样属于面积守恒的量。改变的只是单元内部的混合程度，一个三十米单元平均要把若干类地类混在一起。




图 12 地形失真随网格尺寸的变化。四个子图的横轴都是网格边长，取五、十、二十、三十米四个值并按对数刻度摆放。子图 (a) 的纵轴是高程统计量，单位是米，深蓝实线圆点是单元内高程标准差的均值，深蓝虚线方点是同一量的中位数，红色三角实线是单元内高差均值。可以读出三条曲线都随边长线性上升，标准差均值从 0.589 米升到 3.145 米，高差均值从 1.99 米升到 12.87 米。中位数始终低于均值，说明分布右偏，少数单元内部的起伏远大于平均水平。图内左上角的文字给出两米全域的高程标准差，用来提示单元内的量远小于全域名。子图 (b) 的纵轴是坡度，无量纲，红色圆点实线是粗网格自身算出的坡度均值，深蓝方点虚线是把两米坡度聚合到同一网格后的均值，两条细点线是对应的中位数。可以读出聚合曲线在四档上都停在 0.343，而粗网格模拟的曲线从 0.335 单调降到 0.283。曲线旁的注释给出两者的比值，从 0.977 降到 0.823。比值小于 1 表示粗网格把地形看缓。子图 (c) 使用双纵轴。左轴是单元内高程均值减单元内最低高程，单位是米，对应蓝色圆点实线，它从 0.99 米升到 6.44 米。右轴是满足深度条件的单元占比，单位是百分数，对应两条红色虚线，深于零点一米的占比从 87.8% 升到 99.7%，深于零点五米的从 64.2% 升到 92.9%。可以读出两条占比曲线在二十米之后接近饱和，说明局部洼地的丢失在二十米档已经基本完成。子图 (d) 的横轴是水道宽度，单位是米，由两米水体掩膜的欧氏距离变换得到，纵轴是水体像元占比，单位是百分数。浅蓝色直方图是宽度分布，四条竖虚线标出四档网格边长，分别写在竖线顶端。可以读出直方图集中在最小分辨宽度附近，绝大多数水体像元的宽度落在第一条竖线的左侧，也就是比五米网格还要窄。这张图的物理含义是粗网格无法分辨城市里的细窄水道，它的读法是先看曲线随边长的走向，再看竖线与直方图的相对位置。

这张图把聚合项的来源交代清楚。单元内起伏与洼地深度随边长上升，坡度随边长下降，水道宽度始终小于网格边长，四件事指向同一个结论。粗网格看到的地形是抹平之后的产物，抹平的量在三十米档已经相当可观。地形失真无法在数值格式里修掉，它属于粗化本身带来的信息损失。这一点决定了聚合项会长期存在，前置模型的目标正是从外部把它估出来。

**表 5 地形失真随网格尺寸的变化。**全部统计量只使用 static.nc 中确实存在的通道，高程取 DEM，坡度取 Slope，水体取土地利用编码七，建筑取 Building\_binary。单元内高程标准差与单元内高差刻画一个粗单元内部的地形起伏被抹平的程度，数值越大表示粗网格看到的越平坦。洼地深度是单元内高程均值减去单元内最低高程，代表被粗化抹掉的最深局部汇水点。坡度比是粗网格自身坡度均值除以二米坡度聚合后均值，小于一表示粗网格系统性地把地形看缓。最后两列把二米水道宽度分布与网格边长相比，水体占比一列是二米水体像元中被网格边长高于其宽度的比例。参照量，二米高程标准差为 94.7 米，二米水体像元中位宽度见正文。

| 边长<br>(米) | 分辨率比 | 单元内高程<br>标准差均值(米) | 单元内<br>高差均值(米) | 洼地<br>深度<br>均值<br>(米) | 洼地<br>深于<br>0.1 米<br>(%) | 洼地<br>深于<br>0.5 米<br>(%) | 粗网格<br>坡度均<br>值 | 聚合后<br>的<br>坡度均<br>值 | 坡度<br>比 | 水道<br>宽/边<br>长<br>中位数 | 窄于边<br>长的<br>水体占<br>比(%) | 单元主<br>导<br>地类占<br>比(%) |
|-----------|------|-------------------|----------------|-----------------------|--------------------------|--------------------------|-----------------|----------------------|---------|-----------------------|--------------------------|-------------------------|
| 5         | 2.5  | 0.589             | 1.99           | 0.993                 | 87.8                     | 64.2                     | 0.3352          | 0.3432               | 0.977   | 0.40                  | 92.2                     | 97.8                    |
| 10        | 5.0  | 1.097             | 3.91           | 1.955                 | 94.8                     | 78.7                     | 0.3233          | 0.3432               | 0.942   | 0.20                  | 94.1                     | 96.1                    |
| 20        | 10.0 | 2.157             | 8.52           | 4.261                 | 99.0                     | 89.5                     | 0.3010          | 0.3432               | 0.877   | 0.10                  | 97.4                     | 92.8                    |
| 30        | 15.0 | 3.145             | 12.87          | 6.443                 | 99.7                     | 92.9                     | 0.2826          | 0.3432               | 0.823   | 0.07                  | 99.4                     | 89.8                    |

表 5 把图 12 的曲线换成具体的数字，同时补上几项图里放不下的量。读表时先看前三列，它们给出单元内的起伏随边长增长的速度。再看洼地四列，前两列是深度均值，后两组是占比。坡度三列把粗网格模拟与聚合放在一起，比值小于一表示粗网格偏缓。最后三列涉及水体与土地利用，水道宽比中位数从 0.40 降到 0.067，窄于网格的水体占比从 92.2% 升到 99.4%，主导地类占比从 97.8% 降到 89.8%。表中没有列入粗网格模拟高程与聚合高程的差值。五米档的这个量是 0.053 米，比十米档的 0.004 米高出一个数量级，看不出随网格变化的单调趋势，它很可能是粗网格静态文件的配准差异，因此不作横向比较。

把这一节与上一节的聚合项放在一起，可以得到一个对应关系。聚合项的均方根误差从五米的 0.118 米升到三十米的 0.248 米，与单元内高程标准差和洼地深度的增长同步。两者指向同一个机制，粗网格把地形抹平之后，它给出的水面也一并变平。这一部分误差无法通过改进数值格式消除。


## 2.7 跨分辨率相关性的衰减规律

前两节用全局标量描述误差的大小，这一节换一个角度，比较两幅图在形状上有多像。形状比较包含两件事。一件是两者在同一位置是否给出同样的干湿判断，由判定类指标承担。另一件是两者的数值是否同步变化，由分布相似性指标承担。判定类指标在全域上计算，分布相似性指标中的两个相关系数只在湿区上统计，湿区取聚合真值超过五厘米的单元，因为干区上的相关系数没有意义。结构相似度例外，它在整个粗网格域上计算。

淹没范围的匹配度随分辨率比下降，下降的幅度取决于阈值。五厘米阈值下，二十年一遇情景的临界成功指数从五米网格的 0.3248 变到三十米的 0.2818，中间在十米处升到 0.3626。一百年一遇情景的对应数值是 0.3504、0.3921、0.3053 与 0.3197，走势相同。一米阈值下的衰减猛烈得多，二十年一遇情景从十米的 0.2391 降到三十米的 0.0898，降幅约百分之六十二，一百年一遇情景从 0.2564 降到 0.1169，降幅约百分之五十四。衰减主要集中在十米到二十米这一段，二十米到三十米之间几乎持平。这里的 F1 分数（F1 score，精确率与召回率的调和平均）一律高于临界成功指数，两者相差约零点一六到零点一七，这是定义带来的固定差别，不改变相对结论。

水深分布的相似性给出另一条曲线。湿区上的皮尔逊相关系数（Pearson correlation coefficient，衡量两组数值的线性同步程度）在五米网格上是 0.6026，十米升到 0.6554。二十米跌到 0.2975，三十米只剩 0.1946。十米到二十米的跌幅超过一半。斯皮尔曼等级相关系数（Spearman rank correlation coefficient，先把数值换成排名再求相关）的衰减平缓得多。四档分别是 0.2302、0.2823、0.2262 与 0.2861，三十米上的数值甚至略高于五米。两者的差别说明粗网格丢掉的主要是数值上的比例关系，单元之间的相对次序保留得较好。结构相似度（Structural Similarity Index，简写 SSIM，同时比较亮度、对比度与结构）从五米的 0.9599 降到三十米的 0.8973，绝对值一直很高，这与它包含亮度项有关。

流速场只在数据存有单宽流量的整点时刻才能派生。本章取全域水量最大的那个时刻，在两个情景下都是起始后的第六个整点，单宽流量的两个分量除以水深得到流速幅值。派生指从已有变量直接算出新变量，这里的流速幅值就是这样一个派生量。这个派生量在粗网格上有明显的厚尾，三十米网格上粗网格模拟的平均流速是 3.75 米每秒，聚合后的平均流速只有 0.65 米每秒，前者被少数水深极小的单元拉高。因此流速部分只报告等级相关系数，皮尔逊系数仅作参考。等级相关系数在四档网格上落在 0.34 到 0.51 之间，与水深同一量级的相关系数接近，说明流速的空间格局在粗化中受到的破坏与水深相当。



**图 13 跨分辨率相关性的衰减。** 四个子图的横轴都是分辨率比，定义为粗网格边长除以两米，取 2.5、5、10 与 15 四个值，按对数刻度摆放。蓝色对应二十年一遇情景，红色对应一百年一遇情景，蓝色一律用虚线。子图 (a) 的纵轴是临界成功指数，圆点、方点与三角分别对应五厘米、三十厘米与一米三个阈值，同一情景内用透明度区分阈值，阈值越高线条越淡。可以读出三条结论。同一阈值的曲线在分辨率比 5 处最高，也就是十米网格处匹配度最好。阈值越高曲线越低，一米阈值的曲线整体位于最下方，在分辨率比 15 处降到 0.09 附近。衰减集中在分辨率比 5 到 10 这一段，之后趋于平坦。子图 (b) 的纵轴是相关系数与结构相似度，取值在零到一之间，圆点连线是皮尔逊系数，方点是斯皮尔曼系数，紫色三角是结构相似度。可以读出皮尔逊系数从 0.60 一路跌到 0.19，斯皮尔曼系数基本停在 0.23 到 0.30 之间不随分辨率比下降，结构相似度从 0.96 缓慢降到 0.90。三条曲线的分离说明线性同步性损失最快，次序结构损失最慢。子图 (c) 的纵轴是流速幅值的相关系数，横轴同为分辨率比，图注中的时刻指全域水量最大的整点。可以读出皮尔逊系数在 0.29 到 0.44 之间波动，斯皮尔曼系数在 0.34 到 0.51 之间波动，两者都没有表现出随分辨率比单调下降的趋势。这个现象与流速的厚尾分布有关，少数水深极小的单元会产生极大的派生流速，因此本子图应主要看等级相关系数。子图 (d) 的纵轴是均方根误差除以平均真值水深，是一个无量纲的归一化误差。可以读出它从分辨率比 2.5 处的 4.83 升到 15 处的 6.25，一百年一遇情景从 4.40 升到 5.77，两条曲线在分辨率比 10 处有一个明显的台阶。把它与子图 (a) 对照可以看出，误差的绝对增长与匹配度的衰减在同一段上同时发生。

这张图回答的是相关性以什么方式衰减。结论是衰减并不均匀，它集中在十米到二十米之间，之后进入平台期。不同指标给出的衰减速度差别很大，淹没范围的判定最脆弱，尤其是深水判定，水深的具体数值其次，单元之间的相对次序最稳定。对超分辨率任务的含义是，粗网格提供的次序信息比数值信息可靠，重构模型应当更多地利用前者。

**表 6 跨分辨率相关性与流速场相似性。**水深部分比较粗网格模拟值与聚合后的二米真值，行列含义与表 1 一致。二值掩膜下交并比与临界成功指数恒等，因此只列临界成功指数，F1 单独列一列以便读者对照。流速场的相似性由  $h_{ux}$  与  $h_{vy}$  两个单宽流量分量除以水深得到，只在数据存有流量场的整点时刻评估，取全域水量最大的那个整点。100a 与 20a 情景都落在起始后的第 6 个整点。最后一列是聚合到粗网格后的平均流速，与相邻一列的粗网格平均流速对照。表头篇幅有限，用短名代替完整说法。模拟均流速是粗网格模拟值给出的平均流速，聚合均流速是聚合后的二米真值给出的平均流速，两个短名与 2.1 节的命名一一对应。流速是数据中没有直接存储的量，由存有的单宽流量与水深相除得到，属于派生量。

| 重现期  | 边长(米) | 分辨率比 | CSI<br>@0.05 | CSI<br>@0.30 | CSI<br>@1.00 | F1<br>@0.05 | 水深<br>Pearson | 水深<br>Spearman | 水深<br>SSIM | 流速<br>Pearson | 流速<br>Spearman | 模拟<br>均<br>流速<br>(m/s) | 聚合<br>均<br>流速<br>(m/s) |
|------|-------|------|--------------|--------------|--------------|-------------|---------------|----------------|------------|---------------|----------------|------------------------|------------------------|
| 20a  | 5     | 2.5  | 0.325        | 0.238        | 0.212        | 0.490       | 0.603         | 0.230          | 0.960      | 0.291         | 0.339          | 0.109                  | 0.676                  |
| 20a  | 10    | 5.0  | 0.363        | 0.268        | 0.239        | 0.532       | 0.655         | 0.282          | 0.956      | 0.366         | 0.504          | 1.556                  | 0.638                  |
| 20a  | 20    | 10.0 | 0.279        | 0.171        | 0.108        | 0.436       | 0.298         | 0.226          | 0.925      | 0.334         | 0.393          | 2.830                  | 0.627                  |
| 20a  | 30    | 15.0 | 0.282        | 0.202        | 0.090        | 0.440       | 0.195         | 0.286          | 0.897      | 0.437         | 0.502          | 3.815                  | 0.653                  |
| 100a | 5     | 2.5  | 0.350        | 0.268        | 0.231        | 0.519       | 0.641         | 0.244          | 0.956      | 0.337         | 0.415          | 0.098                  | 0.672                  |
| 100a | 10    | 5.0  | 0.392        | 0.299        | 0.256        | 0.563       | 0.690         | 0.288          | 0.951      | 0.356         | 0.496          | 1.451                  | 0.659                  |
| 100a | 20    | 10.0 | 0.305        | 0.200        | 0.130        | 0.468       | 0.373         | 0.228          | 0.923      | 0.319         | 0.376          | 2.724                  | 0.656                  |
| 100a | 30    | 15.0 | 0.320        | 0.223        | 0.117        | 0.484       | 0.223         | 0.300          | 0.895      | 0.405         | 0.469          | 3.752                  | 0.699                  |

表 6 把图 13 的曲线展开成数字，并把流速部分单独列出。前七列比较水深场，行列含义与表 1 一致，其中交并比一列不单列，因为二值掩膜下它与临界成功指数恒等。中间三列是水深分布相似性，可以直接读出皮尔逊系数在分辨率比 5 之后掉得最快。右侧四列是流速场，前两列是两个相关系数，后两列是粗网格模拟与聚合的平均流速，两者的落差来自派生量的厚尾，读表时需要留意。表中流速一列的单位是米每秒。

2.8 逐瓦片的离散与解释份额

全局曲线只给出平均行为，工程上真正关心的是某一块具体区域会有多准。把研究域按 480 米边长切成方块瓦片，逐块计算粗网格模拟值与聚合真值的临界成功指数，就得到瓦片之间的离散。可用的瓦片共 487 块，两个情景各算一次，参与统计的记录因此是 974 条。二十米与三十米网格上，一块瓦片内部的单元数分别是 576 与 256，足以支撑一个稳定的比值。

瓦片之间的差异相当大。五米网格上逐瓦片临界成功指数的标准差是 0.125，百分之五到百分之九十五分位落在 0.149 与 0.549 之间。分位数是把一组数值从小到大排好之后按位置取到的值，百分之五到百分之九十五分位区间表示去掉两端各百分之五之后的取值范围。三十米网格上的标准差升到 0.161，分位区间变成 0.081 到 0.614。网格变粗之后，全局平均值几乎不变，离散却扩大了约三成。全局指标因此掩盖了区域之间的巨大差别。误差校正如果只用一个全局标量，对某些瓦片会明显不足，对另一些瓦片又会过头。

同一块瓦片在不同网格上的取值高度相关。五米与三十米的逐瓦片临界成功指数相关系数是 0.613，五米与十米之间是 0.857，十米与二十米之间是 0.893。把三十米的值对五米的值做一元回归，斜率是 0.788，小于一。斜率小于一表示粗网格把瓦片之间的好坏差别压缩了一些，原本很好的瓦片被压低，原本很差的瓦片被抬高。这与图 14 中子图 (a) 的散点形状一致，数据点整体落在等值线下方。等值线是数值相等的点连成的线，这里指两个网格取值相等的那一条。




图 14 逐瓦片离散及其来源。四个子图的每个点都是一块 480 米瓦片，两个情景用蓝红两色区分，蓝点为二十年一遇，红点为一百年一遇。子图 (a) 的横轴是五米网格上的逐瓦片临界成功指数，纵轴是同一块瓦片在三十米网格上的对应值，灰色虚线是两者相等的等值线。可以读出散点围绕等值线分布，相关系数是 0.613，说明两个网格对瓦片好坏的判断大体一致。多数点落在等值线下方，与回归斜率 0.788 相符，表示粗网格把极端值向中间压缩。子图 (b) 到子图 (d) 的横轴依次换成瓦片内湿区占比、单元内两米高程标准差与瓦片内建筑像元占比。三个子图的纵轴统一为十米网格的逐瓦片临界成功指数，并使用同一批瓦片。图例中的  $r$  是皮尔逊相关系数。子图 (b) 可以读出湿区占比越高，匹配度越低， $r$  为负 0.44。子图 (c) 可以读出地形越粗糙，匹配度反而越高， $r$  为正 0.50，方向与直觉相反，原因与湿区分区有关，见正文说明。子图 (d) 可以读出建筑占比与匹配度的负相关最强， $r$  为负 0.85，密集建成区的散点几乎排列在一条下降带上。三个子图的纵轴范围相同，因此可以直接比较散点带的陡峭程度。

这张图说明离散来自可以识别的外部条件。建筑占比与匹配度的负相关最强，地表破碎、排水路径复杂的区域最难被粗网格还原。地形粗糙度一项的正相关需要结合湿区占比来读。粗糙地形多分布在城市外围的山坡，那里的淹没格局简单，整片干或整片湿，判定容易。平坦的建成区水浅且破碎，判定困难。三条关系都是相关关系，把它们当作因果需要额外的证据。

把 2.5 节的逐个对照放进一个统一的框架，就可以定量给出各因素的解释份额。因变量取每块瓦片的临界成功指数，也就是 2.5 节用来比较的那一个量。解释变量按研究方案的分类分成五组，分别是降雨情景、坡度与粗糙度、不透水率、建筑与土地利用、河道邻近度。另外把由粗网格自身算出来的湿区占比单列成一组状态量。这里说的派生量指从已有变量直接算出来的量，湿区占比就属于这一类，它不算外部条件，因此单独成组。份额用分组沙普利值计算。沙普利值 (Shapley value) 来自合作博弈论，它把一组变量联合起来的解释力，按各参与变量的平均边际贡献分摊下去。选用它的原因是它不依赖变量的进入顺序。逐项回归做不到这一点，它的系数会随变量的增减而剧烈变化。

**表 7 逐瓦片匹配度的贡献度分解。**因变量是每一块瓦片上粗网格模拟值与聚合后的二米真值的临界成功指数，阈值为 0.05 米。解释变量按研究方案分为五组，另加一组湿区占比作为状态量单列。份额是分组 Shapley 值占全模型已解释方差的比例，六行之和为百分之百。使用 Shapley 值是因为它不依赖变量的进入顺序，在解释变量彼此相关时比逐项回归更稳妥，共线性程度见正文。湿区占比一列由粗网格自身派生，属于状态量而不是外部条件，读表时应与另外五行区分。全部瓦片参与拟合，包括训练、验证与测试条带，这一节是解释性分析而不是预测模型，因此不受切分纪律约束。

| 因素                     | 5 米<br>(%) | 10 米<br>(%) | 20 米<br>(%) | 30 米<br>(%) |
|------------------------|------------|-------------|-------------|-------------|
| 降雨情景                   | 0.5        | 0.5         | 1.4         | 4.1         |
| 坡度与粗糙度                 | 12.4       | 10.3        | 16.5        | 15.6        |
| 不透水率                   | 2.7        | 8.7         | 6.1         | 7.9         |
| 建筑与土地利用                | 65.5       | 65.1        | 62.9        | 61.3        |
| 河道邻近度                  | 12.7       | 9.1         | 8.4         | 6.7         |
| 湿区占比（状态量，另列）           | 6.2        | 6.3         | 4.8         | 4.3         |
| 全模型决定系数 R <sup>2</sup> | 0.805      | 0.865       | 0.729       | 0.527       |
| 参与回归的瓦片数               | 974        | 974         | 974         | 974         |

表 7 给出分解结果。四档网格上建筑与土地利用一组的份额都在六成以上，五米是 65.5%，十米是 65.1%，二十米是 62.9%，三十米是 61.3%。坡度与粗糙度一组占 10.3% 到 16.5%，河道邻近度一组占 6.7% 到 12.7%，不透水率一组占 2.7% 到 8.7%。降雨情景的份额最小，五米与十米上都只有 0.5%，到三十米升到 4.1%。湿区占比一组占 4.3% 到 6.3%。全模型的决定系数从十米的 0.865 降到三十米的 0.527，说明粗化程度越高，瓦片之间的差异越难用静态地理条件解释。

表 7 里的份额有一个容易读错的口径，需要先讲清楚。六行份额的分母是全模型已经解释掉的那一部分差别，它比瓦片之间匹配度的全部差别要小。六行相加正好等于百分之百。以十米网格为例，全模型的决定系数是 0.865，也就是说瓦片之间匹配度的差别里有 86.5% 被这六组变量解释掉了，剩下 13.5% 解释不了。在这 86.5% 里面，建筑与土地利用一组占 65.1%。换成占全部差别的比例，把 86.5% 与 65.1% 相乘得到约 56%，与图 15 中子图 (a) 的堆叠高度一致。因此这句话的完整读法是，瓦片之间匹配度的差别里，有大约 56% 与建筑密度及土地利用的差别同步变化。它不能读成建筑造成了 65% 的误差。两者差的是一件因果证据，本数据只有相关关系，给出因果结论需要专门的对照实验。

共线性必须如实报告。方差膨胀因子（Variance Inflation Factor，简写 VIF，等于一减去该变量被其余变量解释的比例之后再取倒数）在两组变量上极端偏高。坡度与单元内高程标准差在五米网格上的 VIF 分别是 346.8 与 298.9，到三十米仍分别有 45.1 与 45.7。两个河道距离变量在四档上都在 750 以上。绿色地类占比的 VIF 落在 12 到 13 之间。这意味着组内单个变量的系数不可信，只有组一级的份额具有解释力。建筑占比与不透水率之间还存在包含关系，建筑像元本身多为不透水面，把它们分成两组是研究方案的要求，两者的份额分界线因此带有一定的人为成分。所有份额都只是相关结构上的分摊，不能读成因果效应的大小。

河道与管网这一项需要单独交代。本数据只包含地表河道，没有排水管网与检查井的图层，因此这里的河道邻近度衡量的是地表水体与坡面汇流的距离效应。它的份额在五米上达到 12.7%，到三十米降到 6.7%。这个走势可以解释为粗网格越粗，单元内部到水体的远近差别被抹得越平，距离变量的分辨率越低。排水管网的效应在本数据中无法单独识别，此处标注为待补充。

图 15 把份额、共线性与跨网格变化并排放在一起。三个子图使用同一批瓦片和同一个因变量，左侧是各组的解释份额，中间是解释变量之间的共线性，右侧是份额随网格尺寸的走向。




图 15 逐瓦片匹配度的贡献度分解与共线性诊断。子图 (a) 是堆叠柱状图，横轴是四档粗网格的边长，纵轴是各因素对逐瓦片临界成功指数方差的解释份额，也就是分组 Shapley 值。六段颜色对应六组变量，堆叠段之和等于全模型的决定系数，柱顶标注的  $R^2$  就是这个和。可以读出建筑与土地利用一段在四档网格上都最长，占已解释方差的六成以上，坡度与粗糙度、河道邻近度两段次之，降雨情景一段最短。总高度从十米的 0.865 降到三十米的 0.527，柱子随之明显变矮。子图 (b) 是水平条形图，横轴是方差膨胀因子，纵轴是十米网格用到的十一个解释变量，红色虚线画在 5 的位置作为参考。可以读出坡度与单元内高程标准差两根条最长，都超过 190，两个到水体距离变量都超过 750，说明组内变量高度重合。子图 (c) 是热力图，横轴同样是四档网格，纵轴是六组变量，颜色深浅表示该组占已解释方差的比例，格内的百分数是具体取值，色标范围固定在 0 到 0.6，因此列与列之间可以直接比较。可以读出建筑与土地利用一列在十米处最深，向右逐格变浅，与子图 (a) 中  $R^2$  的下降方向一致。

这张图把三个层面的证据放在同一处读。份额最大的两组恰好也是共线性最强的两组，说明这里的份额只能在组一级解释，单个变量的系数不能单独解读。网格变粗之后，可解释的方差总额明显下降，各组的相对排序基本保持，建筑与土地利用始终排在第一位。

## 2.9 前置模型的结构、训练与测试结果

前面几节说明粗网格误差是一个有组织、位置可预期的场，这一节把它变成一个可以调用的模型。模型的预测对象是粗网格误差场，也就是粗网格模拟水深与聚合真值之差。需要先说明这个目标的口径。它的监督目标是粗网格口径上的可减误差，也就是 2.4 节里 c 减 a 那一笔。方块内部的方差不在它的职责范围内，那一部分由下游的超分辨率环节负责补出来，本节与后面几节都只照这个分工来评价它。它的输入只能包含粗网格上就能拿到的量，因为校正必须发生在超分辨率重构之前。输入因此分成两部分，一共十六个通道。第一个通道是粗网格水深场本身。其余十五个通道是同一档粗网格上的静态地理特征，即高程、坡度、坡向的正弦与余弦分量、平面曲率、剖面曲率、地形位置指数与地形湿度指数。再往后是到建筑的距离、到道路的距离、到水体的距离、下渗率、曼宁系数、土地利用编码与建筑二值掩膜。除此之外，网络还会收到水深的非线性变换，也就是把水深加一之后取自然对数，这样浅水处的细微差别不会在归一化中被抹掉。这个变换作为额外通道并入输入，网络实际看到的通道数是十七。

模型本体是一个小型卷积网络。卷积指的是在每个位置用一个固定大小的邻域窗口做加权求和，权重由训练得到，因此它天然地利用空间上下文。本模型叠三层卷积，每层通道宽度三十二，卷积核尺寸三乘三，激活函数统一使用修正线性单元（Rectified Linear Unit，简写 ReLU，把负值截为零，正值原样保留）。最后一层用一乘一的卷积把三十二个通道压成一个通道，输出的就是误差估计值。输出层的权重与偏置都初始化成零，因此训练开始的那一刻模型输出恒为零，校正后的场与不做校正完全相同。恒等映射由此成为一个天然的出发点，模型只需要判断该往哪个方向修正。

训练目标取平均绝对误差，它比平方误差更不容易被少数极端单元主导。损失只在有效单元上累加，无效单元指水深为缺失的单元。目标值先除以训练集水深的标准差再送入损失，这样不同分辨率上的梯度处在同一量级。优化器采用自适应矩估计（Adaptive Moment Estimation，简写 Adam）。它是一种按梯度的一阶矩与二阶矩自动调整步长的随机优化方法。初始学习率是千分之三，并按余弦曲线在训练过程中衰减到零。训练固定一百五十轮，批量大小十六，每轮把训练瓦片重新打乱一次。每轮结束在验证条带上计算校正后场的指标，取验证平均绝对误差最小的那一轮作为最终模型。测试条带在所有选择完成之后只读一次，这条纪律与整个项目其余部分保持一致。为了让结果可复现，随机种子固定为零，训练与评估都在同一张显卡上串行完成。

**表 8 前置模型与两个基线在测试集上的对比。**校正后的粗网格场与聚合后的二米真值比较，测试集为南部地理条带，只在模型与轮次确定之后读取一次。恒等映射表示对粗网格场不做任何处理。双线性重采样把粗网格场用双线性核插值到二米格网后再平均回粗网格，是一个没有可学参数的平滑算子。前置模型在训练条带上拟合、在验证条带上挑选轮次，测试条带不参与任何选择。同一档网格的三行可以直接对照。平均偏差与体积相对误差两列的含义需要说明，正值表示粗网格给多了水，负值表示给少了水。恒等映射与双线性重采样两行的这两列全为正，前置模型三行的这两列全为负，符号在三者之间发生了翻转，并且前置模型在十米与五米两档上的体积相对误差绝对值高于基线。逐档数值与解释见正文。

| 边长<br>(米) | 方案        | MAE<br>(米) | RMSE<br>(米) | 偏差<br>(米) | 体积相对<br>误差(%) | CSI<br>@0.05 | CSI<br>@0.30 | CSI<br>@1.00 |
|-----------|-----------|------------|-------------|-----------|---------------|--------------|--------------|--------------|
| 5         | 恒等映射（不校正） | 0.0747     | 0.3201      | +0.0151   | +21.2         | 0.372        | 0.307        | 0.243        |
| 5         | 双线性重采样    | 0.0697     | 0.2796      | +0.0151   | +21.1         | 0.410        | 0.312        | 0.265        |
| 5         | 前置模型      | 0.0420     | 0.1780      | -0.0168   | -23.5         | 0.521        | 0.403        | 0.356        |
| 10        | 恒等映射（不校正） | 0.0644     | 0.2944      | +0.0096   | +13.4         | 0.422        | 0.345        | 0.270        |
| 10        | 双线性重采样    | 0.0577     | 0.2284      | +0.0096   | +13.4         | 0.469        | 0.346        | 0.313        |
| 10        | 前置模型      | 0.0425     | 0.1935      | -0.0119   | -16.6         | 0.511        | 0.422        | 0.370        |
| 20        | 恒等映射（不校正） | 0.0900     | 0.4083      | +0.0197   | +27.6         | 0.345        | 0.232        | 0.133        |
| 20        | 双线性重采样    | 0.0787     | 0.3086      | +0.0197   | +27.6         | 0.427        | 0.243        | 0.155        |
| 20        | 前置模型      | 0.0466     | 0.1728      | -0.0029   | -4.0          | 0.562        | 0.386        | 0.212        |
| 30        | 恒等映射（不校正） | 0.0900     | 0.4499      | +0.0197   | +27.6         | 0.370        | 0.261        | 0.116        |
| 30        | 双线性重采样    | 0.0805     | 0.3306      | +0.0197   | +27.5         | 0.426        | 0.255        | 0.124        |
| 30        | 前置模型      | 0.0461     | 0.2232      | -0.0136   | -19.1         | 0.554        | 0.312        | 0.151        |

表 8 给出测试集上的对比，三行一档，分别是恒等映射、双线性重采样与前置模型。恒等映射对应不做任何校正，它给出的是校正必要性的下限。双线性重采样把粗网格场用双线性核插值到两米格网后再平均回粗网格，是一个没有可学参数的平滑算子，它可以检验单纯的几何平滑能否带来改善。前置模型在三者中的位置就是本节的核心结论。需要提醒的是，表中的误差都是在粗网格上计算的，与表 1 的口径一致，因此可以直接与前面各节的数据对照。读这张表时请特别留意平均偏差与体积相对误差两列，前置模型在这两列上的符号与两个基线相反，逐档的数值与含义见下一段。

表 8 有一处结论必须单独点出，平均偏差与体积相对误差的方向在四档网格上全部发生了翻转。不做校正的粗网格模拟给出的是正偏差，四档的体积相对误差依次为正百分之二十一点二、正百分之十三点四、正百分之二十七点六与正百分之二十七点六，也就是水量一律偏多。前置模型校正之后，同一批网格的体积相对误差依次变为负百分之二十三点五、负百分之十六点七、负百分之四与负百分之十九点一，符号全部翻转。逐点偏差的方向同样翻转，从正零点零零九六米到正零点零一九七米变为负零点零零二九米到负零点零一六八米。

其中两档的体积平衡反而被改差。五米档的体积相对误差绝对值从百分之二十一点二升到百分之二十三点五，十米档从百分之十三点四升到百分之十六点七。三十米档从百分之二十七点六降到百分之十九点一，二十米档从百分之二十七点六降到百分之四。把四档放在一起看，前置模型在体积守恒这个口径上真正改善的是二十米与三十米两档，五米与十米两档比不校正更差。这说明前置模型在平均绝对误差、均方根误差与匹配度上获胜，是靠把偏多的水量换成偏少的水量，获胜的代价是一次方向相反的体积失衡。

这个结果与后文那一米阈值例外互为表里。平均绝对误差按单元取平均，浅水单元在数量上占绝对多数，模型因此把大部分校正量用于收掉浅水区多报的范围。收得偏紧之后，被压掉的水量超过了粗网格原本多算的水量，全场平均偏差于是由正转负。按这个读法，符号翻转来自训练目标对浅水单元的偏重。它只是一种可能解释，需要一次按水深加权的对照训练才能确认，此处标注为待补充。

这个方向还需要与后置环节放在一起提醒。本报告后面几章记录的既有超分辨率模型存在深水欠估，最不利处的水深比真值低约一米半。前置环节先把全场水量压低，后置环节再压低深水，两处偏差方向相同，沿整条预报链可能相互放大。两端叠加的实际幅度无法从现有数据判断，端到端测量尚未进行，本节末尾已按同一方式标注为待补充。

**表 9 前置模型相对两个基线的配对检验。**配对单位是一块瓦片，同一块瓦片在两个方案下的同一指标相减。平均差值为负且指标越小越好，表示前置模型更优。置信区间来自对差值重抽样四千次的自助法，不跨零即认为差异稳定。t 检验与 Wilcoxon 符号秩检验同时给出，前者假设差值近似正态，后者只要求对称。效应量采用配对 Cohen's  $d_z$ ，等于平均差值除以差值的标准差。最后一列的统计口径随指标方向而变。对于逐瓦片平均绝对误差与均方根误差，它统计差值严格为负的瓦片，也就是明确改善的瓦片。对于逐瓦片临界成功指数，差值越大越有利，因此它统计差值不小于零的瓦片，其中包含恰好持平的情形。该列取 100.0 时含义是没有一块瓦片变差，它与全部瓦片都获得改善并不等价，五米档前置模型对恒等映射的临界成功指数一行就属于这种情况。


| 边长<br>(米) | 比较                | 指标              | 平均差<br>值 | 95% 自助法<br>置信区间       | t      | Wilcoxon<br>p 值 | Cohen's<br>$d_z$ | 未变差瓦<br>片<br>占比(%) |
|-----------|-------------------|-----------------|----------|-----------------------|--------|-----------------|------------------|--------------------|
| 5         | 前置模型 减 恒等映射       | 逐瓦片 MAE         | -0.0326  | [-0.0360, -0.0295]    | -19.59 | 5.40e-40        | -1.26            | 97.1               |
| 5         | 前置模型 减 恒等映射       | 逐瓦片 RMSE        | -0.1327  | [-0.1468, -0.1194]    | -19.05 | 5.74e-39        | -1.22            | 95.9               |
| 5         | 前置模型 减 恒等映射       | 逐瓦片<br>CSI@0.05 | +0.1757  | [+0.1664,<br>+0.1848] | +36.72 | 1.89e-41        | +2.36            | 100.0              |
| 5         | 前置模型 减 双线性重<br>采样 | 逐瓦片 MAE         | -0.0276  | [-0.0307, -0.0247]    | -18.23 | 2.15e-38        | -1.17            | 96.7               |
| 5         | 前置模型 减 双线性重<br>采样 | 逐瓦片 RMSE        | -0.0957  | [-0.1079, -0.0838]    | -15.63 | 6.97e-36        | -1.00            | 91.7               |
| 5         | 前置模型 减 双线性重<br>采样 | 逐瓦片<br>CSI@0.05 | +0.1446  | [+0.1342,<br>+0.1551] | +26.41 | 2.95e-41        | +1.70            | 97.9               |
| 5         | 双线性重采样 减 恒等<br>映射 | 逐瓦片 MAE         | -0.0050  | [-0.0054, -0.0046]    | -22.41 | 1.89e-41        | -1.44            | 100.0              |
| 5         | 双线性重采样 减 恒等<br>映射 | 逐瓦片 RMSE        | -0.0370  | [-0.0397, -0.0343]    | -26.70 | 1.89e-41        | -1.72            | 100.0              |
| 5         | 双线性重采样 减 恒等<br>映射 | 逐瓦片<br>CSI@0.05 | +0.0311  | [+0.0272,<br>+0.0351] | +15.53 | 1.49e-29        | +1.00            | 84.7               |
| 10        | 前置模型 减 恒等映射       | 逐瓦片 MAE         | -0.0218  | [-0.0260, -0.0176]    | -10.13 | 6.46e-31        | -0.65            | 87.2               |
| 10        | 前置模型 减 恒等映射       | 逐瓦片 RMSE        | -0.1142  | [-0.1332, -0.0947]    | -12.00 | 1.20e-32        | -0.77            | 87.2               |
| 10        | 前置模型 减 恒等映射       | 逐瓦片<br>CSI@0.05 | +0.0639  | [+0.0556,<br>+0.0726] | +14.69 | 4.79e-31        | +0.94            | 83.9               |
| 10        | 前置模型 减 双线性重<br>采样 | 逐瓦片 MAE         | -0.0151  | [-0.0186, -0.0114]    | -8.24  | 9.70e-28        | -0.53            | 87.2               |
| 10        | 前置模型 减 双线性重<br>采样 | 逐瓦片 RMSE        | -0.0539  | [-0.0692, -0.0372]    | -6.74  | 1.28e-24        | -0.43            | 80.2               |
| 10        | 前置模型 减 双线性重<br>采样 | 逐瓦片<br>CSI@0.05 | +0.0663  | [+0.0576,<br>+0.0747] | +15.14 | 1.23e-29        | +0.97            | 83.5               |

| 边长<br>(米) | 比较                | 指标              | 平均差<br>值 | 95% 自助法<br>置信区间       | t      | Wilcoxon<br>p 值 | Cohen's<br>d <sub>z</sub> | 未变差瓦<br>片<br>占比(%) |
|-----------|-------------------|-----------------|----------|-----------------------|--------|-----------------|---------------------------|--------------------|
| 10        | 双线性重采样 减 恒等映射     | 逐瓦片 MAE         | -0.0067  | [-0.0076, -0.0058]    | -14.44 | 6.94e-32        | -0.93                     | 81.8               |
| 10        | 双线性重采样 减 恒等映射     | 逐瓦片 RMSE        | -0.0603  | [-0.0650, -0.0558]    | -25.40 | 2.85e-41        | -1.63                     | 97.5               |
| 10        | 双线性重采样 减 恒等映射     | 逐瓦片<br>CSI@0.05 | -0.0025  | [-0.0156,<br>+0.0104] | -0.38  | 9.26e-01        | -0.02                     | 57.4               |
| 20        | 前置模型 减 恒等映射       | 逐瓦片 MAE         | -0.0431  | [-0.0480, -0.0380]    | -16.82 | 4.29e-36        | -1.08                     | 93.8               |
| 20        | 前置模型 减 恒等映射       | 逐瓦片 RMSE        | -0.2042  | [-0.2269, -0.1816]    | -17.87 | 2.85e-39        | -1.15                     | 95.5               |
| 20        | 前置模型 减 恒等映射       | 逐瓦片<br>CSI@0.05 | +0.1653  | [+0.1507,<br>+0.1798] | +22.17 | 5.10e-40        | +1.42                     | 95.0               |
| 20        | 前置模型 减 双线性重<br>采样 | 逐瓦片 MAE         | -0.0317  | [-0.0364, -0.0270]    | -13.34 | 2.72e-32        | -0.86                     | 90.1               |
| 20        | 前置模型 减 双线性重<br>采样 | 逐瓦片 RMSE        | -0.1123  | [-0.1276, -0.0962]    | -14.02 | 6.45e-34        | -0.90                     | 86.8               |
| 20        | 前置模型 减 双线性重<br>采样 | 逐瓦片<br>CSI@0.05 | +0.1351  | [+0.1245,<br>+0.1452] | +25.76 | 2.82e-40        | +1.66                     | 95.0               |
| 20        | 双线性重采样 减 恒等映射     | 逐瓦片 MAE         | -0.0113  | [-0.0124, -0.0103]    | -20.41 | 6.03e-39        | -1.31                     | 93.4               |
| 20        | 双线性重采样 减 恒等映射     | 逐瓦片 RMSE        | -0.0918  | [-0.1002, -0.0840]    | -22.37 | 1.89e-41        | -1.44                     | 100.0              |
| 20        | 双线性重采样 减 恒等映射     | 逐瓦片<br>CSI@0.05 | +0.0302  | [+0.0162,<br>+0.0442] | +4.16  | 8.61e-05        | +0.27                     | 63.2               |
| 30        | 前置模型 减 恒等映射       | 逐瓦片 MAE         | -0.0435  | [-0.0489, -0.0384]    | -16.01 | 2.89e-39        | -1.03                     | 94.2               |
| 30        | 前置模型 减 恒等映射       | 逐瓦片 RMSE        | -0.2355  | [-0.2622, -0.2083]    | -17.28 | 6.03e-39        | -1.11                     | 95.0               |
| 30        | 前置模型 减 恒等映射       | 逐瓦片<br>CSI@0.05 | +0.1436  | [+0.1255,<br>+0.1617] | +15.66 | 1.07e-29        | +1.01                     | 87.2               |
| 30        | 前置模型 减 双线性重<br>采样 | 逐瓦片 MAE         | -0.0340  | [-0.0387, -0.0295]    | -14.42 | 1.13e-36        | -0.93                     | 90.9               |
| 30        | 前置模型 减 双线性重<br>采样 | 逐瓦片 RMSE        | -0.1272  | [-0.1438, -0.1105]    | -14.80 | 2.55e-36        | -0.95                     | 93.8               |
| 30        | 前置模型 减 双线性重<br>采样 | 逐瓦片<br>CSI@0.05 | +0.1394  | [+0.1255,<br>+0.1533] | +19.45 | 1.95e-35        | +1.25                     | 90.1               |

| 边长<br>(米) | 比较                | 指标              | 平均差<br>值 | 95% 自助法<br>置信区间       | t      | Wilcoxon<br>p 值 | Cohen's<br>d <sub>z</sub> | 未变差瓦<br>片<br>占比(%) |
|-----------|-------------------|-----------------|----------|-----------------------|--------|-----------------|---------------------------|--------------------|
| 30        | 双线性重采样 减 恒等<br>映射 | 逐瓦片 MAE         | -0.0095  | [-0.0109, -0.0082]    | -13.89 | 4.26e-37        | -0.89                     | 90.5               |
| 30        | 双线性重采样 减 恒等<br>映射 | 逐瓦片 RMSE        | -0.1083  | [-0.1192, -0.0972]    | -19.35 | 2.15e-40        | -1.24                     | 97.5               |
| 30        | 双线性重采样 减 恒等<br>映射 | 逐瓦片<br>CSI@0.05 | +0.0042  | [-0.0129,<br>+0.0205] | +0.49  | 1.00e-01        | +0.03                     | 59.5               |

表 9 给出配对检验的结果。配对单位是一块瓦片，同一块瓦片在两个方案下的同一指标相减，因此样本量是测试条带上的瓦片数。平均差值为负且指标越小越好时表示前置模型更优。置信区间来自对差值重抽样四千次的自助法，如果不跨零就认为差异稳定。t 检验与 Wilcoxon 符号秩检验同时给出，前者假设差值近似正态，后者只要求分布对称。效应量采用配对 Cohen's d 下标 z，它等于平均差值除以差值的标准差，数值在零点二、零点五与零点八附近通常被读作小、中、大。

最后一列给出差值方向未变差的瓦片占比，它回答的是改善是否普遍，而不是只看平均值。这一列的统计口径随指标方向而变。对于平均绝对误差与均方根误差，它统计差值严格为负的瓦片，也就是明确改善的瓦片。对于临界成功指数，数值越大越有利，因此它统计差值不小于零的瓦片，其中包含恰好持平的情形。五米档前置模型对恒等映射的临界成功指数一列显示 100.0，含义是没有任何一块瓦片的差值为负，也就是一块都没有变差，它与全部瓦片都获得改善并不等价。



**图 16 前置模型在测试集上的表现。** 全部结果取自南部测试条带，十米网格，测试条带在模型与轮次确定之后只读一次。子图 (a) 是逐瓦片配对散点，横轴是校正前的平均绝对误差，纵轴是校正后的平均绝对误差，单位都是米，红色虚线是两者相等的等值线。可以读出绝大多数点落在等值线下方，表示校正后误差下降，右下角落点很少，说明校正没有明显放大误差。子图 (b) 是三种场在粗网格上的淹没范围匹配度，横轴是三个阈值，纵轴是临界成功指数，灰、橙、绿三色依次对应恒等映射、双线性重采样与前置模型。可以读出前置模型在三个阈值上都高于两个基线，高阈值处的差距最大。子图 (c) 是数值误差对比，横轴是均方根误差与平均绝对误差两个指标，单位是米，颜色规则同前。可以读出前置模型的两根柱子都明显矮于基线。子图 (d) 把校正后的粗网格场用最近邻方式升采样到两米，再与两米真值比较，横轴仍是三个阈值，纵轴是临界成功指数。可以读出前置模型在五厘米与三十厘米两个阈值上仍然领先于两个基线，在一米阈值上却是恒等映射最高。这一项检验的是校正效果能否穿过升采样环节传递下去，深水处的例外见下一段。

这张图是本章的落点。前置模型在粗网格的三档阈值上都优于恒等映射与双线性重采样，把粗网格升采样到两米之后，低阈值上仍保持领先，说明误差场里确实存在可以被学到的结构。双线性重采样作为唯一的无参数基线，它只做几何平滑，能改善多少也给出了参照。把这张图与图 9 的误差空间分布放在一起看，可以理解改善的来源。误差沿河道成片分布，卷积网络的三乘三邻域正好能够利用这种局部连续性。

两米格网上的一米阈值是一个例外，需要单独说明。四档网格上，恒等映射在该阈值下的临界成功指数都高于前置模型，差值从 0.07 到 0.17 不等，网格越粗差距越大。一种可能是校正量的分配受到了训练目标的牵引。平均绝对误差按单元取平均，浅水单元在数量上占绝对多数，模型因此把主要精力用在收掉浅水区多报的淹没范围。深水单元数量很少，模型没有足够信息把它们与浅水单元分开，倾向于一并压低，深水面积于是被收得过紧。恒等映射虽然整体误差大，却完整保留了粗网格原有的深水面积，在深水判定上因此占优。这件事实质上是前文符号翻转在深水区的另一面，两者都指向同一个倾向，也就是校正量过度集中在浅水。这一现象提示后续可以按水深对损失加权，或者对深水区单独设一条保底规则，两种做法都需要重新训练与验证，此处标注为待补充。

计算规模需要交代清楚。全部训练与评估在一张四吉字节显存的移动显卡上完成，五米档的训练耗时约五分半，十米档约一分半，二十米与三十米两档各在半分钟上下，四档合计约八分钟。网络参数量只有约两万三千个，推理时对一块 480 米瓦片的耗时在毫秒量级，因此校正环节不会成为整条预报链的瓶颈。前置模型的输出仍是一套粗网格水深场，可以原样送入已经完成的超分辨率模型，本章没有对后者做任何训练、修改或重新评估。需要说明的是，本章没有把校正后的场实际接入超分辨率模型并测量端到端效果，这一步需要重新运行超分辨率推理，超出本章的数据范围，此处标注为待补充。

## 2.10 本章术语速查

这一节把本章反复使用的专有名词集中在一张表里，按大致出现的先后排列，每个词给出一句话解释。全报告范围的术语解释仍在附录一的表 21 中，两张表内容有少量重叠，本表只覆盖第二章。

**表 10 本章术语速查。**本表只集中第二章出现的专有名词，便于阅读本章时随时回查，不替代附录一的表 21。表中术语按在本章出现的先后排列。

| 术语     | 全称与解释                                                                   |
|--------|-------------------------------------------------------------------------|
| 粗网格模拟值 | 低分辨率水动力程序直接在粗网格上求解浅水方程得到的水深场，每个粗方块一个值。它是超分辨率模型实际收到的输入，误差会原样传给下游。        |
| 聚合     | 把若干细网格单元的水深按面积加权平均成一个粗方块代表值的动作。它不求解任何方程，只做平均，因此不会改变水量总量，只会抹掉方块内部的起伏。    |
| 聚合真值   | 把两米精细结果按面积平均到粗网格得到的场。它的作用是提供一个与粗网格模拟值落在同一套方块上的参照，使两者可以直接相减。             |
| 模拟项    | 粗网格模拟值减聚合真值。它衡量同一个方块上数值求解与方块形状造成的差，是本章第三笔账中的第一笔。                        |
| 聚合项    | 聚合真值减两米真值。它衡量粗化本身造成的差，也就是方块内部信息在取平均时丢掉的量，与数值方法无关。                       |
| 总误差    | 粗网格模拟值减两米真值。把模拟项与聚合项相加，中间的聚合真值相互抵消，正好得到总误差，这条恒等式在本章逐单元得到了验证。            |
| 表示误差   | 用方块形状去近似真实水面所带来的形状偏差。它与数值误差在现有数据中无法分开，本章把两者合并报告。                        |
| 数值误差   | 粗网格上的离散格式与两米网格不同所带来的偏差。网格边长改变会同时改变渠道断面与干湿判定，因此它不随网格加密而单调缩小。             |
| 交叉项    | 模拟项与聚合项在同一个像元上相乘再取平均的那一部分，数值上等于两倍的协方差。它接近零表示两类误差在同一像元上几乎没有系统的同向或反向关系。   |
| 细网格口径  | 把每个粗方块的模拟值按最近邻铺到它覆盖的两米单元上，再与两米真值逐格比较的算法。它把模型误差与地面本身的不均匀混在一起报，因此读数系统性偏高。 |
| 粗网格口径  | 把粗网格模拟值与同一方块的聚合后的二米真值比较的算法。本章的主口径，它只测模型算得准不准，不掺入方块内部的起伏。                |
| 块内方差   | 方块内各两米单元的水深偏离该方块聚合真值的平方的平均。它只由两米真值决定，与粗网格模拟值无关，属于下游超分辨率环节要补的细节，前置模型不负责。 |
| 最近邻升采样 | 把粗方块的值原样复制到该方块覆盖的每个细单元上，不给相邻方块加权。它的方块内平均被保留，升采样后再聚合回去得到原值，因此用于口径换算。     |
| 湿区     | 聚合真值超过五厘米的单元。两个相关系数只在湿区上统计，因为在干区上两份值都接近零，相关系数没有意义。                      |
| 分位数    | 一组数值从小到大排好之后按位置取到的值。百分之五到百分之九十五分位区间表示去掉两端各百分之五之后剩下的取值范围。                |
| 等值线    | 数值相等的点连成的线。散点图中用等值线标出两个网格取值完全相同的位置，落在线下方表示纵轴那一侧偏小。                      |
| 派生量    | 由已有变量直接算出来的量，例如用单宽流量的两个分量除以水深得到流速幅值。湿区占比也属于这一类，它由粗网格自身算出，不算独立的外部条件。     |
| 掩膜     | 与水深层同样大小的真假标记图，用来圈定某个指标或损失项作用的范围。水深超过阈值的单元记为真，其余记为假。                    |

| 术语     | 全称与解释                                                                                                |
|--------|------------------------------------------------------------------------------------------------------|
| 临界成功指数 | Critical Success Index，二值判定下命中数除以 命中、漏报与误报三者之和，取值零到一，越大越好。洪水事件中不积水区域占绝大多数， 若用准确率会得到虚高分， 因此改用这个指标。    |
| 结构相似度  | Structural Similarity Index，同时比较亮度、 对比度与结构的三分量指标，取值越接近一表示两幅图的观感越接近。它包含亮度项， 因此绝对值通常偏高，读的时候要与其他指标合看。   |
| 方差膨胀因子 | Variance Inflation Factor，等于一减去该变量 被其余解释变量解释的比例之后再取倒数。数值越大表示变量之间重合越多， 组内单个变量的系数 越不可信，此时只有组一级的份额可以解读。 |
| 沙普利值   | Shapley value，合作博弈论中的分配方法， 把一组变量联合起来的解释力按各参与变量的平均边际贡献分摊下去。选用它是因为它不依赖 变量进入的顺序，而逐项回归的系数会随变量的增减而剧烈变化。   |
| 恒等映射   | 不做任何校正，输出与输入完全相同。它给出校正 必要性的下限，前置模型的所有改善都相对它来读。                                                       |
| 双线性重采样 | 用双线性核把粗网格场插值到两米网格再平均回 粗网格的平滑算子，没有可学参数。它用来检验单纯的几何平滑能带来多少改善。                                           |

### 三 数据、模型与方法

#### 3.1 研究区与数据来源

研究区位于新西兰惠灵顿城区。数据使用的坐标系是新西兰横轴墨卡托 2000（New Zealand Transverse Mercator 2000，记为 NZTM2000，在空间参考系统中登记为 EPSG:2193）， 它把球面上的经纬度投影成平面直角坐标，单位是米，因此可以直接量算距离与面积。数据覆盖的范围东西宽 12960 米，南北长 23040 米。洪水场来自 HiPIMS 水动力模拟器， 这是惠灵顿地区用于洪水风险评估的一套二维水动力模型，它同样是按浅水方程推进水流的。静态地理信息来自同一套模拟的输入文件，包括地形、土地利用、河道网络等，共十五个通道。通道这个词借用了图像处理的说法，指同一个空间位置上叠放的一组数值，每个通道代表一种属性。降雨重现期有两个，分别是二十年的 20a 与一百年的 100a。重现期是水文上的频率概念， 二十年重现期表示这样的降雨平均每二十年出现一次，数值越大代表降雨越极端。五十年的降雨过程数据存在，但没有对应的洪水模拟结果，因此没有纳入使用。

#### 3.2 数据组织与切分原则

整套数据被切成边长 480 米的正方形瓦片。瓦片在这里就是数据分块的单位， 把整张大图裁成许多同样大小的小块，训练时逐块读取。这个尺寸的选择有具体的工程理由。在二米、五米、十米、二十米、三十米这五种分辨率下，480 米都能被整除，因此同一块瓦片 在所有分辨率上恰好对应一个完整的存储块，读取时不必跨块拼接，也就不会在瓦片边界上 引入人为的断层。整个区域被划分为 48 行、27 列，共 1296 块瓦片。

训练集、验证集与测试集的划分方式需要特别说明。切分按地理条带进行，条带指的是沿东西方向贯穿整幅图的横带，自北向南依次分配集合，没有采用随机抽取瓦片的做法。两种做法差别很大。随机切分会让空间上紧邻、水文上连通的瓦片分散到不同集合， 模型只要记住邻居的答案就能在验证集上取得虚高的分数。按条带切分则保证验证与测试区域 在空间上与训练区域分离，模型的泛化能力才能被真实反映。表 11 列出了各集合的瓦片数量。 为保证边界干净，条带之间还留有一条宽度为一块瓦片的缓冲区，缓冲区不参与训练也不参与评估。

**表 11 数据集合的瓦片数量与评估规模。** 中列是划分出的瓦片总数，右列是其中可用、即含有效淹没像元而被实际评估的瓦片数。缓冲区 用于隔离训练与评估区域，本身不产生任何评估结果。

| 集合  | 划分瓦片数 | 实际评估瓦片数 | 用途        |
|-----|-------|---------|-----------|
| 训练集 | 810   | —       | 参数学习      |
| 缓冲区 | 54    | —       | 空间隔离，不参与  |
| 验证集 | 162   | 182     | 模型选择与调参   |
| 测试集 | 270   | 242     | 最终复核，只读一次 |

表中评估瓦片数与划分瓦片数不同，原因在于评估时两种降雨情景分别成对读取，一个划分瓦片 可能产生多个评估样本。这一细节在比较不同报告的数字时经常造成混淆，因此在此明确。

3.3 降雨驱动与洪水场的基本形态

水深场的空间格局由降雨过程与地形共同决定，因此有必要先交代驱动条件。数据里用到的是一场 设计暴雨。设计暴雨由多年观测资料折算而来，代表某个重现期的标准雨型，并不对应历史上 真实发生过的某一场雨。数据中的降雨以每秒水深增量存储，时间步长一秒，总时长六小时。把增量累加到十分钟的区块上，可以还原出这场设计暴雨的原始形状，也就是水文学中用来描述 一场降雨时程分配的图形，称为雨型图。横轴是时间，纵轴是降雨强度，它的形状决定了洪水 过程线的形状。图 17 给出了三个重现期的雨型。




图 17 三个重现期的设计暴雨时程。两个子图共用同一个横轴，即从零到六小时的降雨历时，单位是小时。左子图 (a) 是十分钟区块的降雨强度，纵轴单位是每小时毫米。曲线画成阶梯形而不是平滑曲线，原因是原始雨型由分段常数构成，每个十分钟区块内强度保持不变，阶梯画法如实反映了这一点。右子图 (b) 是累计降雨深度随时间的变化，纵轴单位是毫米，它等于左子图曲线到当前时刻的积分面积。三条曲线的重现期分别是二十年、五十年与一百年，其中五十年只有降雨过程而没有对应的洪水模拟结果，因此用虚线区分，只作为强度参照，不参与建模。

读这张图的关键是看峰值的出现位置与两侧的上升下降方式，而不是盯住单点数值。具体的读法是，在左子图上找最高的一级台阶，看它落在横轴的哪个位置，再看它比两侧的基础段高出多少。右子图则要看曲线的斜率，斜率最大的那一段就对应左子图里强度最高的那一级。

三个重现期的雨型形状完全一致，都是先在开始阶段维持一个较低的基础强度，随后逐步抬升，在第三小时附近形成一次集中的强降雨，之后回落并进入长尾。这种形状是设计暴雨的典型形式，它的物理含义是最大淹没水深主要由第三小时前后的那次强降雨决定，而前后的降雨则决定了土壤的前期湿润程度与管网的前期充满程度。

数量上的差别体现在三个层次。总量分别为 73.2、86.4 与 96.6 毫米。峰值十分钟强度在一百年重现期下达到 136.7 毫米每小时，二十年重现期下略低。基础强度三个重现期都在 9.5 毫米每小时上下，差别很小。这个结构说明重现期的放大主要体现在峰值段，而不是均匀地放大整场降雨。对于淹没深度而言，峰值段决定了深水区的水量，基础段决定了积水范围，两者对应的模型误差特征并不相同。

序列开头有五分钟零值，末尾也有少量零值，这是降雨过程本身的边界，不是数据缺失。本报告使用的一百年与二十年两档降雨都有对应的洪水模拟结果，可以直接作为学习目标。五十年的降雨过程虽然存在，但缺少对应的洪水场，因此没有进入数据集。

把降雨条件与后文的结果对照，可以得到一个有用的判断。后文发现的深水欠估出现在一百年这样峰值更高的情景上，而不是仅出现在较小重现期。这说明深水误差不是降雨强度不足造成的，峰值段注入了足够的水量，问题出在模型没有把这些水量放到正确的位置与深度。

### 3.4 模型结构

模型名为 HydroGeo-SRNO，可以拆成三个部分理解。第一部分是水文编码器，编码器指的是把原始输入转换成一组内部表示的那部分网络。它接收粗网格水深等两个通道，用八个卷积块提取多尺度特征，通道宽度 64。卷积是图像处理中最基本的运算，它用一个小的窗口在图上滑动，把窗口内的数值加权求和，因此能捕捉局部的空间模式，比如某处的水深比周围高说明那里可能是洼地。八个卷积块让模型能同时看到从几米到上百米的不同尺度。第二部分是地理编码器，它接收十四通道连续地形变量与土地利用类型。土地利用是一个类别变量，它的取值是公园、道路、建筑一类的标签而不是数值大小，所以先通过嵌入层压成八维向量再与连续变量拼接，输出宽度 48。嵌入层的作用是把类别标签映射成一组可以参与算术运算的数值，让模型能够表达不同土地利用对水流的不同影响。第三部分是隐式算子，它是模型的核心，宽度 192，八头注意力，两层。它的作用是在连续坐标上查询任

意位置的水深。常规卷积只能在固定网格上生成结果，要改变分辨率就得重新设计网络，而这里按坐标查询的方式让模型可以直接在十米输入的基础上输出二米网格。

输出端采用残差形式。残差这个词指的是模型只预测一个在参考值基础上的修正量，而不是直接给出最终结果。具体做法是先在粗网格输入上做双三次插值得到基础场，再让模型预测一个修正量叠加其上。双三次插值是一种比双线性插值更平滑的放大方法，它用周围十六个点做三次多项式拟合。这样设计让模型只需学习被网格抹掉的细节，而不必从零构造整个水深场，训练因此更稳定。此外模型还有一个湿区分类头，用来判断每个像元是否积水，它的输出也参与损失计算。

### 3.5 损失函数与评价指标

损失函数由五项加权求和构成，权重取自配置文件。各项的分工如下。深度项权重 1.0，直接比较预测水深与真实水深，用的是 Huber 损失。Huber 损失是一种对离群值稳健的回归损失，它在误差较小时按误差的平方惩罚，超过某个转折点之后改为按误差的一次方惩罚。这样处理的原因是水深场里存在个别极端像元，纯平方损失会被这些像元主导，模型会把大量精力花在少数几个点上。湿区项权重 0.30，判断每个像元是否积水，属于分类任务，解决的是有没有水的问题。对数残差项权重 0.20，它先把水深取自然对数再比较误差，作用是让浅水区的微小水深变化获得与深水区相当的相对权重。边界项权重 0.10，约束水陆交界处的位置，因为那里是最容易出错的地方。极端项权重 0.10，目标是照看水深最大的那一部分像元。后文会说明这一项的实际效果与它的名义目标不符，这正是本报告的诊断重点之一。表面上看深度项占主导，但实际贡献取决于每一项的数值量级，图 20 会给出实测的分解结果，那里才是理解问题的入口。

评价指标分为判定类与数值类两组。判定类的核心是临界成功指数（已在 1.3 节说明），它的下标表示判定阈值。CSI@0.05 m 用的是五厘米阈值，衡量整体积水范围是否判对。CSI@1.00 m 用一米，只统计深水像元，衡量深水区判得准不准。这两个阈值下的表现经常背离，本报告的核心问题正藏在这种背离之中。数值类的指标有四个。平均绝对误差是所有像元误差绝对值的平均，单位是米，它对大误差特别敏感。均方根误差先平方再平均最后开方，因此大误差会被放大，它是判断是否存在严重错误的主要依据。峰值深度误差只看全图最深的那一个像元，衡量模型能否抓住最极端的深度。体积相对误差把整个区域的积水量加总后再比较，衡量模型是否保住了总水量。这四个指标各有侧重，前两个看普遍水平，后两个看极端与总量。


### 3.6 计算条件

全部训练与评估在单块 NVIDIA GeForce GTX 950M 上完成，显存 4 GB。显存是显卡上用来存放模型参数与中间计算结果的专用内存，它的容量决定了模型一次能处理多少数据。这一限制带来两个具体约束。第一，批大小只能设为 1。批大小指的是一次前向计算同时处理多少个样本，把它设为 1 意味着每次只处理一块瓦片，无法通过并行处理多块来提高速度。第二，半精度浮点运算在这个显卡的架构上不稳定。半精度浮点用十六位二进制表示一个数，比常用的三十二位单精度省一半内存与带宽，但表示范围也更窄，在这款较旧的架构上会产生非数值结果，也就是运算结果变成无效值，因此全程使用单精度。这也意味着任何一次实验都必须串行执行，不同配置之间不能同时占用显卡。报告中所有涉及多组配置的比较，都是依次运行得到的，运行时长在后续章节中逐项说明。

## 四 研究过程

### 4.1 阶段一 基线训练及其饱和

基线模型按配置训练三百轮次，实际在第一百八十轮次被主动停止。轮次是训练的基本单位，一个轮次指模型把训练集里的全部样本完整看一遍，每看完一遍就更新一次参数，并在验证集上算一次指标。验证集是从训练数据中划出、不参与参数更新的一部分，它的用途是观察模型在没见过的数据上表现如何，因此可以用它的指标来判断该在哪一轮停下来。停止的理由是模型在约第九十八轮次之后不再改善。图 18 给出了训练过程中的验证集指标变化。



**图 18 基线模型的训练曲线与饱和现象。**横轴是训练轮次，也就是模型把训练集完整看过多少遍。这张图用了左右两个纵轴，读的时候必须先确认曲线对应哪一根轴，否则会把两条线的交叉误读成某种关系。左纵轴是验证集上 0.05 米阈值下的临界成功指数，蓝色实线对应此轴，看的是模型判对积水范围的能力。右纵轴是训练损失，橙色细线对应此轴，看的是模型在训练数据上的错误数值。灰色点线标在第一百轮次，红色虚线标在第一百五十五轮次，也就是验证指标最高、被选为最佳权重的那一轮。

读这张图要先看两条线的形状，再看它们的相对位置。蓝色曲线在前五十轮次快速上升，这是模型学习地形与水流基本关系的阶段。大约到第九十轮次，上升速度明显放缓。到第一百轮次之后，曲线在一个很窄的区间内来回摆动，看不出向上的趋势。橙色损失曲线一直在缓慢下降，但下降幅度越来越小，最后几十轮次几乎水平。

两条线在后期出现方向上的分离。损失还在降，验证指标却不再涨，说明模型正在优化的方向与淹没制图的质量发生了偏离，它在降低目标的数值，而这个数值已经不再反映制图质量。这种情况通常意味着损失函数与评价指标之间存在偏差，模型找到了降低损失但对提升指标没有帮助的方向。这一线索在下一阶段被追查到底，并最终指向深水问题。

用固定的一批瓦片在第一百轮次、第一百五十五轮次等几个检查点上逐一比较，验证指标的变化全部落在噪声范围内。也就是说，从第九十八轮到第一百八十轮的八十多个轮次里，模型没有取得任何可靠的进步。继续训练只会消耗时间，因此训练在一百八十轮次被停止，此时的权重被保留为后续工作的起点。

## 4.2 阶段二 深水误差的根因诊断

诊断从两个方向同时进行。一个方向是把误差按真实水深分层，看偏差随深度如何变化。另一个方向是直接测量损失函数各项在真实数据上的数值，看目标函数到底在优化什么。图 19 是第一个方向的诊断工具，图 20 是第二个方向的结果，两者相互印证，指向同一处缺陷。





图 19 按真实水深分层的误差结构（从头训练的对照组）。这张图是把一个总体的误差数字拆成十一段来看。两个子图共享横轴，即真实水深的十一个区间，从零到 0.05 米一直延伸到三米以上，区间按深度递增排列，因此横轴从左向右代表水越来越深。左子图 (a) 是平均偏差，也就是预测值减真值的平均值，柱子向上表示高估，向下表示低估，柱子的长度就是偏差的绝对大小。右子图 (b) 是平均绝对误差，用折线表示，它先把误差取绝对值再求平均，因此只看错多少，不看错的方向。两个子图放在同一张图上，是为了把方向与幅度分开看，这是判断误差性质的基本方法。

先看左子图。横轴从左向右代表水越来越深。最左侧最浅的区间，蓝色柱子略微向上，说明模型在几乎不积水的地方稍稍高估，这是可以接受的。往右走，柱子逐渐转为向下，并且越往右越长。在一至一点五米的区间，柱子已经明显向下。到三米以上的区间，向下的长度达到最大。整条柱形序列呈现出单调向下的趋势，画成曲线就是一路走低。这个形状本身就是结论。模型对水深的低估带有明确的方向性，随着深度增加稳定增强，属于系统性偏差。

再看右子图。平均绝对误差随深度单调上升，这是自然的，因为水深越大，可允许的绝对误差本应越大。值得关注的是上升的速度。最浅区间误差不到 0.02 米，到三米以上已经超过 2.5 米。深水区的误差量级是浅水区的一百倍以上。这说明模型对待深浅两种情形的方式极不对称。浅水判得很准，深水几乎失控。

把两个子图放在一起读，可以得到一个明确判断。如果误差主要来自随机性，那么偏差应该在零附近上下摆动，绝对误差上升而偏差不上升。实际观察到的是偏差与绝对误差同向上升，说明误差的主要成分是系统性低估，随机噪声只占次要位置。既然是系统性的，就说明模型在某个环节被系统性地引导到了错误方向，而最可能的引导者就是损失函数。



**图 20 损失函数的实测分解。** 这张图的目的是回答一个看起来简单、实际很容易被忽略的问题，就是训练时模型到底在优化什么。左子图 (a) 是五项损失的加权贡献，即每项的原始数值乘以它在配置文件里的权重，纵轴是贡献的数值大小。右子图 (b) 把同一组数字换成百分比，每一项除以总损失，纵轴就是该项占总目标的份额，五项相加等于百分之百。两个子图描述的是同一组数据，左图看绝对量级，右图看相对结构。数据取自冻结的基线权重上真实批次的实测结果，配置文件里的权重只是名义值，两者可能相差很远，这也是为什么必须实测而不能只读配置。

这张图解释了前面那个疑问，也就是为什么损失在降而指标不涨。看左子图，五项贡献的高度差别很大。按物理直觉，最该被信任的深度项，权重虽然设为 1.0，实际贡献只有 0.0695。而极端项权重只有 0.10，贡献却有 0.0657，几乎与之持平。右子图把这个关系说得更清楚。深度项占 34.3%，极端项占 32.4%，对数残差项占 15.8%，边界项占 15.3%，湿区项只占 2.3%。

配置文件里的权重与实测的占比相差如此之大，原因在于各项的原始数值本身量级不同。深度项的原始值只有 0.07 左右，而极端项高达 0.66，相差近十倍。权重只是在这个基础上再乘一次，无法扭转量级上的差距。这提醒我们，看损失函数的构成不能只看权重表，必须看加权后的实际贡献。

更深一层的问题出在对数变换上。深度项与对数残差项都在对数空间计算，也就是先把水深取对数再算误差。对数变换的好处是让浅水区的微小变化获得足够权重，但代价是压低了深水区的绝对差异。举一个具体的例子。真实水深五米、预测三米，绝对误差两米，在水深九米处出现同样的两米误差，这两个误差在对数空间中对应的代价分别只有实际米数的 0.17 倍与 0.10 倍。也就是说，越深的地方，两米的错误越不值钱。模型要降低损失，最省力的办法就是把深水压低，因为这样既降低了深度项，又不影响浅水区已经很好的表现。

再看极端项。它是在线性尺度上计算的，本来应该能够约束深水，问题在于它的掩膜范围。掩膜的定义是每个瓦片内水深超过该瓦片自身 95 分位数的像元。多数瓦片的大部分面积是干的或不积水的，这样的瓦片里第九十五分位数对应的水深往往只有 0.19 米左右。于是这一项的掩膜在多数瓦片上覆盖的其实是浅水，深水很少进入它的视野。更麻烦的是这个阈值随瓦片变化，一个瓦片与另一个瓦片之间没有一致性，模型无法从中形成稳定的深水约束。

两处缺陷叠加的结果，就是深水在整个目标函数中几乎没有可靠的代表。深度项因对数变换而对深水不敏感，极端项名义上覆盖尾部却常常落在浅水，其余各项与深水无关。模型在深水区表现糟糕，问题出在训练目标本身。网络容量是充裕的，只是目标没有要求它做好。

### 4.3 阶段三 从头训练的深水损失对比


针对上述诊断，损失函数新增一个深水项，记为  $l_{\text{deep}}$ 。设计要点有三条。第一，它在米空间中计算，直接以实际水深的差异为惩罚，不再经过对数变换，这样深水区的两米误差就实实在在值两米，不会被压缩。第二，用掩膜圈定生效范围。掩膜是逐像元的开关，取值为一时该项参与计算，取值为零时该项被忽略，它的作用是把损失限制在关心的那一部分像元上。这里的掩膜由真实水深阈值定义，默认取一米，确保覆盖尾部。如果某瓦片中没有超过一米的水深，则退化为对该瓦片湿区深度的分位数。分位数

是排序后按位置取值的概念，例如九十分位数表示有九成样本比它小，用它可以把掩膜门槛按瓦片自身的水深水平来设定，避免在浅水瓦片上掩膜落空、整项失去作用。第三，使用 Huber 形式并把转折点设在五米，使常见误差区间保持线性惩罚，同时限制极端离群值的影响。

为了隔离这一项的作用，实验设计成两臂对照。对照臂把权重设为零，即完全恢复原有损失，记为 D0。实验臂把权重设为 0.5，记为 D2。两臂的随机种子、网络结构、数据顺序、学习率计划与训练轮次完全相同，唯一差别就是这一项的权重。随机种子是初始化模型参数时用的随机数起点，固定它可以保证两次运行从同一个起点出发，否则参数初始化的随机差异会混进比较结果里。学习率计划指学习率随训练轮次变化的安排，它决定了每一步参数调整的步长。这些设置全部固定之后，两臂的差别才能被干净地归因到深水项权重上。每臂训练四十轮次。

实测的训练成本是每轮次 13.2 分钟，两臂共八十轮次，合计约十七点六小时。这个数字需要说明清楚，因为项目早期曾把每臂四十轮次误算成总共五小时，理由是混淆了单臂轮次与总轮次。实际计时取自每轮次记录的时间戳。

结果显示，深水项确实起了作用，方向也对，代价却很大。图 21 给出了对比结果。



**图 21** 从头训练时深水权重的收益与代价。横轴分成两组指标。左侧一组是深水指标，也就是一米阈值下的临界成功指数，衡量深水范围判得准不准。右侧一组是整体指标，也就是五厘米阈值下的临界成功指数，衡量全部积水范围判得准不准。每组内左柱是权重为零的对照臂，右柱是权重为 0.5 的实验臂。这里说的对照臂指的是除了被考察的那一个变量之外，其余设置与实验臂完全相同的参照组，它的作用是提供一个基准，让实验臂的变化可以被归因到那一个变量上。柱子上的箭头与数字标注了两臂之间的差，向上代表实验臂更好，向下代表更差。两组柱子必须一起看，因为它们的走向相反，这正说明深水与整体之间存在取舍关系。

先看左组。深水指标从 0.149 升到 0.171，绝对提升 0.022，相对提升 14.7%。这是全项目第一个真正推动深水阈值指标上升的改动，说明前面的诊断是准确的，深水项的设计方向也对。需要留意的是，这一提升来自阈值判定，后面按水深分层的诊断会说明它在数值层面意味着什么。

再看右组。整体指标从 0.490 降到 0.447，下降 0.043，相对下降 8.7%。这个下降幅度是前面深水提升的两倍还多。在洪水制图里，整体指标代表积水范围的判定质量，它的明显退化会直接损害模型在常规制图任务中的可用性。一个只在最深处变准、却在大片区域变差的结果，对实际使用没有价值。

收益与代价的对比非常不对称。深水指标提升了 0.022，整体指标却掉了 0.043。换一个说法，为了在最深的两万个像元上取得一点进步，代价是三百万个浅水像元上的明显退步。这种交换在工程上不可接受。

原因可以在损失占比里找到。权重设为 0.5 时，在从头训练的模型上实测到的深水项占目标函数百分之五十九。单一项就吃掉了将近六成权重，其他四项的梯度被严重稀释。前面已经知道，浅水区占了 86% 的像元面积，这些像元主要靠深度项与湿区项约束。当这两项的梯度被深水项淹没，浅水区就失去了有效监督，误差迅速上升。这与阶段二诊断出的对数空间缺陷指向同一处根源，都是权重分配失衡，深水项这个概念本身是成立的，问题出在给的力度上。

按预先设定的规则，实验臂需要在整体指标不低于对照臂 0.01 的范围内，才有资格被采纳。实验臂低了 0.043，远超允许范围，因此被否决。这里有一个容易被误读的地方。规则的执行记录里写着一句话，说没有实验臂在深水指标上超过对照臂。这句话在字面上会让人以为深水项没有效果。实际上深水项确实提升了深水指标，只是因为整体指标上被否决，剩下的合格臂只剩对照臂，比较退化成了自己与自己比。真正的深水数据在上表中，阅读时必须结合规则的执行过程才能理解。

#### 4.4 阶段四 冻结模型的温和微调

从头训练失败后，策略发生转向。既然整体精度退化来自权重过大，一个自然的想法是把权重 调小。但在动手之前需要先算清楚，多小的权重才算小。这一步不能靠直觉，原因在于深水项在 不同模型上的原始数值差别很大。从头训练的模型深水误差相对较小，深水项原始值约 0.52。冻结的基线模型因为已经带有两米的深水偏差，同样的深水项原始值高达 1.57，是前者的三倍。

这意味着同一个权重数字在两种模型上代表完全不同的强度。表 12 列出了冻结模型上不同 权重对应的占比，这是决定权重的依据。

**表 12 深水项权重在冻结基线模型上的实际占比。** 第二列是加权后的深水项数值，第三列是它在总目标中的百分比。对照阶段三的实验臂可以看到， 权重 0.5 在从头训练时占 59%，在冻结模型上会占到 79.5%。权重 0.25 看似是 0.5 的一半， 实际占比 65.9%，仍高于从头训练实验臂的水平。

| 深水项权重 | 加权数值   | 占总目标比例 | 评价         |
|-------|--------|--------|------------|
| 0.00  | 0.0000 | 0%     | 对照，不含深水项   |
| 0.05  | 0.0784 | 27.9%  | 与深度项、极端项相当 |
| 0.10  | 0.1568 | 43.6%  | 明显但未压倒其他项  |
| 0.20  | 0.3137 | 60.7%  | 已超过从头训练实验臂 |
| 0.25  | 0.3921 | 65.9%  | 并非温和折半     |
| 0.50  | 0.7842 | 79.5%  | 极度失衡       |

表中一行数字推翻了原计划。原计划打算用 0.25，理由是"0.5 的一半"。但实测显示 0.25 的 占比达到 65.9%，仍然高于阶段三失败实验臂的 59%，复制同样的缺陷只是时间问题。真正温和的 区间是 0.05 到 0.10，两者占比分别为 27.9% 与 43.6%。因此微调实验采用这两个权重，并额外 训练一个权重为零的微调对照臂。

对照臂的作用需要单独说明。它是从同一个冻结权重出发、用同样的学习率与轮次微调 二十轮，唯一的差别是把深水项权重设为零。有了它，比较才是成对的。如果只拿微调后的模型 与微调前的模型比，任何改善都可能来自多训练了二十轮，与深水项没有关系。有了对照臂， 两者的差别被精确地限制在深水项这一项上。这是本报告在方法上做的第一处关键修正。

微调的另一个前提是让优化真正起作用。这里存在两个技术陷阱，都被实测发现并修正。第一， 训练脚本的轮次参数是绝对编号，恢复训练时余弦学习率计划会被快进。从第一百八十轮恢复并 指定第二百零轮，学习率只剩下约 2.7 乘十的负六次方，模型几乎不动。修正办法是新增一个参数， 按需要的轮数重建余弦计划，并令总轮次等于起点加轮数减一。第二，优化器的状态恢复会覆盖 新设置的学习率，因为存档里保存着旧值。修正办法是在载入之后重新施加学习率。两处修正都 在真实权重上验证过，日志中可见学习率被正确重置到十的负四次方，训练区间正确落在 第一百八十一到第二百零轮。

4.5 阶段五 两处测量陷阱与修正

这一阶段没有改动模型，改动的是测量方式。两处陷阱对结论的影响不低于模型本身，因此单独 成节。

第一处 把成功当成了失败

两个微调实验臂在一夜之间先后完成了全部二十轮训练，产出了完整的权重与逐轮记录，但 实验管理脚本把它们标记成了失败并中止了流程。追查后发现原因是退出码。训练脚本在 本机上一贯返回 120，即使完全成功也是如此，原因是解释器在退出时输出了一句关于输出流 刷新的警告，Python 把这句警告转换成了非零状态码。关键在于，此前所有被认可的实验臂 返回的都是同一个 120，包括阶段三的两个实验臂。也就是说，脚本的判据把本机上的正常 退出误当成了崩溃。


危害有两层。直接后果是两个已经完成的实验臂会被重新训练一遍，白白占用显卡约八点八 小时。更隐蔽的后果是，脚本在报错时写的是"拒绝从崩溃的运行中得出科学结论"，语气上很 恰当，实际却是在否定一个真实完成的实验。这与项目早期的一次事故方向相反。那次是把崩溃 当成了结论，这次是把结论当成了崩溃。

修正的办法是彻底放弃用退出码判断成败，改为检查训练器自身的产物。判断依据有三条，日志 中必须出现训练结束的标记，逐轮记录文件必须非空，权重文件必须已经写出。三条同时满足 才算完成。改用产物判断之后，即使退出码非零，只要产物齐全就记为成功。反过来，如果训练器中途崩溃，产物必然残缺，仍会被正确识别。已完成的实验臂按这套标准复核后恢复了状态。

## 第二处 在噪声中挑选了最大值

这一处更关键，它直接关系到深水改善这个结论是否成立。训练过程中，每轮结束后会在一个 六十批次的验证子集上计算深水指标，并把指标最高的那一轮保存为深水最优权重。批次指的是一次前向计算里打包在一起处理的一组瓦片，六十个批次大致相当于验证集的一小部分。问题在于这个子集的规模。深水像元在全图中本就稀少，六十批次里能覆盖到的深水样本更少，指标的统计波动因此很大。这里说的测量基线，指的就是用哪一批数据、多大的范围来给出 这个指标数字。

验证这个判断无需额外实验，因为权重为零的对照臂本身就是最好的证据。对照臂按定义不含 深水项，不可能从深水损失中获益，它的深水指标变化应当全部来自噪声。如果连它都在波动，那么用同样方式测出来的实验臂结果也就不可信。实测结果中，这个臂的深水指标在二十轮之间 从 0.141 波动到 0.171，极差达到 0.030。图 22 把这一现象画了出来。



**图 22 同一实验臂在两种测量基线下的表现差异。** 这张图的用意是把测量范围本身的影响单独暴露出来。左子图 (a) 画的是权重为零的对照臂。横轴是微调轮次，从第一轮到第二十轮。纵轴是深水指标。灰色折线来自训练时使用的六十批次子集，蓝色折线来自全部一百八十二个验证瓦片。两条线用的是同一个模型、同一批权重，差别只在测量范围，因此任何差异都只能归因于测量方式。淡灰色带标示子集折线的波动区间。右子图 (b) 换了一个视角，横轴仍是轮次，纵轴是实验臂相对对照臂的深水指标增益，也就是把左子图里两条线代表的两种做法各自算出的差值直接画出来。增益为正表示实验臂在这一轮比对照臂好，为负则相反。灰色对应子集基线，蓝色对应全验证集基线。

先读左子图。灰色折线上下跳动的幅度很大，最高与最低之间相差 0.030。蓝色折线明显平稳得多，波动幅度不到灰色线的一半。两者用同一批权重，差别只来自测量范围。这说明子集基线确实引入了额外波动，而且波动幅度不小。图上还有一个细节可以佐证，两条线的整体高度接近，说明子集基线的偏差主要是随机性的，没有表现出系统性。这一点很重要，它意味着两个基线在大样本下会收敛到同一个答案，但在小样本下会给出互相矛盾的挑选结果。

再看右子图。灰色折线是子集基线算出的增益，蓝色折线是全验证集基线算出的增益。灰色线在零附近剧烈摆动，有时为正有时为负，看不出稳定方向。蓝色线则大部分时间位于零以上，并且有一个稳定的小幅正值。两条线的对比把问题的性质说清楚了。用子集基线看，实验臂与对照臂的差别被噪声淹没。换成全验证集基线，差别才浮现出来。

后果可以用数字直接说明。对照臂在子集上的最好成绩是 0.171，而两个实验臂的最好成绩分别是 0.1737 与 0.1736，领先幅度只有 0.0026，约等于对照臂自身波动标准差的一半。在一个波动标准差为零点零零五的指标上，从二十个轮次中取最大值，得到的数值本身就会比真实水平高出约一点五个标准差。也就是说，实验臂相对对照臂的这点领先，完全可以用挑选行为解释，不必假设深水项起了作用。

这里有一个容易让人掉进去的陷阱，值得单独提醒。如果只在子集基线上比较，而且只用“挑最大值”这一个动作，得到的结论是“深水项没有效果”。这个结论与阶段三的真实结果矛盾，却与子集数据吻合。相反，如果不做任何挑选，直接读最后一个轮次，得到的结论又可能偏向“深水项有效”。两种读法都在同一个小样本上打转，谁也说服不了谁。真正的出路是换一个足够大的测量基线。

修正做法是把训练期间保存的每一个轮次的权重都拿出来，在全部一百八十二个验证瓦片上重新评估。这样挑选仍然取最大值，但最大值不再建立在噪声之上。整个工作评估了三个实验臂各二十个轮次，共六十次全量评估，每次约两点四分钟，总计约两点四小时。选择标准也在这一基线上重新执行。这是本报告在方法上的第二处关键修正，也是深水结论能否成立的关键。

## 4.6 阶段六 延长训练与当前状态

微调确认有效之后，一个自然的问题是改善能否随训练延续下去、能否进一步扩大。为回答这个问题，从被选中的最优权重出发再训练二十轮，同时按同样的安排训练一个匹配的对照臂。匹配的含义是两个臂从同一个父权重出发，其余设置完全相同，只有深水项权重不同。

父权重的选择需要说明。被选中的最优轮次是第一百八十七轮，而训练结束时最后一个轮次是 第二百轮。延长训练从第一百八十七轮出发，没有采用最后一个轮次。原因是第二百轮并非被选中的轮次，从它出发会重新引入刚刚排除的挑选偏差。两个臂各训练二十轮，单臂约四点四小时，训练已于 9 月 29 日 0 时 48 分结束，权重与逐轮记录均已产出。

延长训练已经评估完毕，结论是改善没有继续扩大。深水对照臂在第一百九十一轮达到 深度桶 CSI 零点一九五，被选中的基线臂在第一百九十二轮达到零点一九五，两者都低于 第一阶段选出的第一百八十七轮的零点一九八。也就是说再训练二十轮之后，最好的轮次 仍然不如原来那一轮。

更该留意的是那个深水权重为零的对照臂。它在延长训练中从零点一八八升到零点一九五，涨幅与带深水项的臂基本相同。这说明第二十轮的涨幅主要来自训练的继续，而不是深水项的作用。把这条曲线与阶段四的结论放在一起，两处证据指向同一件事，在本数据集上，深水项带来的增益量级很小，与轮次之间自然波动的量级相当，延长训练并不会把它放大。


这一阶段的评估沿用与阶段四完全相同的全量流程，因此两组结果可以直接比较。本报告的主要结论不依赖这一阶段，它回答的是另一个问题，也就是深水改善能否随训练区间的延长而继续扩大。答案是不能。

## 五 结果

---

### 5.1 逐瓦片的空间重构对比

到这里为止，误差一直以数字的形式出现。数字说明量级，却不说明误差长在什么地方。洪水是一个空间现象，读者真正关心的是水在哪里、有多深、模型把它放到了哪里。这一节把结果摊回地图上，先看整个测试区域的格局，再放大到单个瓦片看细节。图 23 给出测试集上 两百四十二块瓦片的空间格局与逐格性能，图 24 取深水像元最多的那一格做八面板的逐格解剖，图 25 再取三格跨越不同淹没程度的瓦片做横向对照。三张图看下来，从整体到局部、从最严重的一格到不同类型的一格，误差长在哪里就有了一幅完整的图像。




**图 23 测试集的空间格局与逐瓦片性能。** 这张图回答的是误差长在哪里。五个子图共用同一套网格，横向二十七列自西向东，纵向四十八行自北向南，每一格是一个四百八十米见方的瓦片，网格的留白处表示该瓦片没有可评估的淹没像元。(a) 每格的最大真值水深，采用百分位截断以避免个别极值压低对比度。(b) 每格中水深超过一米的像元个数，它是判断该格是否属于深水区的依据。(c) 与 (d) 分别是冻结基线与微调模型在每格上的深水判定指标，取值范围为零到一，数值越高表示该格的深水范围越准确。(e) 是两者的差值，红色表示微调更好，蓝色表示更差。读法是先看 (a) 与 (b) 确定深水在哪里，再把 (c) 与 (d) 对照着看哪里的判定质量差，最后用 (e) 检查改善是否集中在问题最严重的位置。三个层次对应三个问题，也就是水在哪里、哪里判得差、改好了没有。

读这套图要按顺序看。先看 (a) 与 (b)，它们描述的是洪水本身的地理分布。深水并没有均匀铺满整个研究区，而是集中在中部偏东的一片区域，那里是城区低洼地带与沿河通道，两百四十二个瓦片中有两百二十八个的最大水深超过一米，两百零三个超过两米，但真正贡献深水像元的只是其中一部分。这一点在后面会反复出现，它决定了误差的分布形状。

再看 (c) 与 (d)。深水判定指标高的瓦片与 (b) 中深水像元多的瓦片并不完全重合，这说明深水像元多的地方并不自动容易判对。有两类瓦片特别值得注意。一类是深水像元很少的瓦片，模型只要整体偏浅一点就会把整个深水类判空，指标直接落到零，这样的瓦片冻结基线有四十个，微调后有三十七个。另一类是深水像元多但地形复杂的瓦片，模型能抓到范围却抓不准深度，指标停在零点二到零点三之间。

最后看 (e)。改善在空间上是有结构的，不是随机撒开。红色的格子大多落在 (b) 里深水像元较密的那一带，也就是问题最严重的地方改善最明显。反过来，浅水格子里的颜色接近白色，说明改动在那些地方几乎没有作用。逐瓦片统计显示，改善超过零点零一个指标单位的瓦片有九十七个，变差超过同样幅度的只有三十个，其余一百一十五个落在两者之间。改善的方向明确，幅度却不大，这个特征与后文的高阶统计结果一致。

Deepest urban-flood test tile 100a iy=42 ix=10 peak truth 4.07 m 7,908 pixels above 1 m  
MAE over wet pixels frozen 0.672 m fine-tuned 0.666 m | CSI@1.00 m frozen 0.201 fine-tuned 0.189 | 45.4% of pixels improved




**图 24** 测试集中深水像元最多的瓦片，八面板逐格对比。该瓦片属于百年重现期情景，位于网格第四十二行第十列，真值峰值四点零七米，水深超过一米的像元有七千九百零八个。上排四个面板依次是地形高程、十米粗分辨率输入、两米真值以及冻结基线的预测。下排依次是微调后的预测、冻结基线的绝对误差、微调后的绝对误差，以及微调相对冻结基线的误差削减量。误差削减面板中红色表示微调在这一格把误差改小了，蓝色表示改大了，颜色标尺对称于零。所有深度面板共用同一套色标与量程，可以直接横向比较。

这套图最值得看的是上排第二个与第三个面板的关系。十米输入只给出一个粗网格，放大五倍之后是一片平滑的色块，完全看不到河道与街道的细节。两米真值则显示出清晰的结构，右下方有一条深槽，深度接近峰值，周围是深度递减的浅水区，再外侧是干地。模型要做的事情就是在只有粗网格和地形信息的条件下，把这条深槽的位置与深度恢复出来。

比较上排第四个面板与下排第一个面板。两个预测都恢复出了深槽的大致位置，形状也接近真值，肉眼很难立刻分出高下。这正是这道题的困难所在。模型已经抓住了主要结构，剩下的差别藏在数值里而不是形状里。把两个预测与真值相减，得到下排中间两个绝对误差面板，差别才显现出来。两张误差图的亮区位置基本相同，都沿着深槽边缘和水陆交界处分布，说明误差的来源是同一个，也就是地形陡变处的深度梯度没有被完整重建。

下排最右侧的削减面板把差别单独抽了出来。红色区域集中在深槽内部，蓝色区域散布在浅水与干地的交界带。这个分布有两层含义。在深槽内部，微调把误差压得更低，这是想要的效果。在交界带，微调略微推高了误差，代价被限制在很小的量级。逐像元统计显示，这一格上有百分之四十五点四的像元误差变小，百分之四十七点五变大，净效果是平均绝对误差从零点六七二米降到零点六六六米，深水判定指标从零点二零一降到零点一八九。指标在这格上反而略降，提醒我们单格抽样的波动足以盖过真实效应，判断必须靠全量配对统计。

还要注意一个容易被忽略的细节。这一格深水区的平均真值是一点六四二米，冻结基线的平均预测只有零点五九九米，平均偏差约负一点零四三米，也就是说深槽内的水深被系统性削掉了六成左右。微调之后深水区的平均预测升到零点六零一米，偏差几乎没有变化。这说明深水欠估不是个别格子的偶然现象，它是模型在整个深水区间上的一致行为，也正是本报告要解决的核心问题。需要指出的是，这一格已经是被选中微调的权重作用最强的场景，改善仍然如此有限，可见问题的顽固程度。



**图 25** 三个瓦片跨越淹没程度区间的对比。这张图的用意是检验改善是否与积水程度有关。三行按积水程度由深到浅排列，由上到下分别是深水城市瓦片、中等淹没瓦片与浅水瓦片，这样排列便于纵向追寻同一列在图上的变化。每一行从左到右依次是十米粗输入、双线性插值、冻结基线预测、微调后预测以及两米真值。读法是先看最右一列的真值，记住该瓦片的实际水深格局，再回到左边看各方法重建得如何。十米输入与双线性插值两列的作用是给出不做学习的下限，用于判断模型是否真的学到了结构。每一行单独设定色标量程，因此在同一行内比较颜色是有效的，跨行比较颜色深浅则没有意义，这一点与得分卡的限制相同。行首标注该瓦片的湿区平均绝对误差在冻结与微调两个模型下的数值，读者可以直接读出这一格的误差变化，不必从颜色估算。

三个瓦片放在一起看，可以回答一个关键问题，也就是改善究竟出现在什么条件下。

第一行是前面详细分析过的深水瓦片，湿区平均绝对误差从零点六七二米降到零点六六六米，深水像元接近八千个。第二行是二十年重现期的中等淹没瓦片，误差从零点一八五米微升到零点一八八米，深水判定指标从零点三八三升到零点三九七，峰值深度误差却从零点二二二米恶化到零点四九七米。第三行是最浅的一个，误差从零点零九七米升到零点一零五米，深水判定指标从零点三九三升到零点四二二，峰值深度误差从零点八三二米降到零点二五七米。

把这九个数放在一起，可以得到两条规律。第一条是关于平均绝对误差的。它在深水瓦片上下降，在另外两个瓦片上小幅上升，幅度都在千分之几米。出现这种分化的原因是深水项把优化压力挪到了深水像元上，浅水像元因此失去了部分注意力。第二条是关于峰值深度误差的。它在这个瓦片上升、在那个瓦片下降，方向完全不一致，因为在十万像素里它只由最深的那一个决定。这两条规律正好解释了报告前面为什么反复强调峰值深度误差不可作为主要论据。

真正稳定的信号是深水判定指标。它在第二行与第三行上都上升，说明微调确实把深水范围的边界推得更准了，而这两行的深水像元数分别是七百六十六与一百三十七，都远小于第一行。换句话说，改善在深水像元多与少的瓦片上都出现了，它不依赖于某一类特定的积水格局。

第三行的数字还有一个用处，它可以校准读者的直觉。这一格的深水像元只有一百三十七个，占总有效像元的比例不到千分之三，但它决定了深水判定指标的全部取值。模型在这一格上的深水平均偏差从负零点二零一米收敛到负零点零一四米，几乎完全消除。少数像元可以支配一个指标，这个现象在报告中出现过多次，是理解所有深水指标时必须记住的前提。

**表 13 逐瓦片的直接对比（测试集代表性瓦片）。**瓦片按真值峰值水深从第 10 百分位取到最大，覆盖从浅水到最深的完整区间。CSI 列为该瓦片自身的判定指标，体积误差为该瓦片的总水量相对偏差。倒数第二列是微调模型相对冻结基线的深水增益，正值表示改善。单个瓦片的指标波动较大，这里看的是改善是否在全区间上一致出现。


| 瓦片                      | 真值峰值<br>(m) | 湿区占比<br>(%) | 基线<br>CSI@0.05 | 微调<br>CSI@0.05 | 基线<br>CSI@1.00 | 微调<br>CSI@1.00 | 深水<br>增益 | 基线<br>体积误差 | 微调<br>体积误差 | 体积<br>增益 |
|-------------------------|-------------|-------------|----------------|----------------|----------------|----------------|----------|------------|------------|----------|
| ['20a'] iy=40<br>ix=7   | 1.32        | 4.0         | 0.690          | 0.689          | 0.667          | 0.667          | +0.000   | 0.031      | 0.038      | -0.008   |
| ['20a'] iy=39<br>ix=17  | 3.62        | 25.3        | 0.487          | 0.483          | 0.000          | 0.000          | +0.000   | 0.151      | 0.171      | -0.021   |
| ['20a'] iy=43<br>ix=13  | 4.49        | 11.5        | 0.618          | 0.631          | 0.082          | 0.126          | +0.044   | 0.284      | 0.204      | +0.080   |
| ['100a'] iy=43<br>ix=12 | 5.44        | 10.5        | 0.494          | 0.492          | 0.021          | 0.055          | +0.034   | 0.266      | 0.179      | +0.087   |
| ['20a'] iy=44<br>ix=7   | 6.40        | 4.5         | 0.573          | 0.586          | 0.457          | 0.462          | +0.005   | 0.182      | 0.089      | +0.093   |
| ['100a'] iy=38<br>ix=10 | 9.35        | 26.2        | 0.486          | 0.472          | 0.188          | 0.194          | +0.007   | 0.620      | 0.627      | -0.006   |
| ['100a'] iy=38<br>ix=6  | 23.67       | 19.1        | 0.702          | 0.708          | 0.895          | 0.896          | +0.001   | 0.023      | 0.006      | +0.016   |

表 13 把代表性瓦片的逐格数值列在一起。它的作用是让前面三张图的读数可以逐行核对，本身不提供新的结论。表中瓦片按真值峰值水深从第十百分位取到最大值，覆盖从浅到深的完整区间。看这张表时应该注意列的对应关系，深水增益列是微调相对冻结基线的差值，正值表示改善。多数行是正值，少数行是负值，负值的幅度普遍小于正值，这与逐瓦片配对的整体结论吻合。

5.2 点对点一致性与偏差结构

空间图给出的是位置的印象，散点图给出的是数值的关系。这一节把所有测试像元两两配对，直接画出预测值与真值的关系，用来观察模型在数值轴上偏向哪一侧。图 26 给出全测试集的点对点一致性，上排看整体关系，下排看偏差随水深的变化。

Point-wise agreement on the full test split



**图 26 全测试集的点点对一致性。** 这张图回答的是预测与真值在数值上对不对得上。上排是预测水深与真值水深的二维密度图，横轴是真值，纵轴是预测，颜色深浅表示落在该处的像元数，采用对数标度以便同时显示密集区与稀疏区，白色虚线是一比一参考线，点落在这条线上表示预测与真值相等，落在下方表示预测偏浅。红色点线标出一米位置，用来圈定深水区段。左下角文本框给出深水像元个数以及该区间上预测与真值的均值，可以直接读出偏差的量级。下排是偏差结构图，横轴是预测与真值的平均，纵轴是预测减真值，这类图用来判断偏差是否随水深变化。红色实线是平均偏差，两条黑色虚线是一点九六倍标准差给出的界限，黑色实线在零处。读法是先在上排看密度带相对对角线的位置，再在下排看漏斗是否张开。

上排两个面板的读法是把颜色当作频次。整幅图呈现出一条沿对角线的密集带，说明预测与真值总体上是同步的，模型没有把水深关系搞反。密度带在低水深一侧特别宽，在高水深一侧收窄并且明显偏向对角线下方。这个形状就是深水欠估的直接证据。水深越大，预测越容易落在真值下方。

红色点线与白色虚线的交点是判断整体水平的位置。在交点上，两个模型的表现几乎一样，都是略微偏低。真正拉开差别的地方是一米以上的区域。把该区域的像元单独统计，冻结基线的平均预测是一点四四七米，真值平均是二点三五零米，平均偏差负零点九零三米，百分之八十四的像元被低估。微调之后平均预测升到一点五一七米，偏差收窄到负零点八三三米，低估比例降到百分之八十一。二。改善是真实的，但离消除还差得很远。如果把水深按体积加权，冻结基线的总水量比真值少百分之二十二点九六，微调后少百分之二十点三四。

还有一个结构值得单独指出。在图的下部，预测值出现了若干条水平方向的密集带，这些带跨越了很宽的真值范围，意味着模型把一些本该有深度的像元统一压到了几个固定的低值上。这类带是插值基底与门控机制共同作用的结果，粗网格经过固定倍率放大后本身带有阶梯状取值，模型没有完全把这些阶梯抹平。它们的绝对量级很小，对平均指标的影响有限，但它解释了为什么浅水区的误差分布会出现尖锐的峰。

下排两个面板把偏差随水深的变化摊开。理想情况下所有点应该聚集在横轴上，实际呈现为一个向左下倾斜的漏斗。左侧窄而平，说明浅水区的偏差小且稳定。右侧逐渐散开，说明深水区的偏差既大又不定。这个漏斗在微调之后略微收窄，尤其是最右侧发散的部分，但形状没有改变。

两个面板的统计量可以直接比较。冻结基线的平均偏差是负零点零一六四米，标准差零点一八八六米，微调的对应数值是负零点零一四五米与零点一八八二米。偏差缩小了约零点零零二米，离散度几乎不变。这个对比说明微调做的事情是整体上把水位抬了一点，而不是重新分配了误差的结构。百分之四十六点七的像元绝对误差变小，百分之四十九点一变大，其余持平。逐像元层面接近五五开，而整体指标改善，差别来自那些误差最大的深水像元。

这里需要提前说明一个尺度问题，它贯穿后面的所有分析。水深超过一米的像元只占总像元的百分之一二，但它们承载了全部水量的百分之四十点四。这意味着两个几乎相反的结论可以同时成立。在像元数量上，深水几乎是可忽略的少数，而在水量的意义上，深水是决定性的多数。所有以像元平均为基础的指标都被浅水区主导，所有与水量相关的指标都被深水区主导。报告后面反复出现的"指标之间方向不一致"的现象，根源就在这里。

### 5.3 基线水平与超分辨率增益

在进入深水问题之前，先给出模型与两种传统插值方法的整体对比，作为后续所有讨论的背景基线。图 27 汇总了验证集与测试集上的三组指标。




图 27 模型与两种传统插值方法的指标对比。左子图 (a) 是验证集，右子图 (b) 是测试集，两个子图的结构完全一致，可以左右对照着读。每组内三根柱子依次是模型、双线性插值与最近邻插值，柱子的颜色区分方法。纵轴是临界成功指数，取值在零到一之间，越高越好。横轴是三档判定阈值，从左到右依次升高，阈值越高表示判定积水的门槛越严。柱顶数字是具体取值。这张图的作用是给出一个背景基线，回答学习模型相比不做学习的插值方法到底好多少，好在哪个阈值上，以及这个优势是否在不同数据集合上稳定。

先看整体模式。在验证集与测试集、三个阈值组成的全部六种组合上，模型的柱子都是最高的，说明学习模型相对传统方法有稳定优势。这个优势在 0.05 米阈值下最大，验证集上模型 0.539，双线性 0.314，最近邻 0.305，模型的领先幅度超过 0.22，相对提升约七成。这个幅度说明模型确实学到了地形与水流的对应关系，已经超出平滑插值的水平。

再看阈值的走向。三个阈值从左到右依次升高，所有方法的柱子都在下降。这是意料之中的，阈值越高，判定越严格，命中越困难。更该注意的是下降的速度。模型从 0.539 降到 0.169，降幅超过三倍。双线性从 0.314 降到 0.109，降幅约三倍。两者的相对降幅接近，但模型的绝对水平始终更高。这说明模型在深水区同样领先传统方法，深水问题出在模型自身，与插值方法的对比无关，是模型自己也做得不够好。

比较左右两个子图还能看到一个稳定的规律，测试集的指标普遍高于验证集。模型在测试集上 0.05 米阈值为 0.599，高于验证集的 0.539。造成差异的原因在于两个集合的地理构成不同，测试集覆盖的区域积水更连片、更容易判别。这一点在跨报告比较数字时必须注意。

## 5.4 深水分桶诊断

阶段二已经说明，深水误差是系统性的。这一节给出更细的数值，并用它作为后续改动的衡量基准。表 14 列出了从头训练对照臂在十一个水深区间上的误差结构。

**表 14 按真实水深分层的误差结构（验证集，对照臂）。**第二列是该区间的像元数，用于判断各区间在统计上的权重。第三、四列是平均绝对误差与均方根误差。第五列是平均偏差，负值表示低估。最后一列是被低估的像元比例。

| 水深区间（米）    | 像元数       | 平均绝对误差 | 均方根误差 | 平均偏差   | 低估比例  |
|------------|-----------|--------|-------|--------|-------|
| 0 – 0.05   | 8 847 913 | 0.0135 | 0.058 | +0.008 | 7.3%  |
| 0.05 – 0.1 | 468 001   | 0.0744 | 0.166 | +0.033 | 48.9% |
| 0.1 – 0.2  | 303 884   | 0.1266 | 0.219 | +0.029 | 56.0% |
| 0.2 – 0.3  | 147 053   | 0.1877 | 0.276 | –0.019 | 64.2% |
| 0.3 – 0.5  | 185 304   | 0.2683 | 0.341 | –0.117 | 73.2% |
| 0.5 – 0.75 | 144 928   | 0.3772 | 0.446 | –0.267 | 81.6% |
| 0.75 – 1.0 | 78 968    | 0.5284 | 0.620 | –0.422 | 85.5% |
| 1.0 – 1.5  | 70 164    | 0.8451 | 0.948 | –0.750 | 90.3% |
| 1.5 – 2.0  | 40 045    | 1.0927 | 1.249 | –1.013 | 91.9% |
| 2.0 – 3.0  | 33 074    | 1.5366 | 1.783 | –1.358 | 90.1% |
| 3.0 以上     | 21 322    | 2.5811 | 3.013 | –1.755 | 75.0% |

这张表的读法可以从三个角度切入。第一个角度是像元数的分布，它决定了各区间在整体指标中的实际权重。最浅区间有 884 万个像元，占全部有效像元的 86%。深水几个区间加起来只有 16 万个像元，占比不到 2%。这个悬殊的比例解释了后面所有的取舍难题。整体指标由绝大多数浅水像元决定，而深水改善只影响极少数像元，两者的代价无法等量齐观。

第二个角度是偏差的符号变化。从最浅区间到 0.1 至 0.2 米区间，偏差为正，模型略微高估。从 0.2 米开始转负，此后一路加剧。到三米以上，平均偏差达到负 1.755 米。符号的转折点出现在 0.2 米附近，这个位置大致对应损失函数中极端项掩膜的典型阈值 0.19 米。这一对应关系与前面的诊断相互印证。掩膜覆盖到的地方监督有效，掩膜之外的地方监督薄弱，误差就集中在监督薄弱的一侧。这个对应关系是诊断阶段的一个有力旁证。

第三个角度是最右侧的低估比例。这一列的走势并不单调，前几行逐行上升，到 1.5 至 2 米区间达到 91.9%，之后反而下降到 75%。最后的下降容易被误读为深水区反而好些了。实际原因是三米以上的像元中有一部分是河道，河道里的水深本身变化剧烈，模型偶尔给出高估，拉低了低估比例，但偏差的绝对值仍然是所有区间中最大的。看这类比例指标时，必须与偏差的绝对值一起读，单看比例会得出相反的印象。

### 5.5 从头训练的权利衡代价

阶段三已经说明，从头训练时把深水权重设为 0.5，深水指标提升 0.022，整体指标下降 0.043，因超出精度护栏而被否决。这里补充充分桶层面的证据，看改善究竟发生在哪些区间。

**表 15 两种权重下各水深区间的误差对比（全量验证集，182 块瓦片）。**两个臂都取各自被选中的检查点，因此两列在同一基准上。左半部分是权重为零的对照臂，右半部分是权重 0.5 的实验臂。第四列是平均绝对误差的变化百分比，负值表示误差减小。

| 水深区间（米）    | 对照臂 平均绝对误差 | 实验臂 平均绝对误差 | 变化    | 对照臂 偏差 | 实验臂 偏差 |
|------------|------------|------------|-------|--------|--------|
| 0 – 0.05   | 0.0135     | 0.0253     | +88%  | +0.008 | +0.020 |
| 0.05 – 0.1 | 0.0744     | 0.0832     | +12%  | +0.033 | +0.038 |
| 0.1 – 0.2  | 0.1266     | 0.1425     | +13%  | +0.029 | +0.023 |
| 0.2 – 0.3  | 0.1877     | 0.2226     | +19%  | –0.019 | –0.034 |
| 0.3 – 0.5  | 0.2683     | 0.3261     | +22%  | –0.117 | –0.147 |
| 0.5 – 0.75 | 0.3772     | 0.4776     | +27%  | –0.267 | –0.306 |
| 0.75 – 1.0 | 0.5284     | 0.6257     | +18%  | –0.422 | –0.438 |
| 1.0 – 1.5  | 0.8451     | 0.8597     | +1.7% | –0.750 | –0.655 |
| 1.5 – 2.0  | 1.0927     | 1.0499     | –3.9% | –1.013 | –0.897 |
| 2.0 – 3.0  | 1.5366     | 1.4493     | –5.7% | –1.358 | –1.290 |
| 3.0 以上     | 2.5811     | 2.7091     | +5.0% | –1.755 | –2.426 |
| 一米以上合计     | 1.2691     | 1.2640     | –0.4% | –1.066 | –1.071 |
| 全部像元合计     | 0.0556     | 0.0702     | +26%  | —      | —      |


这张表给出的结果比预期复杂，需要逐段读。先看一米以下的部分。从最浅区间到一米，七行全部恶化，幅度从 12% 到 88% 不等。最浅区间接近翻倍，从 0.0135 涨到 0.0253。这个区间占了 86% 的像元，它的恶化直接拖垮了整体指标。深水项的梯度确实溢出了它的设计范围。

一米以上四个区间的表现并不一致。1.5 至 2.0 米与 2.0 至 3.0 米两行改善，误差分别下降 3.9% 与 5.7%，偏差也相应收窄。1.0 至 1.5 米一行基本持平，误差略升 1.7%。最深的一行反而恶化，误差上升 5.0%。把四行按像元数加权合并，一米以上的平均绝对误差从 1.2691 变到 1.2640，只下降 0.4%。

这张表与聚合指标之间有一处落差，需要专门解释。聚合指标显示这个实验臂的深水判定有明显进步，深水指标从 0.1487 升到 0.1707，峰值深度误差从 2.661 米降到 1.881 米。可是按水深分层的数值误差几乎没有变化。两个结果都是真的，它们衡量的是深水的不同侧面。深水指标与峰值误差属于阈值型和极值型统计，只要更多深水像元被推过一米这条线，或者最坏的那一个像元被拉回来，它们就会改善。分层误差衡量每个像元的数值偏差，它要求全部深水像元整体变准。这个实验臂做到的是前者。

### 5.6 微调的配对结果

这一节给出本报告的核心结果。三个实验臂从同一个冻结权重出发，各训练二十轮，逐轮在 全部一百八十二个验证瓦片上评估。因为三臂在每个轮次上是匹配条件，同轮次相减得到的是 配对差值，不受挑选偏差影响。图 28 把三条轨迹画在一起。



**图 28** 三个微调实验臂在全验证集上的逐轮表现。三个子图共享横轴，即微调轮次，从第一百八十一轮到第二百轮，共二十个点，每点是一次全量评估的结果。左子图 (a) 是深水指标，也就是一米阈值下的临界成功指数。中子图 (b) 是整体指标，也就是五厘米阈值下的临界成功指数。右子图 (c) 是体积相对误差，衡量全图总水量的相对偏差，数值越小越好。三个子图中，灰色圆点是权重为零的对照臂，蓝色方块是权重 0.05 的实验臂，红色三角是权重 0.10 的实验臂。两条虚线是冻结基线在对应指标上的水平，作为参考，用来判断微调之后的模型相对微调之前处在什么位置。读这张图的方法是先看同一条线自己的走势，判断训练是否稳定。再在同一个轮次上比较三条线，判断深水项是否带来层次。最后看三个子图的层次是否一致，判断改善与代价的关系。

左子图是全部证据中最关键的一张。三条轨迹的分布呈现出清晰的层次。灰色对照臂整体最低，并且有几次比较深的下探。蓝色与红色两条线整体位于灰线之上，其中红色线在大部分轮次上又略高于蓝色线。三者之间有大量重叠，单看某一个轮次无法区分，但把二十个轮次一起看，层次的稳定性就显现出来。这正是配对比较相对单点比较的价值所在。

左子图还有一个容易被忽略的细节需要点出。红色线的起点在中段，随后上升，然后在后半段维持在一个较高的水平。也就是说，深水改善分布在整段训练的中间与后半段，未依赖末端的偶然高位。即便完全不挑选，直接读最后一个轮次，红色线仍然高于灰色线。排除挑选行为的检验是结论稳健性的最好证明。

中子图展示了代价的大小。三条线几乎完全交织在一起，看不出系统的层次。灰色、蓝色、红色的摆动幅度相当，中心位置也接近。这说明深水项对整体精度几乎没有影响，与阶段三中整体指标下降 0.043 形成了鲜明对照。同一项改动，在从头训练时造成严重退化，在微调条件下却几乎不动摇整体精度。两相对照，可以确认问题的确出在权重强度的分配上。

右子图是体积相对误差，三条线同样呈现层次，红蓝两线整体位于灰线之下。体积误差衡量的是全图总水量的相对偏差，它对深水像元的绝对误差特别敏感，因为深水像元贡献了绝大部分水量。这一指标的改善说明深水的数值修正是有实际意义的，不只是指标上的数字变化。

## 5.7 统计检验与效应量

视觉上的分层需要统计量来确认。因为每个轮次上的比较都是配对的，可以使用配对  $t$  检验。配对指的是两个被比较的对象共享同一个外部条件，此处就是同一个训练轮次上的深水臂与对照臂，它们的差别只来自深水项。把同一轮次的差值先算出来再检验这些差值是否显著不为零，可以消掉轮次之间共同的波动，因此比把两组数直接比较更灵敏。二十个轮次给出十九个自由度。自由度可以理解为参与估计的独立信息量，它决定临界值的大小。双侧百分之九十五置信水平下，十九个自由度对应的  $t$  临界值是 2.09，也就是说  $t$  统计量的绝对值超过 2.09 才被认为在统计上显著。置信区间给出的是真实效应可能落在的范围，如果这个范围不跨越零，就说明改善的方向是可靠的。同时用自助法重抽样两万次估计置信区间，作为对正态假设的稳健性检验。自助法的做法是把现有样本有放回地重新抽取很多次，每次算一个统计量，用这许多个统计量的分布来近似统计量的真实分布，它不依赖数据服从正态分布这个前提。结果汇总于表 16。

表 16 的配对单位是训练轮次，回答的是在这个训练窗口内，带深水项的臂是否系统性地优于不带深水项的臂。这是一个关于训练过程的问题。它不能回答另一个更贴近实际使用的问题，就是把两个最终要部署的权重放在测试集上逐瓦片比较，改善是否

依然可靠。后一个问题需要另一套配对设计，也就是把瓦片当作配对单位，因为最终部署时关心的是 每一块地面上的表现，而不是第几轮训练。图 29 与随后的说明处理的就是这个问题。




图 29 逐瓦片配对差值的自助法抽样分布。四个子图 (a) 至 (d) 分别对应深水判定指标、整体判定指标、体积相对误差与峰值深度误差。这里把配对单位换成了瓦片，也就是拿同一块地面在两个模型上的表现相比，两百四十二块测试瓦片因此给出两百四十二对数值。横轴是两个模型在这批瓦片上的平均差值，所有指标都已统一符号，正值表示微调更好，负值表示更差，这样四个子图的方向可以放在一起看。柱状图是对瓦片有放回地重新抽样两万次得到的均值分布，它刻画的是这个平均差值在换一批瓦片时会有多大波动。深色曲线是均值与标准差相同的正态分布，用来检查自助分布在有限样本下是否仍然接近正态，两者贴合说明用正态区间不会失真。黑色实线在零处，红色实线是实测均值，两条虚线夹出的范围是自助法给出的百分之九十五置信区间。各子图左上角的文本框给出统计量、置信区间与配对样本量。

读这张图有三步。先看红色实线相对零的位置，判断改善的方向。再看两条虚线是否把零夹在中间，如果夹住了，说明这个改善在统计上无法与没有变化区分开。最后看柱状分布的宽度，它代表估计的不确定性，宽度越窄说明结论越稳。

四个子图给出的结论可以分为两组。

第一组是深水判定指标与体积相对误差。深水判定指标的平均差值为正零点零一三七，统计量四点五九，置信区间为零点零零七九到零点零一九六，不跨零。体积相对误差换算到“正值表示更好”的符号之后，平均改善零点零二二六，统计量七点二一，是所有指标中最稳健的一个。这两个结果说明，在测试集上逐瓦片比较，微调对深水与水量指标的改善在统计上可靠，而且不是由少数瓦片带动的，因为自助分布的宽度不足以让区间触及零。

第二组是整体判定指标与峰值深度误差。整体判定指标的平均改善只有零点零零一三，统计量二点二二，置信区间为零点零零零二到零点零零二五。区间虽然不跨零，但宽度已经超过均值本身，说明这个改善的边缘性。峰值深度误差的平均改善零点零六八七米，统计量二点六九，置信区间从零点零一八三到零点一一八三，宽度约为改善量的一点五倍。换个说法，这个指标的真实效应量可能在零点零二到零点一二米之间的任何一个位置。这两项的结论都是“方向为正，但证据薄弱”。

把四个子图放在一起读，可以得到一个比单一显著性判断更有用的结论。改善的可靠性随指标与深水问题的关联程度单调变化，直接度量深水的指标最可靠，度量水量的次之，度量整体判定质量的再次之，由单个像元决定的指标最弱。这个排序与 5.4 节按

水深分桶的结论、5.6 节按指标分组的结论完全一致， 三条独立的分析路径指向同一个答案。

正态近似曲线与自助柱状图的贴合程度也值得看一眼。四个子图中两者都贴合良好， 说明即便误差分布本身具有厚尾， 均值的抽样分布仍然由中心极限定理主导， 用正态区间不会失真。这一点在图 33 显示厚尾之后需要确认， 否则配对检验的 置信区间会站不住脚。

**表 16 配对检验结果（二十个轮次）。** 第二列是实验臂相对对照臂的平均差值。第三列是配对t统计量， 绝对值超过 2.09 即在百分之九十五水平上显著。第四列是自助法给出的百分之九十五置信区间。第五列是科恩效应量， 衡量 差值相对于其自身波动的倍数。第六列是二十个轮次中实验臂更优的轮次数。


| 指标        | 实验臂     | 平均差值     | t 统计量 | 置信区间               | 效应量   | 更优轮次    |
|-----------|---------|----------|-------|--------------------|-------|---------|
| 深水指标      | 权重 0.05 | +0.0064  | +4.85 | [+0.0039, +0.0089] | 1.08  | 18 / 20 |
| 深水指标      | 权重 0.10 | +0.0082  | +5.72 | [+0.0054, +0.0108] | 1.28  | 17 / 20 |
| 整体指标      | 权重 0.05 | +0.00004 | +0.08 | [-0.0010, +0.0012] | 0.02  | 9 / 20  |
| 整体指标      | 权重 0.10 | -0.0006  | -0.85 | [-0.0020, +0.0006] | -0.19 | 10 / 20 |
| 均方根误差（湿区） | 权重 0.10 | -0.0042  | -8.23 | [-0.0052, -0.0032] | -1.84 | 19 / 20 |
| 峰值深度误差    | 权重 0.10 | -0.033   | -2.10 | [-0.061, -0.003]   | -0.47 | 15 / 20 |
| 体积相对误差    | 权重 0.05 | -0.0142  | -4.56 | [-0.020, -0.008]   | -1.02 | 19 / 20 |
| 体积相对误差    | 权重 0.10 | -0.0199  | -8.14 | [-0.024, -0.015]   | -1.82 | 18 / 20 |

表的读法可以按行分组。前两行是核心结论， 两个实验臂在深水指标上分别领先 0.0064 与 0.0082， t 统计量为 4.85 与 5.72， 都远超临界值。效应量分别为 1.08 与 1.28， 按通常的 标准属于大效应。这两个数字的含义是， 平均改善幅度超过改善量自身标准差的一倍， 改善相当稳定， 没有依赖少数极端轮次。

第三、四行是对照。整体指标的平均差值分别是正 0.00004 与负 0.0006， t 统计量 0.08 与 负 0.85， 都远小于临界值。置信区间横跨零。这两个数字的含义是， 深水项对整体精度的影响 在当前样本量下无法与零区分。这与阶段三的情形形成直接对照， 那时整体指标的下降 是 0.043， 大约是这里的七十倍， 且方向明确。

后四行表明改善不止出现在深水指标上。均方根误差下降 0.0042， 体积误差下降 0.0199， 两者的 t 统计量都在负八附近， 效应量超过 1.8， 属于强效应。这两个指标直接反映水深的 数值准确度。它们同时改善， 说明深水的修正没有以牺牲其他区域的数值准确度为代价， 反而 带来了轻微的连带收益。

最后一行需要谨慎对待。峰值深度误差衡量的是全图最深一处像元的误差， 权重 0.10 时 t 统计量负 2.10， 刚好超过临界值， 属于边际显著。这个指标由单个像元决定， 对少数极端 情况极其敏感， 项目早期曾两次因为它而得出过强的结论。因此这里仅记录其改善方向， 不作为 主要论据。图 30 用森林图把所有配对结果放在同一尺度上展示。



**图 30 配对变化的森林图。**森林图是把许多组比较浓缩到一张图上的做法，它把每组的估计值与不确定范围并排画出来，便于一次性判断哪些结论稳、哪些不稳。纵轴按指标分组，每一行是一个指标与权重的组合。横轴是相对对照臂的配对平均变化，所有指标都已统一符号，正值表示改善。黑色圆点是平均差值，横线是百分之九十五置信区间，竖线在零处，表示无变化。横线越长说明估计越不确定，圆点落在竖线哪一侧说明改善的方向。标记号表示置信区间不跨零，即在统计上显著。这张图在本报告中的作用是把分散在多个表格里的统计结论一次摊开，让读者能够横向比较各项改动的可靠程度。

森林图的读法是从下往上看位置，再看横线是否与竖线相交。横线不与竖线相交，说明改善在统计上可靠。相交则说明无法排除零变化。

先看横线的位置分布。深水指标两行、均方根误差两行、体积误差两行的圆点都明显位于零右侧，这是正向改善。整体指标两行的圆点紧贴竖线，几乎落在零上。这一分布直观地印证了前文的判断，改动的作用集中在深水及其相关的水量指标上，对整体判定质量没有可测量的影响。

再看横线的长度。深水指标两行的横线较短，说明配对差值的波动小，估计精度高。峰值深度误差一行的横线最长，跨越了相当大的范围，虽然圆点位于零右侧，但估计的不确定性明显更高。横线的长度与指标的稳定性直接相关，峰值误差由单个像元决定，天然波动大，这也是它不适合作为主要论据的原因。

最后看效应的量级。横轴的单位是原始指标单位，不同指标的量级不同，不能直接比较长度。深水指标的变化在 0.006 到 0.008 之间，均方根误差在 0.004 左右，体积误差在 0.02 左右。要判断相对大小，需要结合各指标自身的水平，也就是前表中的平均值。表 17 给出相对变化，是更适合横向比较的形式。

**表 17 最优微调权重相对冻结基线的相对变化。**正值表示改善，负值表示退化，单位是百分比。验证集与测试集分别列出。整体指标一行是唯一 出现轻微下降的指标，下降幅度不到百分之一。

| 指标              | 验证集    | 测试集     | 方向       |
|-----------------|--------|---------|----------|
| 深水指标 CSI@1.00 m | +7.66% | +8.16%  | 两个集合一致改善 |
| 峰值深度误差          | +4.45% | +12.64% | 改善       |
| 体积相对误差          | +8.22% | +11.84% | 改善       |
| 均方根误差（湿区）       | +1.20% | +1.85%  | 轻微改善     |
| 整体指标 CSI@0.05 m | +0.08% | -0.86%  | 基本不变     |
| 中间指标 CSI@0.30 m | -0.25% | +0.54%  | 基本不变     |

这张表把结论压缩成六行。深水指标在两个集合上分别提升 7.66% 与 8.16%，方向一致，幅度 接近。体积误差提升 8.22% 与 11.84%。整体指标的变化在正负百分之一以内，属于测量噪声的 范围。全部六行没有任何一项出现方向相反的显著变化，这是结论稳健的重要标志。

5.8 测试集复核

到目前为止的所有选择都建立在验证集上。验证集被反复用于比较，存在过拟合到该集合的风险。测试集提供了一次独立检验的机会。按预先设定的规则，测试集只在最终选定模型后读取一次， 读取的值不用于任何后续调整。表 18 给出了完整结果。

**表 18 冻结基线与最优微调模型在测试集上的完整对比。**测试集含二百四十二块瓦片，其地理区域与验证集完全分离。加粗表示改善的项目。单位说明， 误差类指标单位为米，体积误差为无量纲相对值。

| 指标              | 冻结基线          | 微调模型          | 变化      |
|-----------------|---------------|---------------|---------|
| 深水指标 CSI@1.00 m | 0.2547        | <b>0.2754</b> | +8.16%  |
| 中间指标 CSI@0.30 m | 0.4666        | <b>0.4691</b> | +0.54%  |
| 整体指标 CSI@0.05 m | <b>0.5987</b> | 0.5936        | -0.86%  |
| 峰值深度误差          | 1.614         | <b>1.410</b>  | +12.64% |
| 体积相对误差          | 0.1944        | <b>0.1714</b> | +11.84% |
| 均方根误差（湿区）       | 0.3986        | <b>0.3913</b> | +1.85%  |

表 18 最重要的信息是一致性。验证集上观察到的每一项改善，在测试集上都得到了复现，方向 相同，幅度相当甚至更大。深水指标提升 8.16%，与验证集的 7.66% 非常接近。峰值深度误差 从 1.614 米降到 1.410 米，改善 0.204 米，比验证集上的幅度更大。体 积误差改善 11.84%。一个在验证集上挑出来的模型能在独立区域上复现全部改善，说明改善来自深水项本身的机制，可以排除对 验证集地理特点的过拟合。

唯一下降的是整体指标，幅度 0.86%。这个幅度小于测试集上同类指标的常见波动， 且与验证集 上正 0.08% 的结果方向相反。两处合起来看，整体指标应当被理解为"没有变化"，可以排除"轻度退化"。图 31 把冻结基线与微调模型的四个关键指标并排给出，两个 集合分别展示。




图 31 冻结基线与微调模型的逐项对比。这张图的用意是把改动前后放在一起，让读者一眼看清哪几项动了、哪几项没动。左子图 (a) 是验证集，右子图 (b) 是测试集，两个子图的结构完全一致，可以左右对照。每组内左柱是冻结基线，也就是微调之前的模型，右柱是微调之后的模型。四个指标依次是深水指标、峰值深度误差、体积相对误差与湿区均方根误差。读这张图要先分清方向，深水指标越大越好，后三项越小越好，因此后三项的柱高降低才代表改善。柱间的文字标出该项是变好还是变差，不确定方向时可以依赖这个标注。两个子图都给出是为了确认改善能在独立区域上复现，这一点在第 5.8 节有专门讨论。

读这张图要分两步，先看每根柱子旁边的判定文字，再看两根柱子的高度差。判定文字已经把方向信息标出，可以快速浏览整体模式。高度差则给出改善的幅度。

先看左子图，也就是验证集。四组柱子中有三组标着改善，分别是深水指标、峰值深度误差与体积误差。深水指标的提升幅度最大，从 0.184 升到 0.198。峰值深度误差从 2.32 米降到 2.22 米，体积误差从 0.287 降到 0.263。均方根误差一组未在图上标注判定文字，因为它的改善幅度最小，但从数值可以看出从 0.513 降到 0.507。

再看右子图，也就是测试集。模式与左子图基本一致，三组改善指标的柱高变化方向相同。差别在于幅度。测试集上峰值深度误差的下降更明显，从 1.614 米降到 1.410 米，降幅接近 0.2 米，比验证集上的 0.10 米更大。体积误差的降幅也更大。这种“测试集上改善更大”的模式说明微调带来的修正具有普遍性，可以排除针对验证集地理特点的适配。

四组柱子的整体印象是，改善集中在与深水直接相关的三项上，而整体指标并未出现在图上，因为它的变化接近于零。这张图与表 18 给出的是同一组数据，形式不同，可以互相印证。




图 32 四个模型在验证集上的指标得分卡。得分卡是把多个模型在多个指标上的取值排成一张表，再用颜色标出每个模型在同一列中的相对位置。纵轴是四个模型，从上到下依次是双线性插值、最近邻插值、冻结基线与微调后模型，这样排列是为了让不做学习的方法在上、学习模型在下，便于对照。横轴是六个指标，前三列依次是 0.05 米、0.30 米与 1.00 米三档阈值下的临界成功指数，后三列依次是湿区均方根误差、峰值深度误差与体积相对误差这三个数值指标。格内数字是原始取值，读者可以直接读到具体数值，不必从颜色反推。颜色表示该模型在该列内的相对位置，绿色靠近该列最好的一端，红色靠近最差的一端。这里要特别注意颜色的比较范围只限同一列，跨列比较颜色没有意义，因为不同指标的量纲与优劣方向并不相同。

这张卡片要按列读，不要按行读。颜色只在同一列内部有含义，它是四个模型在该列上的相对位置，与指标的绝对水平无关。因此判断一个模型是否全面领先，要看它在多少列上落在绿色一端，而不是看某一格的颜色深浅。


先看列内的分布。三列临界成功指数的绿色都落在最下一行，也就是微调模型所在的行。这说明微调模型在全部三档阈值下都取得了四者中的最好成绩。需要特别指出最右侧那一列，也就是 1.00 米阈值对应的列，微调模型的颜色是最深的，因为在这一列上它对冻结基线的领先幅度最大。三个数值误差列的绿色同样在最下一行，说明微调模型在数值准确度上也全面领先。

再看冻结基线一行。它的颜色在前几列偏中间偏黄，说明它优于两种插值方法但不如微调模型。这个分布与图 27 的结论一致。最上面一行是双线性插值，它的颜色在大多数列偏红，但在峰值深度误差一列上偏绿。这是一个反直觉但合理现象，插值方法产生的水深场比较平滑，不会出现极端的单点错误，因此峰值误差较小。它的代价是整体误差很大，这一点在均方根误差与体积误差两列上表现为最深的红色。

这张卡片的实用价值在于它把四个模型的优劣关系压缩到一屏之内，便于快速核对结论。它也提示了峰值深度误差这一指标的特殊性。插值方法在这一项上并不差，说明该指标单独使用时容易误导，必须与整体误差指标联合解读。

## 5.9 高阶统计分析与阈值敏感性

前几节的指标都是一阶或二阶统计量，也就是均值、偏差与方差。这些量描述误差的平均水平与离散程度，却对误差的分布形状不敏感。洪水风险评估真正关心的往往是尾部，也就是出现大误差的频率有多高、方向偏向哪一侧。判断这一点需要第三与第四阶矩，以及整个分布的形状。这一节把误差当作一个分布来处理，再从分布回到地理空间与阈值。



**图 33 重构误差的分布与高阶矩。**这一组子图把误差当成一个分布来考察，关注的是它的形状而不只是平均值。(a) 是两个模型误差的频次分布，横轴采用对称对数标度以便同时展示零附近的密集区与两侧的长尾，纵轴为对数标度。(b) 是误差的经验累积分布，横轴是误差取值，纵轴表示误差不超过给定值的像元占比，曲线越陡说明误差越集中，曲线在某一侧拖长说明该侧出现大误差的机会更多。(c) 是分位数对分位数图。它的做法是把实测误差与一个标准差相同的正态分布按同样的累积概率逐点配对，如果误差服从正态分布，所有点就会落在黑色虚线上，散点偏离该线越远说明尾部越重。(d) 是分水深区间的偏度与超额峰度，峰度用对数纵轴，偏度用右侧纵轴，最浅的两个区间因为真值接近零、分布退化，未纳入该子图。读的顺序是先看 (a) 判断整体形状，再看 (b) 定位大误差出现在哪一侧，然后用 (c) 检验尾部是否偏离正态，最后用 (d) 看不同水深上的形状差异。

先看 (a)。误差分布以零为中心，两侧对称地衰减，整体形状接近拉普拉斯分布而不是正态分布，也就是中心有一个尖峰、两侧有较厚的肩部。两个模型的曲线几乎完全重合，只有右侧尾部有细微差别。这个重合本身就是一个重要结论，微调没有改变误差的总体分布形状，它只挪动了分布的少量质量。

再看 (b)。累积分布曲线在零点附近的斜率最大，说明绝大多数像元的误差确实很小。两条曲线在整个误差范围内都贴得很近，只有在负侧的中段能够看到微调曲线略微偏右，对应深水区的欠估被减轻。左端尾部两条曲线几乎重合，说明最严重的低估情形没有被消除。把 (a) 与 (b) 对照可以看出一个量级关系，误差小于零点零五米的像元占了绝大多数，而误差超过一米的像元占比极小，但正是这些像元决定了深水问题的全部内容。

(c) 回答的是尾重问题。如果误差服从正态分布，散点应当落在黑色虚线上。实际散点呈现明显的反向弯曲，负侧的弯曲幅度远大于正侧。曲线的斜率在负侧随分位数增大而持续变大，这正是厚左尾的几何特征。这个形状的含义很直接。深水欠估在分布结构中稳定存在，并不属于偶发的离群事件，用正态假设去推断置信区间会严重低估风险。

(d) 把高阶矩按水深拆开。偏度在水深零点一米到三米的区间都是正值且随水深递减，说明误差分布右偏，也就是高估的尾部更长。这个结果看起来与前面的欠估结论矛盾，实际不然。欠估是偏差的符号，偏度是分布形状，两者可以同时成立。多数深水像

元被低估，少数被大幅高估，平均值因此仍然偏负，而分布的右侧却拖得更长。到了三米以上，偏度转为负值，说明极深水体处的误差由欠估主导，右侧尾部消失。超额峰度在所有区间都远大于零，在最浅的深水区间达到数百，意味着极端误差出现得远比正态分布频繁。随水深增加，峰度快速下降，到三米以上只剩个数，说明浅水区的误差重尾更突出。

两个模型在 (d) 上的曲线形状基本相同，只在最深的区间有可见分离。这再次说明微调的作用是有限的位移，而不是分布结构的重塑。这一点与阶段三的失败形成呼应。如果只靠加大损失权重来推动深水，模型会优先改变分布的整体位置，进而伤害浅水区，而分布本身的形状是由数据与网络容量决定的，无法靠权重调整。

**表 19 误差的高阶矩按水深分层（全测试集）。**偏度衡量误差分布的不对称程度，正值表示分布右侧拖尾更长，即高估的极端情形更多。超额峰度衡量尾部的厚重程度，正态分布的取值为零，正值越大说明极端误差出现得越频繁。低估比例为误差为负的像元占比。两列平均绝对误差的对比可以看到微调在哪些区间改变了误差量级。

| 水深区间（米）  | 像元数        | 基线<br>MAE | 微调<br>MAE | 基线<br>低估% | 微调<br>低估% | 基线<br>偏度 | 微调<br>偏度 | 基线<br>超额峰度 | 微调<br>超额峰度 |
|----------|------------|-----------|-----------|-----------|-----------|----------|----------|------------|------------|
| 0-0.05   | 11,758,244 | 0.0098    | 0.0103    | 51.5      | 46.6      | +29.07   | +27.91   | +1712.3    | +1497.6    |
| 0.05-0.1 | 590,168    | 0.0507    | 0.0503    | 64.9      | 65.2      | +9.68    | +10.07   | +187.4     | +203.5     |
| 0.1-0.2  | 427,423    | 0.0940    | 0.0929    | 67.4      | 67.7      | +6.90    | +6.89    | +117.6     | +121.2     |
| 0.2-0.3  | 224,045    | 0.1535    | 0.1521    | 73.2      | 73.0      | +4.94    | +5.10    | +59.9      | +67.1      |
| 0.3-0.5  | 272,456    | 0.2377    | 0.2365    | 79.6      | 79.0      | +4.24    | +4.43    | +51.6      | +57.1      |
| 0.5-0.75 | 181,836    | 0.3640    | 0.3646    | 83.8      | 82.8      | +3.39    | +3.54    | +31.9      | +34.8      |
| 0.75-1   | 83,300     | 0.5437    | 0.5428    | 86.4      | 84.9      | +2.39    | +2.41    | +16.3      | +16.5      |
| 1-1.5    | 68,530     | 0.7623    | 0.7573    | 84.0      | 82.4      | +1.56    | +1.57    | +8.6       | +8.6       |
| 1.5-2    | 37,445     | 1.0483    | 1.0248    | 83.7      | 81.4      | +1.05    | +1.03    | +5.2       | +5.4       |
| 2-3      | 32,885     | 1.2956    | 1.2579    | 84.8      | 82.3      | +0.48    | +0.44    | +3.3       | +3.3       |
| 3-inf    | 29,180     | 1.6712    | 1.6284    | 82.8      | 76.7      | -0.25    | -0.16    | +3.5       | +3.3       |
| 全部像元     | 13,705,512 | 0.0422    | 0.0423    | —         | —         | -5.91    | -5.07    | +170.2     | +172.0     |


表 19 给出了图 33 (d) 背后的完整数值，并补上了最浅两个区间的行。表中最值得注意的是低估比例随水深的变化。在零点零五米以下，低估像元占一半略多，说明模型在极浅水基本无偏。从零点一米到零点二米，低估比例升到百分之六十七，零点三米到零点五米升到百分之八十，此后在百分之八十三到八十六之间趋于稳定。这个上升段的落点与图 35 中判定指标最低的位置大致重合，说明深水问题的起点大约在水深零点三到零点五米，这个量级对应的是城市地表开始出现明显积水、排水能力趋于饱和的阶段。

表中还有一处对比值得留意。微调把最浅区间的低估比例从百分之五十一降到百分之四十七，把最深区间的从百分之八十三降到百分之七十七，中间各区间只变化了一到两个百分点。改善集中在区间两端，这与 5.2 节得到的结论一致，也就是微调的作用是把分布的两端往中间收了一点，中段几乎没有触动。

表 19 的最深一行与图 36 之间存在一处需要说明的对照。固定面板显示，权重 0.10 的臂在三米以上区间的偏差随训练恶化，从负一点一五米一路下探到负一点八五米。测试集的高阶矩给出的方向相反，三米以上区间的平均偏差从负一点四四米收敛到负一点二三米。两者的差别来自测量总体不同。固定面板只含少量瓦片，它追踪同一批像元随训练的变化，反映的是优化路径。表 19 覆盖全部测试像元，比较的是两个终点权重，反映的是终点位置。两者可以同时成立，因为微调在训练过程中确实有一段把最深区

间推得更浅，也在其余区间把水位整体抬高，最终在测试集上的净效果是偏差收窄。对使用者而言，终点位置才是部署时关心的量。对方法研究而言，优化路径的这段波动解释了为什么深水项不能被无限加大。

误差的量级与分布至此已经说清，还剩一个角度没有交代，就是误差在地理上是不是随机散落的。图 34 用空间自相关回答这个问题，它决定了个别点的修正在多大程度上能代表成片的状况。




**图 34 误差场的空间自相关。** 空间自相关衡量的是相邻位置上的数值是否倾向于同向，它是判断误差属于随机噪声还是成片结构的关键工具。(a) 是逐瓦片 lag-1 空间自相关指标的分布。lag-1 表示只比较一个像元与它紧邻像元的关系，不涉及更远的距离。横轴是指标取值，纵轴是落在该取值的瓦片个数，两条曲线分别对应冻结基线与微调模型。(b) 是同一瓦片在两个模型下的配对散点，横轴是冻结基线的指标取值，纵轴是微调模型的取值，对角虚线是两者相等的参考线，点落在虚线下方说明微调之后自相关下降。指标采用莫兰指数，定义在有效像元上、使用四邻域权重，取值接近一时表示相邻像元的误差高度同向，接近零时表示误差在空间上随机，为负则表示相邻像元误差反向。所有瓦片的有效像元数相同，因此不同瓦片之间可以直接比较。

这张图回答的问题是误差在空间上是不是噪声。如果模型的误差是随机的数值扰动，那么相邻像元的误差应当互不相关，指数接近零。实测结果完全不是这样。(a) 中两个模型的分布都集中在零点五到零点七之间，二百四十二个瓦片中有两百零五个冻结基线瓦片的指数超过零点五，微调后有两百零一个。

零点六五这个数值需要一点直觉来理解。在规则网格上，接近零表示随机，接近一表示完全成片，零点六五意味着误差以成片的形式出现，片的大小大约是若干像元。对照前文的绝对误差图可以看出，这些片正是河道边缘、水陆交界与地形陡变带。误差沿地形结构成片产生，并不在逐点层面各自独立出现。

(b) 的配对散点显示，(a) 中两条分布的位置关系在整个取值范围内都成立。微调模型的空间自相关平均下降零点零零八八，配对检验的统计量为负六点一八，说明下降是系统性的。下降的幅度很小，含义是误差的成片程度略微减弱，误差被摊得稍微均匀了一点。这与 5.2 节的结论一致，微调的作用是让误差更分散，而不是让误差整体消失。

空间自相关这个结果对实际应用有直接含义。如果误差是空间随机的，那么加大观测密度就可以通过平均来消除它。误差高度成片时，同一片内的像元会一起错，增加密度并不能减少片本身的错误，只能把片画得更清楚。要做到这一点，必须引入片尺度上的约束，例如流域尺度或街区尺度的水量守恒，而不是逐点的损失项。这为本报告的最后一条结论提供了依据。



**图 35 淹没超限曲线与阈值敏感性。** 超限曲线在水文学中用来描述超过某一量级的事件有多普遍，这里把水深当作量级，曲线上的每一点表示水深超过该阈值的像元占全部像元的多大比例。(a) 是这一比例随水深阈值的变化，横轴是水深阈值，单位是米，纵轴是像元占比，采用对数标度，因为占比从百分之十量级迅速衰减到千分之几，线性纵轴会把深水段压成一条贴底的直线，看不出差别。三条曲线分别是真值、冻结基线与微调。红色点线标出一米位置，是深水与浅水的分界，也是本报告最关心的区段。(b) 是判定指标随水深阈值的变化，横轴同为阈值，纵轴是取值在零到一之间的临界成功指数。灰色点线标出零点零五、零点三零与一米三个常用阈值。两个子图必须合起来读，(a) 说明有多少水面被漏掉，(b) 说明在什么水深上最容易判错，前者是后果，后者是原因。

(a) 是整份报告中信息密度最高的一张图。它把前面所有关于深水欠估的结论压缩成了一条曲线之间的垂直距离。在零点零五米的低阈值上，冻结基线的面积只有真值的百分之九十二点一，也就是说轻度积水的范围已经被漏掉了约百分之八。随着阈值升高，比值持续下降，到零点五米只剩百分之六十一一点五，到一米是百分之六十四，到两米是百分之六十四点四。深水区段上，模型给出的淹没面积稳定在真值的约六成半。

这个六成半的比值说明问题的性质。欠估不只是深度问题，也是面积问题。模型不只把深水画浅了，还把一部分本该淹没的像元判成了干地。深度与范围同时丢失，两者的相对损失在深水段上大致相当。对防洪应用而言，这意味着基于该模型的淹没图会系统性低估受影响面积，而且低估随着水深增加而加重。


微调曲线在整个阈值范围内都位于冻结基线上方，这是它最干净的一个优点。在零点五米以上，微调把面积比值从百分之六十一一点五提高到百分之六十三点三，在一米以上从百分之六十四提高到百分之六十七点二。改善在所有阈值上方向一致，没有出现某个区间变差的翻转。这一点很重要，因为洪水风险评估关心的是整个阈值范围，而单一阈值的改善可能只是把误差从一处搬到另一处。这里的表现说明微调带来的是真实的、一致的水量补充。

(b) 给出的是判定指标随阈值的变化，形状相当反直觉。两条曲线都在零点三到零点五米之间出现一个明显的低谷，随后在更高的阈值上重新上升。低谷位置的物理含义在于，在这个水深区间，真值中的像元分布最接近模型的判定边界，最容易判错。更深的水体虽然绝对误差更大，但因为它与干地的对比足够强烈，判定反而更容易做对，指标因此回升。两条曲线在整个范围内几乎重合，微调的优势随阈值升高而增大，在一米处约为零点零零六六，在一点五米处约为零点零零八五。

把 (a) 与 (b) 放在一起，可以得到一个对使用者的提醒。如果只报告零点零五米阈值下的判定指标，模型看起来表现不错，因为该处的取值在零点五六附近。但同一张图显示，在那样的阈值下，模型的淹没面积已经比真值少了百分之八，而在更受关注的高水深区间，面积缺失接近四成。指标好不代表结果可用，报告里必须同时给出指标的阈值与对应的面积偏差，否则读者无法判断误差的实际后果。

## 5.10 偏差随训练的演化

前面的结果是终点状态，这一节看过程。可视化脚本在固定的五十块验证瓦片上逐轮记录各水深区间的偏差，这组数据不受子集抽样波动影响，适合观察趋势。这里说的固定面板指的是每一轮都只看同一批瓦片、同一批像元，因此相邻两轮之间的差异不掺入换样本带来的波动，可以干净地反映训练本身把模型推向了哪里。图 36 给出了两个实验臂的变化。



**图 36** 深水偏差随微调轮次的变化（固定验证瓦片）。左右两个子图分别是权重 0.05 与 0.10 的实验臂，两个子图的结构完全一致，可以左右对照。横轴是微调轮次，从第一百八十一轮到第二百零轮。纵轴是平均偏差，单位为米，零线表示无偏差，曲线落在零线以下代表低估，越低表示低估越严重。蓝线是水深一至一点五米区间，红线是三米以上区间，两个区间分别代表深水的入口与最深处。这张图的作用是把最终指标拆回到训练过程中，回答改善是在什么时候、以什么方式出现的。

先看左子图，也就是权重 0.05 的情形。蓝线在一至一点五米区间，从负 0.66 出发，在前几轮略微下探到负 0.72，之后基本持平，到末尾停在负 0.72 附近。红线在三米以上区间，起始于负 1.67，中间有过几次摆动，末尾停在负 1.76 附近，比起点略低。总体来看，两个区间都没有出现明确改善，红线的变化幅度不大。

再看右子图，权重 0.10 的情形。蓝线的走势与左图相似，从负 0.68 出发，末段在负 0.72 附近。红线则明显不同，起点是负 1.15，随后快速下降，在中期达到负 2.1 附近，末尾回升到负 1.85。整条红线整体位于蓝线下方很远的位置，且后半段一直比起点更负。

这张图给出了一个必须明确报告的负面信息。在固定面板上，三米以上区间的偏差不但没有改善，在权重 0.10 下还明显恶化。这个结果与表 15 中最深一行出现的模式完全一致，也与图 28 左子图显示的聚合指标改善同时存在。两者并不矛盾，因为聚合指标衡量的是误差的整体大小，而偏差衡量的是误差的方向。一个区间可以在整体误差减小的同时，偏差方向变得更偏。

为了排除这组变化只是训练本身的自然漂移，需要引入对照臂作参照。对照臂在任何一轮都不使用深水项，它的偏差变化全部来自常规训练。实测中，对照臂在首个五个轮次内就出现了类似的偏差下探，幅度与实验臂相当。这说明一至一点五米区间的下探行为是这套学习率下训练的一般效应，不能归因于深水项。而三米以上区间在权重 0.10 下出现的持续恶化，幅度明显超过对照臂，可以视为深水项带来的副作用。

把这个发现与前文联系起来，可以得到对本报告结论的准确界定。深水项成功地让模型在最深区域整体上更接近真值，这由深水指标与峰值误差的改善所证实。但它没有解决最深区域系统性偏浅的方向问题，在较大权重下甚至让方向问题加剧。这两件事需要分开表述，不能合并成“深水问题已解决”。

## 六 分析与讨论

### 6.1 权重的绝对数字没有意义

阶段三与阶段四的结果放在一起，指向一个在损失函数设计中容易被忽视的事实。深水项权重取 0.5 时，在从头训练的模型上占目标函数的 59%，实验失败。同样取 0.5，在冻结模型上占目标函数的 79.5%，情况只会更糟。权重取 0.10 时，在冻结模型上占 43.6%，实验成功。也就是说，决定成败的是该项在加权后占目标函数的比例，权重数字本身说明不了什么。

这个比例取决于两项，权重以及该项在具体模型上的原始数值。冻结模型带有两米的深水偏差，深水项的原始数值是 1.57，而从头训练的模型偏差较小，原始数值只有 0.52。相差三倍的原始数值意味着，同一个权重在两种模型上的实际强度相差三倍。项目

在制定微调计划时之所以从 0.25 降到 0.10，正是因为先测量了原始数值，没有凭“取一半”的直觉决定。这一步测量是本阶段最关键的判断依据。

由此可以给出一条可操作的准则。引入新的损失项时，先测量它在当前模型上的原始数值，再反推需要的权重。直接套用其他工作的权重数字，在模型已经发生变化的情况下，很容易得到完全不同的强度。

## 6.2 为什么微调比从头训练更适合这个任务

同样的损失项，同样的方向，从头训练失败了而微调成功了。差别来自两个方面。

第一是可用精度的余量。从头训练的模型还没有掌握地形与水流的基本对应关系，它的每一个参数都在同时承担两件事，学会整体映射，以及纠正深水偏差。当深水项把梯度大量引向深水，其他参数就失去了学习整体映射的信号，浅水区因此退化。冻结模型已经完成了整体映射的学习，浅水区的表示相当稳定。微调时深水项的梯度只需要调整深水相关的参数，对这个稳定表示的扰动很小，因此整体精度得以保持。这一点在中子图三条线几乎重合的现象上得到了直接印证。

第二是原始数值的差异带来的自限效应。冻结模型的深水偏差大，深水项原始数值高，同样权重带来更强梯度。这一点在直觉上似乎不利于微调，但结合第一点看，它反而成为一种优势。因为模型只需要修正偏差，而深水项一旦开始修正，其原始数值就会下降，梯度强度随之自动减弱。这种自限特性让训练不容易失控。从头训练时模型同时要学两件事，深水项在训练早期就会施加很强的梯度，而这个阶段恰恰是最不能承受强梯度的阶段。

把两方面合起来，可以概括为一句判断。深水项本身没有问题，问题在于它与训练阶段的匹配。在模型尚未成型时加大权重会破坏学习，在模型已经成型后适度加入则能精确修正。

## 6.3 测量方式与模型设计同等重要

本报告记录的两处测量陷阱，其重要性不亚于模型本身的改动。

第一处关于完成判据。把进程退出码当作成功标志，在本机环境下是错误的，因为所有正常退出都会返回 120。这个判据的错误方向很有意思，它把成功判成了失败。项目早期曾经发生过方向相反的事故，把失败判成了成功。两次事故的共同点是，判据本身与它要判断的事实之间没有可靠的对应关系。修正后的判据建立在训练器自身的产物上，这类判据不容易被环境差异干扰。

第二处关于测量基线。深水指标本身样本稀少，在小样本上的估计不稳定。用这样的小样本去做“取最大值”的选择，选出的结果带有系统性的向上偏差。本项目中偏差的幅度约为 1.5 个标准差，超过了真实的效应大小，足以让结论完全反转。这个问题不容易被发现，因为挑选过程发生在训练脚本内部，记录下来的是挑选后的结果，看不出挑选本身的代价。

识别这个问题的方法在本项目中来自对照臂。对照臂按定义不可能获益，它的指标波动就是噪声水平的直接测量。有了这个测量，才能判断候选臂的领先是否超出了噪声。因此一个不产生任何收益的对照臂，实际上是整个实验设计中最有价值的部分。图 22 把这一点展示得非常清楚，它的价值在于把我们在多大程度上看不见这件事量化出来，这比证明什么有效更有意义。

把两处教训合起来，可以得到一条通用建议。当某个指标在数据中占比很低时，它的测量基线与选择方式需要单独设计，不能沿用整体指标的做法。整体指标可以由大数据量支撑，小样本指标则必须扩大测量范围或者改变选择策略。

## 6.4 与从头训练方案的总体对比

表 20 把两条技术路线放在一起，这是本报告最有实际参考价值的一张表。

**表 20 两种深水修正路线的对比。** 两行都取全量验证集，每个臂与自己路线上的对照比较。从头训练一行对照的是权重为零、训练同样四十轮次的臂。微调一行对照的是同一个父权重、微调同样二十轮次、但深水项权重为零的臂。深水指标指  $CSI@1.00\text{ m}$ ，整体指标指  $CSI@0.05\text{ m}$ 。

| 路线     | 深水权重 | 深水指标变化 | 整体指标变化  | 结论               |
|--------|------|--------|---------|------------------|
| 从头训练   | 0.50 | +0.022 | -0.043  | 深水改善，整体代价过大，否决   |
| 冻结模型微调 | 0.10 | +0.014 | +0.0004 | 深水改善，整体代价接近于零，采纳 |

表中两行的深水改善量级接近，分别为 0.022 与 0.014。真正的差别在第三列。从头训练花费了 0.043 的整体精度，微调对应的变化只有正 0.0004，落在测量噪声之内。以深水收益为分子、整体代价为分母衡量效率，两条路线不在同一个量级上。微调的训练轮次还少一半，总计算量也约为一半。

两行的训练预算并不相同，从头训练每臂四十轮次，微调每臂二十轮次，因此这不是严格的等计算量比较。可以明确的是，在相近的深水收益水平上，微调路线所需的整体精度代价小得多。给从头训练更多轮次或许能收回部分整体精度，但表 15 显示它的退化集中在占 86% 面积的浅水区，这些区域的退化来自梯度被稀释。深水项的强梯度会持续存在，延长训练难以自动修复这一点。

## 七 主要结论

本报告围绕城市洪水深度超分辨率中的深水欠估问题，完成了从诊断到修正的完整工作。主要结论可以归纳为六点。

第一，深水欠估源于训练目标，网络容量是充裕的。诊断显示损失函数中两项主导项都在对数空间计算，深水区两米量级的绝对误差只值十分之一的对数代价。极端项虽然在线性空间计算，但其掩膜阈值取自每个瓦片自身分位数，在多数瓦片上落在 0.19 米附近，实际在监督浅水。两处缺陷叠加，使深水在整个目标函数中缺乏可靠的代表。模型在深水区表现糟糕，源于训练目标没有要求它做好，而它本身具备做好的条件。

第二，纠正这一问题的关键是权重占目标函数的比例，权重数字本身不具有决定性。实测表明，深水项在冻结模型上的原始数值是 1.57，在从头训练模型上只有 0.52。同一个权重数字在两种模型上代表三倍不同的强度。据此把微调权重从原计划的 0.25 降到 0.10，使该项占目标函数的比例从 65.9% 降到 43.6%，落在可控区间。

第三，在已经训练好的模型上做温和微调，能够用很小的代价换取深水改善。采用权重 0.10 微调二十轮后，深水指标在验证集与测试集上分别提升 7.66% 与 8.16%，峰值深度误差与体积误差同样改善，整体指标的变化在统计上与零无法区分。配对检验的效应量达到 1.28，置信区间不跨零。相较于从头训练路线，深水收益相当而整体代价小一个数量级。

第四，测试集上的复现是结论可靠的重要证据。验证集的全部改善都在地理上独立的测试集上复现，方向一致，幅度相当。测试集只在最终选定后读取一次，其数值未参与任何模型选择。这一设计排除了改善来自验证集特化的可能。

第五，深水的方向性偏差并未解决，需要与整体改善分开表述。固定面板证据显示，三米以上区间的偏差在权重 0.10 下反而扩大。聚合指标改善与最深区间偏差恶化同时存在，两者衡量的是误差的不同侧面。测试集的高阶矩给出的方向相反，最深区间的平均偏差从负一点四四米收敛到负一点二三米。两处结果的分歧来自测量总体不同，一处追踪同一批像元的训练路径，一处比较最终权重在全部测试像元上的位置。可以确认的是深水整体上更接近真值，不能确认的是深水不再被系统性压低。

第六，误差的空间与分布结构决定了这个问题不能靠逐点损失解决。深水像元只占总像元的百分之一点二，却承载了全部水量的百分之四十四。误差以成片的形式沿河道与地形陡变带分布，lag-1 空间自相关平均为 0.65，微调只把它降低到 0.649。误差分布的超额峰度在所有深度区间都远大于零，尾部远重于正态分布。淹没超限曲线显示，模型给出的深水面积稳定在真值的六成半，欠估同时发生在深度与范围两个方面。这些结构特征共同说明，误差是一个有空间范围、有厚尾的场，并不表现为独立的逐点扰动。逐点损失项只能移动分布的位置，无法改变分布的这些结构性性质。要真正解决深水欠估，需要在街区尺度或流域尺度上引入水量守恒之类的约束，这是本报告之后最值得推进的方向。

## 八 不足与展望

### 8.1 结论适用范围上的限制

当前的验证只在一个研究区和一个超分辨率倍数上完成，也就是惠灵顿城区的十米到二米。不同城市的地形、排水管网密度与降雨特征差别很大，深水项的合适权重很可能随之变化。把结论推广到其他城市时，原始数值需要重新测量，不能沿用 0.10 这个数字。

雨季情景只有二十五年与一百年两档，且缺少五十年的洪水模拟结果，情景多样性有限。模型 是否在更长重现期、更极端降雨下同样受益，目前没有数据可以回答。这一部分属于数据层面的 限制，需要通过补充模拟来消除。

测试集的整体指标略微下降，虽然在统计上可以视为无变化，但不能完全排除在特定地理区域 存在真实的轻微退化。当前没有按地形类型细分测试集来分析这一点，这是一个可以补充的 分析方向。

### 8.2 方法层面可以继续优化的地方

深水项的形式还有改进空间。当前使用固定的米阈值界定深水，一个更自然的选择是按水深 连续加权，让权重随水深平滑上升，避免在阈值附近出现监督强度突变。这有望缓解最深区间 偏差方向恶化的问题，因为连续加权不会让某一区间的梯度突然变得过强。

当前各处训练都使用同一个学习率计划，而深水参数与其余参数可能需要不同的更新速度。对深水相关参数使用独立的学习率，或者使用按损失项自适应的加权方法，可能让收敛更稳定。本项目已经把权重比例作为核心量来测量，自适应方法可以把这个测量过程自动化。

测量流程方面，本轮实验暴露出小样本指标在选择环节的脆弱性。一个直接的改进是把全量 重新评估从离线步骤变成训练时的常规环节，也就是在训练过程中直接在大验证集上评估，省去先在小样本上挑出候选再复核的步骤。这样做会增加每轮的计算量，但省去了挑选偏差，也省去了事后重新评估的时间。在当前的数据规模下，全量评估每次约两点四分钟，每十轮做一次是可行的。

最后是深水区的偏差方向问题。本报告的诊断指向对数变换压制了深水的绝对梯度，但尚未 设计出既保留浅水敏感度又不压制深水的形式。对数变换的引入原本是为了让浅水区的微小变化 获得足够权重，这一需要是真实的，因此不能简单取消。一种可能的思路是在对数空间中按水深 重新加权，让变换的压缩效应只在浅水区生效。这是后续工作中最值得投入的方向。

### 8.3 主题层面可以拓展的方向

当前的超分辨率只处理最大淹没水深这一个标量场。城市洪水模拟还会输出流速分量、淹没 历时等量，这些量的空间结构与水深并不相同，流速在河道中集中，历时在洼地中较长。把 多变量联合超分辨率纳入框架，可能让模型从量的相互关系中获得额外约束，也有助于判断 深水修正是否会随变量一致地发生。

研究区目前是单一城市。把同一套方法搬到地形与气候差异较大的其他城市，可以检验深水 项结论的可迁移性。这类跨城市实验的价值在于，它会暴露哪些权重设置是普适的，哪些只是 对本研究区地形特征的适配。

此外，当前结果全部来自确定性模型。真实的水文模拟带有不确定性，同一场降雨在不同 参数下会给出不同的水深场。如果超分辨率模型能够同时给出预测的不确定性范围，对防洪 决策会有更直接的帮助，例如可以区分"确定会淹到一米"与"可能淹到一米"这两类区域。这类概率化的扩展与深水修正并不冲突，可以叠加进行。

附录一 术语表

表 21 报告中出现的主要术语。解释按物理意义、在公式中的位置、以及为何 需要引入三层展开。

| 术语       | 全称与解释                                                                                                        |
|----------|--------------------------------------------------------------------------------------------------------------|
| 超分辨率     | Super-resolution，把低分辨率场重建为高分辨率场的技术。 在本任务中，输入是十米网格的水深，输出是二米网格的水深。与图像超分辨率不同的是，输入是一次独立的水动力求解结果，与输出之间没有降采样关系。    |
| 引导式      | Guided，指重建过程同时使用低分辨率水深与高分辨率 静态地理信息。之所以需要引导，是因为仅凭低分辨率水深无法判断被网格抹掉的细节应该填在 哪里，地形信息提供了这个判断依据。                     |
| 临界成功指数   | Critical Success Index，洪水制图标准指标。 计算为命中数除以命中、漏报与误报之和。下标表示判定阈值。选择这个指标的理由在于，洪水事件中不积水区域占绝大多数，用准确率会得到虚高分数。        |
| Huber 损失 | 一种对离群值稳健的回归损失。在误差小于某转折点 时表现为二次函数，超过后转为线性。引入它是因为水深场中存在个别极端像元，纯二次损失会 被这些像元主导。                                  |
| 对数空间     | 把水深取自然对数后再计算误差的空间。引入对数 变换是为了让浅水区的微小水深变化获得与深水区相当的相对权重。它的副作用是压制深水区的 绝对误差，这是本报告诊断出的第一处缺陷。                       |
| 掩膜       | Mask，用于选择损失函数作用范围的布尔张量。深水项的 掩膜由真实水深阈值定义。掩膜设计的质量直接决定损失项是否作用于它应该作用的位置，本报告 诊断出的第二处缺陷正是掩膜阈值取自每瓦片分位数。             |
| 配对比较     | Paired comparison，在两个条件在其他方面完全 匹配时，直接比较同条件下的差值。本报告的微调实验三臂从同一权重出发、同轮次相对应， 因此可以配对相减，差值中不含训练轮次差异带来的干扰。          |
| 效应量      | Effect size，衡量差值相对于其自身波动的倍数。相比于显著性检验只回答"是否存在差异"，效应量还回答"差异有多大"。本报告使用科恩 d， 通常认为 0.8 以上为大效应。                    |
| 自助法      | Bootstrap，通过对样本反复重抽样来估计统计量的 分布。引入它是因为配对差值的分布未必接近正态，自助法不依赖分布假设，可作为t检验置信 区间的稳健性对照。                             |
| 瓦片       | Patch，数据切分的基本单位，边长 480 米。选择这个 尺寸是因为它在全部五种分辨率下都能整除，读取时不必跨存储块拼接。                                               |
| 湿区       | Wet area，水深大于零的像元构成的区域。引入它是为了把 干地排除在误差统计之外，因为在干地上讨论水深没有意义。湿区像元的数量决定了数值类指标 由哪些位置主导。                           |
| 残差       | Residual，模型在参考值基础上需要补充的那个修正量。 本报告的输出端先在粗网格水深上做双三次插值得到基础场，再让网络预测残差叠加其上。 引入残差形式是为了让网络只需要学习被网格抹掉的细节，降低学习难度。     |
| 对数变换     | Logarithmic transform，先对水深取自然对数再 计算误差的做法。引入它是因为水深跨越四个数量级，取对数后各深度区间的相对误差变得可比。它的副作用是压缩深水区的绝对梯度，这是本报告诊断出的第一处缺陷。 |
| 分位数      | Quantile，把一组数值从小到大排序后按位置取到的 数值，例如九十五分位数表示有九成五的样本比它小。本报告用它来描述极端项的掩膜阈值， 因为该阈值按每个瓦片自身上限的九十五分位数取，在不同瓦片间并不一致。     |
| 隐式算子     | Implicit neural operator，一种在连续坐标上 查询取值的网络结构。常规卷积只能在固定网格上输出结果，隐式算子接受任意坐标作为输入， 因此可以把十米网格的输入直接映射到二米网格，不必逐级放大。   |
| 莫兰指数     | Moran's I，衡量相邻位置上数值是否同向的 空间自相关指标，取值接近一表示高度同向，接近零表示随机。引入它是为了判断误差是独立 的逐点扰动还是成片的结构性偏差，这个判断决定了能否用逐点损失项解决问题。      |

| 术语    | 全称与解释                                                                                                           |
|-------|-----------------------------------------------------------------------------------------------------------------|
| 偏度    | Skewness，误差分布的三阶矩，衡量分布两侧尾部 是否对称。正值表示右侧尾部更长。本报告用它区分两个容易混淆的现象，多数深水像元被低估 与少数像元被大幅高估可以同时发生。                         |
| 超额峰度  | Excess kurtosis，误差分布的四阶矩减去正态 分布的值，衡量尾部相对于正态分布有多厚。正值越大表示极端误差越频繁。本报告用它说明 深水欠估来自厚尾结构，用正态假设去推断风险会低估极端情形。            |
| 超限曲线  | Exceedance curve，横轴取水深阈值、纵轴取 超过该阈值的像元占比所得到的曲线。引入它是因为单一阈值的指标无法反映误差随阈值的变化， 超限曲线可以把深度与范围两类损失放在同一条曲线上比较。            |
| 重现期   | Return period，某量级降雨平均多少年出现一次。 二十年重现期表示这样的降雨平均每二十年一遇。引入它是为了给降雨情景一个统一的发生概率 标签，使不同强度的模拟结果可以相互比较。                   |
| 双线性插值 | Bilinear interpolation，按目标点到四个 邻近网格点的距离做加权平均来放大的方法。本报告把它作为不做学习的参照，用来确认模型的 优势确实来自学习而不是来自平滑，并说明粗网格向细网格的换算为何改用最近邻。 |
| 细网格口径 | Fine-lattice dialect，把粗方块的值按最近邻铺到 它覆盖的每个细单元上再与细网格真值逐格比较的算法。它把模型误差与方块内部的地面不均匀 混在一个指标里，因此读数系统性偏高，本报告不用它作为主口径。     |
| 粗网格口径 | Coarse-lattice dialect，把粗网格模拟值与同一 方块的聚合后的细网格真值比较的算法。它与下游需要的格网一致，只测模型算得准不准， 本报告用它作为主口径。                          |
| 块内方差  | Within-block variance，方块内各细单元的水深偏离 该方块聚合真值的平方的平均。它是两个口径之间那条恒等式的第二项，只由细网格真值决定， 属于下游超分辨率环节负责补出的细节。                |

## 附录二 复现命令

下表列出生成报告中全部数值与图表的命令。所有命令均可在项目根目录直接执行。

表 22 复现命令与对应产物。

| 用途       | 命令                                                                                                                                                  |
|----------|-----------------------------------------------------------------------------------------------------------------------------------------------------|
| 基线评估     | <code>python scripts/evaluate.py --config configs/v0_10m2m_hmax.yaml --model hydrogeo_srno --ckpt outputs/v0_10m2m_hmax/last.pt --split test</code> |
| 深水微调     | <code>python scripts/run_deep_finetune.py --arms 0.0 0.05 0.10 --epochs 20 --lr 1e-4</code>                                                         |
| 全验证集逐轮重评 | <code>python scripts/scan_epochs.py --arms w005 w01 w00 --stride 1 --include-maxes</code>                                                           |
| 配对统计     | <code>python scripts/report_stats.py</code>                                                                                                         |
| 报告图表     | <code>python scripts/make_report_figs.py</code>                                                                                                     |
| 生成本报告    | <code>python scripts/build_report.py</code>                                                                                                         |

所有数值来源文件位于 `outputs/finetune_deep/epoch_scan.json`、`outputs/finetune_deep/report_stats.json`、`outputs/post_sweep/metrics/` 与 `outputs/deep_sweep/`。图表按 `SciencePlots` 规范绘制，字体为 `Times New Roman`，其余参数与报告正文同源。

本报告由项目内实测数据、评估脚本与统计脚本自动汇总生成，所有数值均可由 outputs/ 下的 JSON 逐项复算。图表按 SciencePlots 规范绘制，正文与图表数据同源。